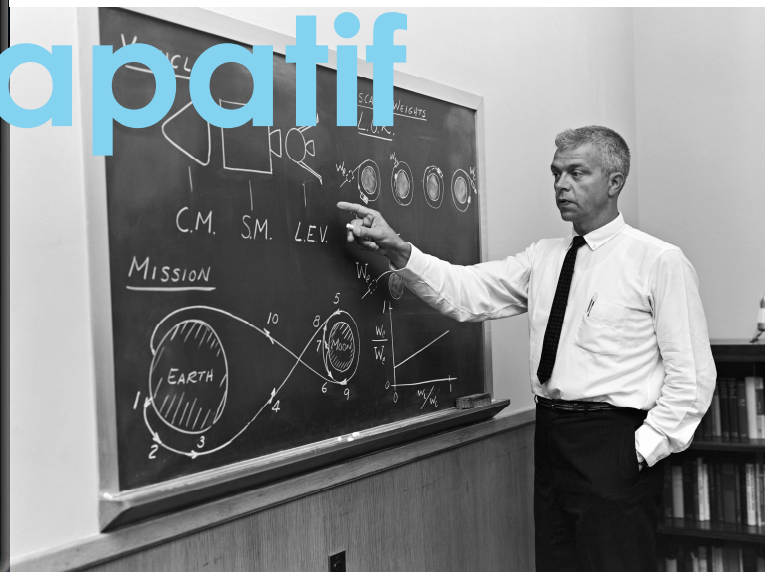
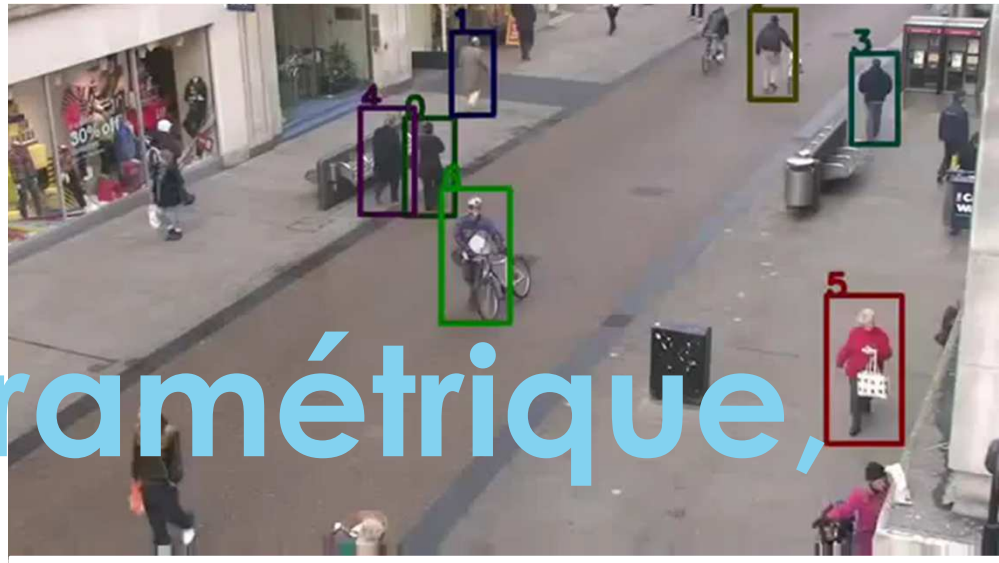
Modélisation Paramétrique, Filtrage Optimal et Adaptatif







How an Inventor You've Probably Never Heard of Shaped the Modern World

A 56-year-old algorithm continues to have a heavy influence on the technologies we all use daily

***David Mindell** is a professor at MIT and founder of Humatics, a Cambridge, Massachusetts, microlocation company that utilizes the Kálmán filter. **Frank Moss**, an alumnus of the MIT Instrumentation Laboratory that built the Apollo computers, is a former director of the MIT Media Lab and a board member at Humatics*

The very same guidance and navigation problems faced by Apollo engineers 50 years ago challenge engineers today as they design self-driving cars.

MIT Technology Review

Pascal Scalart

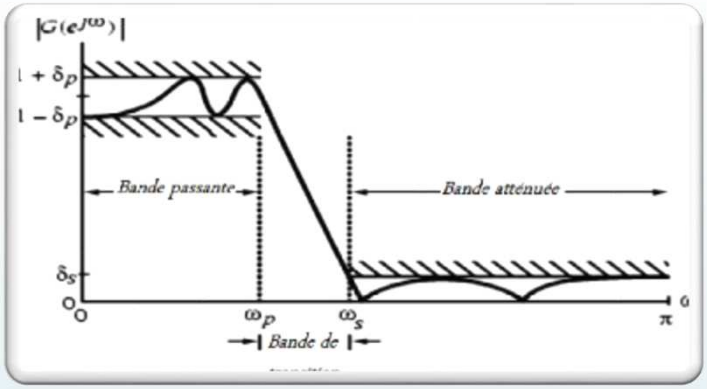
ENSSAT-Université de Rennes

pascal.scalart@univ-rennes1.fr

Septembre 2017

Filtrage classique v.s. Filtrage Optimal

- Le filtrage « **classique** » : Modification du spectre (amplitude, phase) afin de satisfaire un certain nombre de contraintes (gabarit fréquentiel et temporel)



- Le filtrage « **Optimal** »
  - Vise à « séparer » au mieux un signal utile et un signal perturbateur. Par exemple à « extraire » un signal utile perturbé par du bruit
  - Solutions basées sur la théorie de l'**estimation statistique** des **signaux aléatoires** stationnaires
    - Méthodes non-bayesiennes (le paramètre recherché est déterministe) : critères de la variance minimale, du maximum de vraisemblance, des moindres carrés
    - Méthodes bayesiennes (le paramètre recherché est une v.a.) : maximum (vraisemblance) a posteriori, EQMM
  - Nécessite uniquement la **connaissance *a priori*** des propriétés statistiques des signaux aléatoires traités (val. moyenne, variance, fonction autocorrélation, DSP…)

Structure générale : cas du débruitage

Principe général

connaisances a priori

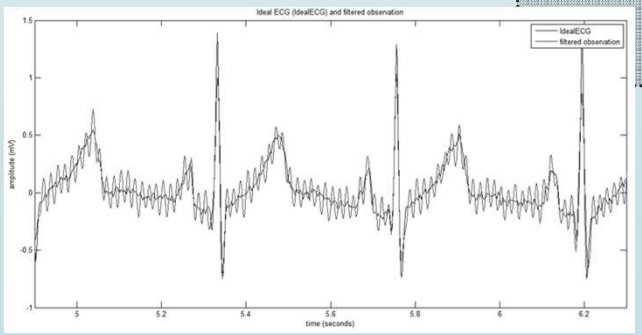
Calcul du filtre optimal

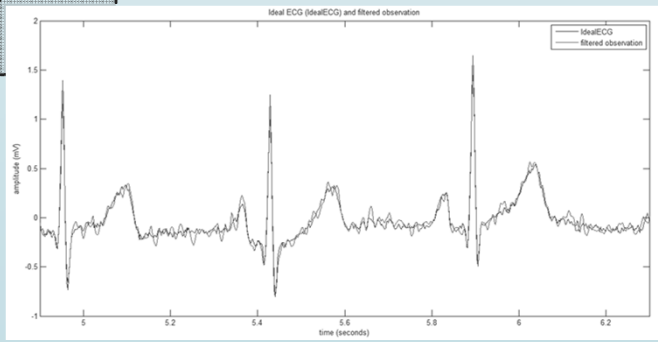
h^{opt}

$x[k] = s[k] + b[k]$

Filtre Optimal

$\hat{s}[k]$

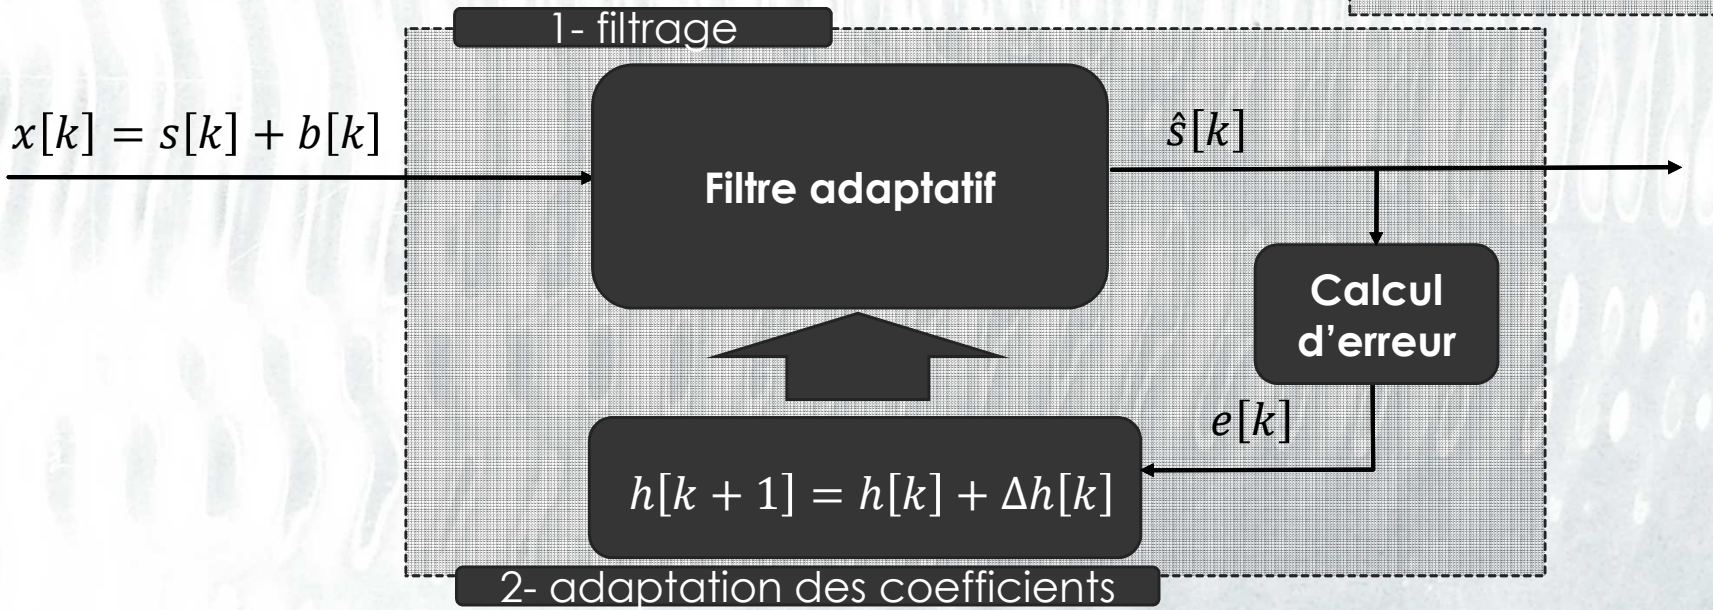




Filtrage Optimal v.s. Filtrage Adaptatif

- Le filtrage « **Adaptatif** »
  - Ne nécessite **pas de connaissance *a priori*** des propriétés statistiques des signaux aléatoires traités
  - Le « filtre optimal » **se construit au fur et à mesure** de l'arrivée des échantillons. **s'adapte** au cours du temps aux évolutions des propriétés statistiques des signaux
  - Dans le cas stationnaire, le filtre **converge** vers le « filtre optimal »

$$\lim_{k \to +\infty} h[k] = h^{opt}$$



Les principales applications…



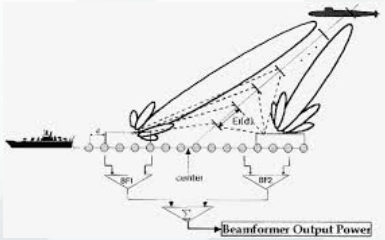
Massive MIMO



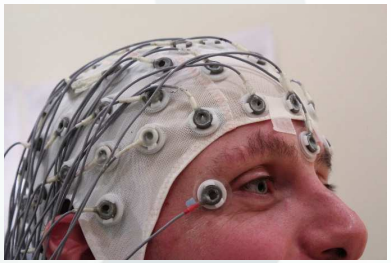
radar



Trait. image



Sonor-Antennes

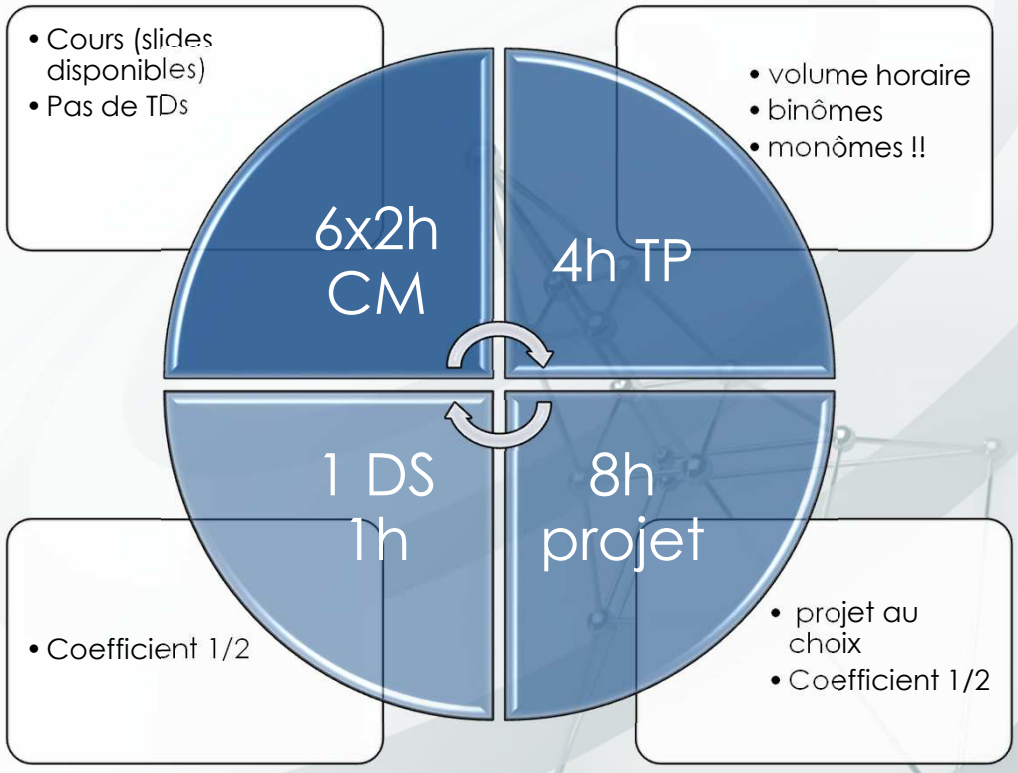


Biomedical

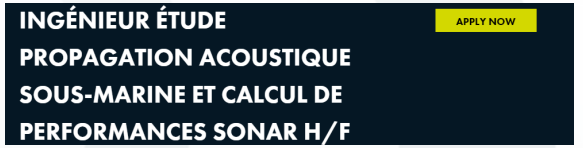
Applications du Filtrage Optimal et du Filtrage Adaptatif

Réduction de bruit	Prédiction de Signal	Identification de système	Annulation d'écho	Egalisation	Réseaux de neurones
Réalisation d'un filtre pour supprimer le bruit au sein d'un signal observé de manière adaptative pour augmenter le RSB	Réalisation d'un filtre permettant d'obtenir une prédiction de la valeur future/passée d'un signal alétoire	Réalisation d'un filtre permettant de déterminer le filtre permettant de modéliser un système réel inconnu	Réalisation d'un filtre permettant de supprimer un signal interférent (l'écho) présent au sain du signal capté	Réalisation d'un filtre permettant de compenser les distorsions introduites sur un signal lors de sa propagation	Adaptation des « poids » d'un réseau de neurones : algorithme de « backpropagation »

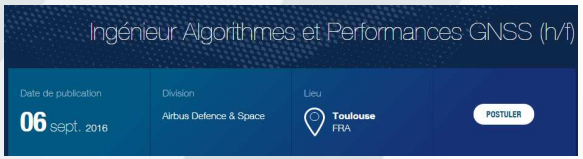
Le programme…











° **Egalisation numérique** pour les transmissions sans fil

° **Annulation d'écho** électrique dans les réseaux de transport

° **Réseaux de neurones** pour l'intelligence artificielle

° **Filtrage de Kalman** pour la navigation inertielle

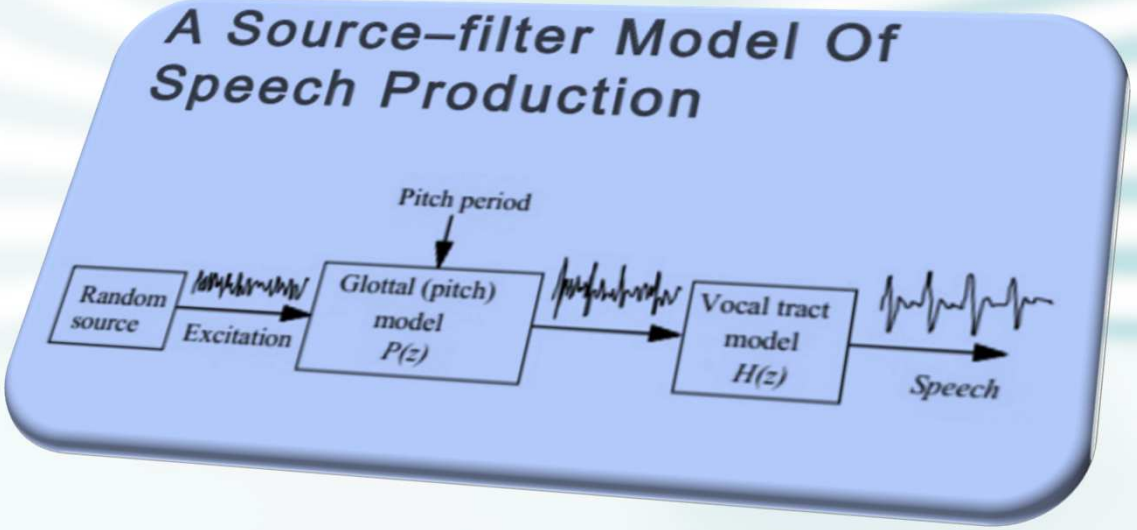


Plan du cours

1. Modélisation paramétrique des signaux aléatoires
2. Prédiction linéaire
3. Filtrage optimal de Wiener
4. Filtrage adaptatif: algorithmes stochastiques
5. Filtrage adaptatif: algorithme des moindre carrés
6. Filtrage de Kalman

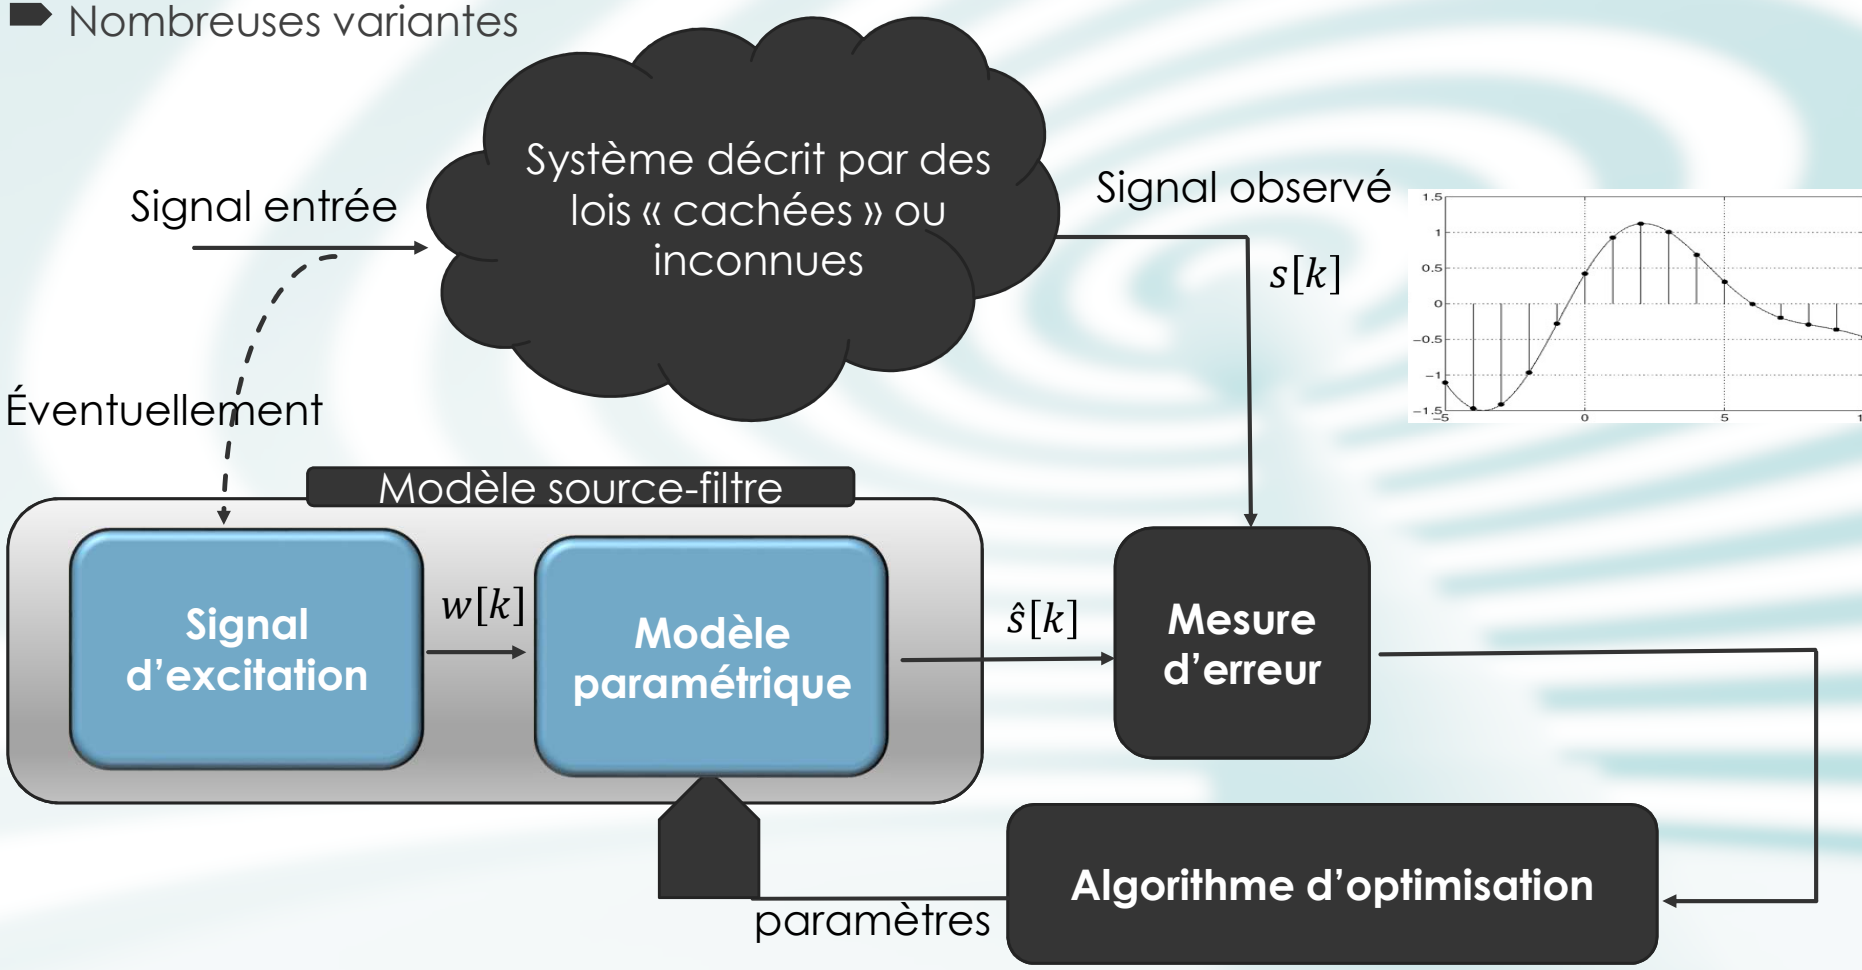


Modélisation paramétrique des signaux aléatoires



Le problème général

- Nombreuses variantes





Théorème de Wold

- Enoncé : « *Tout processus aléatoire stationnaire (au second ordre) à temps discret peut être décomposé en une somme d'un processus aléatoire linéaire et d'un processus prédictible* »

$$s[k] = s_1[k] + s_2[k]$$

- La plupart des processus sont bien approximés par un modèle rationnel linéaire dont les caractéristiques sont les suivantes :
  - les signaux $s_1[k]$ et $s_2[k]$ sont des signaux élatoires **décorrélés**
  - $s_1[k]$ est un processus aléatoire linéaire : $s_1[k] = \sum_{m=0}^{+\infty} b[m]\, w[k-m]$

    où $w[k]$ est un **bruit blanc** (bien sûr décorrélé de $s_2[k]$ d'après le premier point)

$$\mathbb{E}(s_1[m]\, w^*[n]) = 0 \qquad \forall (m,n) \in \mathbb{N}^2$$

  - $s_2[k]$ est un **processus prédictible** c'est-à-dire que l'on peut l'estimer avec une erreur nulle
  - Le filtre $B(z) = \mathrm{TZ}(b[n])$ est stable : $\sum_{m=0}^{+\infty} |b[m]| < \infty$

Trois cas particuliers

- Le **modèle auto-régressif** d'ordre P ou AR(P)

$$\begin{cases} s_1[k] = w[k] \\ s_2[k] = -\sum_{m=1}^{P} a[m]s[k-m] \end{cases}$$

(on suppose $b[0] = 1$)

→ Modèle simple à P paramètres

- Le **modèle à moyenne ajustée** d'ordre Q ou MA(Q)

$$\begin{cases} s_1[k] = \sum_{m=0}^{Q} b[m]w[k-m] \\ s_2[k] = 0 \end{cases}$$

(on suppose $b[0] = 1$)

→ Modèle « moins » simple à Q paramètres

- Le **modèle à auto-régressif à moyenne ajustée** ou ARMA(P,Q)

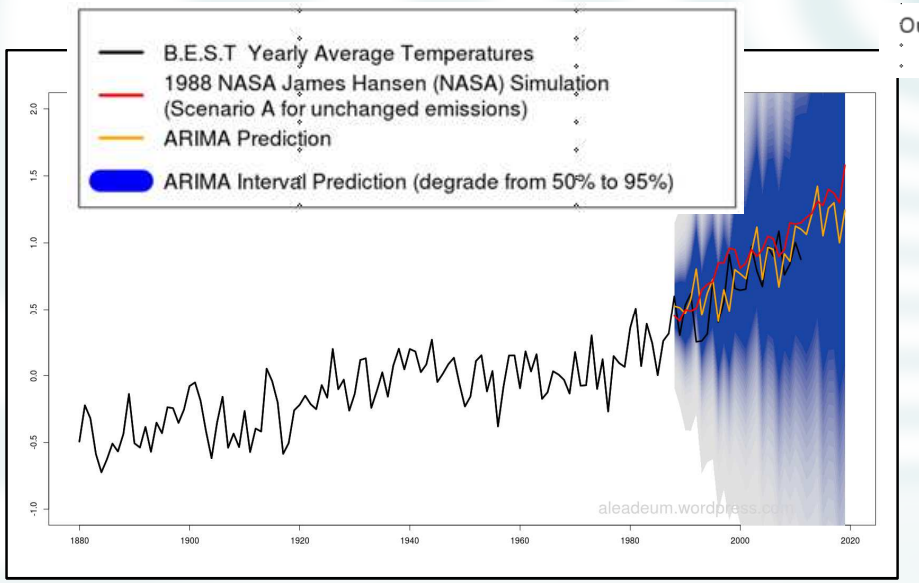
$$\begin{cases} s_1[k] = \sum_{m=0}^{Q} b[m]w[k-m] \\ s_2[k] = -\sum_{m=1}^{P} a[m]s[k-m] \end{cases}$$

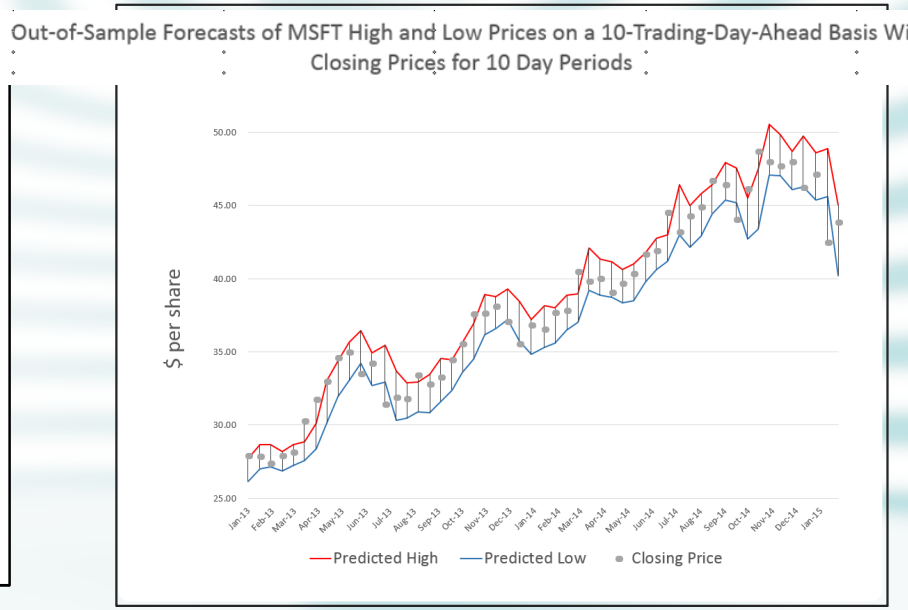
(on suppose $b[0] = 1$)

→ Modèle très général à P+Q paramètres

Une portée très large

- Ces modèles sont généralisés en **économétrie** où l'on parle de **modèle auto-régressif intégré à moyenne ajustée** ou ARIMA(P,D,Q)
- Ces modèle peuvent être appliqués lorsque le signal est non-stationnaire. Ils appliquent préalablement D étapes de différenciation sur le signal afin de réduire les non-stationnarités





Modèle AR(P) : modèle source-filtre (1/4)

- Propriétés
  - Les **coefficients** du modèle sont dédiés à la représentation du **signal prédictible**
  - Le signal **non-prédictible** est réduit à sa **plus simple expression**

- Relation entrée/sortie :

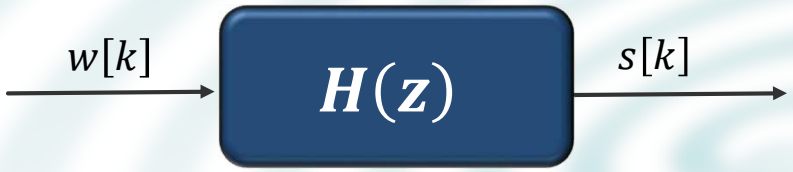
$$s[k] = w[k] - \sum_{m=1}^{P} a[m]s[k-m]$$

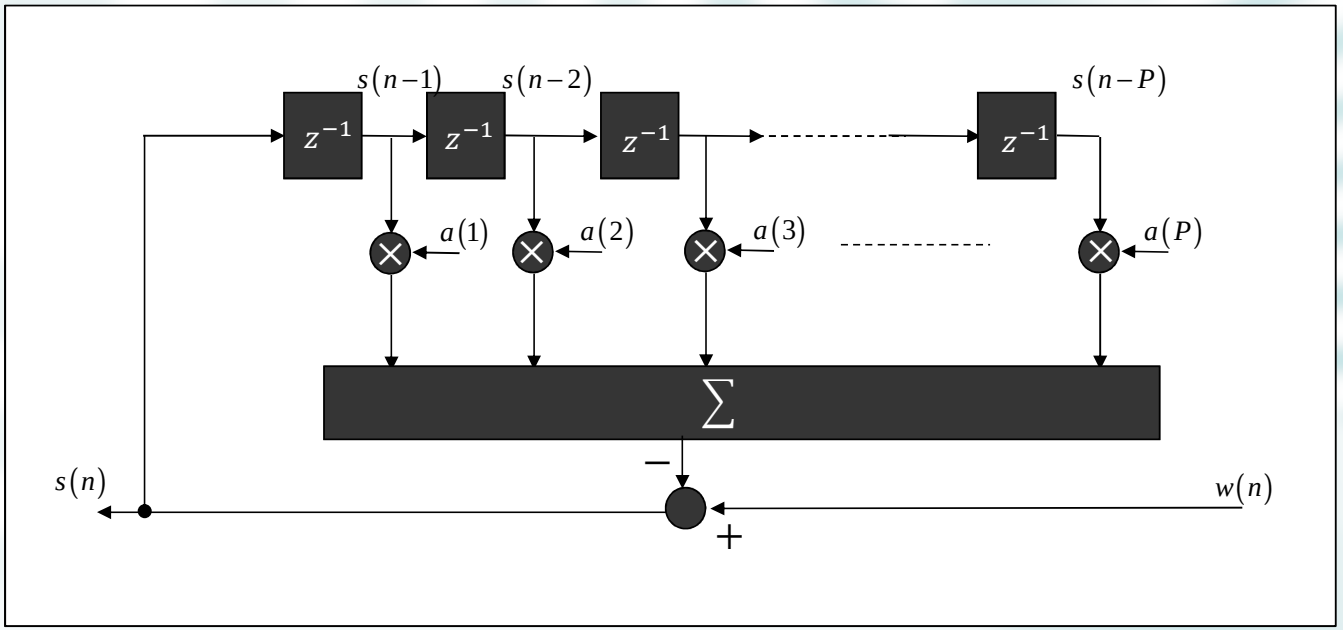
- On a une régression linéaire d'un processus sur lui-même d'où le terme **auto-régressif**
- On introduit un coefficient fictif $a[0]$=1. On peut alors écrire :

$$H(z) = \frac{S(z)}{W(z)} \Longleftrightarrow \boxed{H(z) = \frac{1}{A(z)} \quad \text{avec} \quad \mathrm{A}(z) = \sum_{m=0}^{P} a[m]z^{-m}}$$

Modèle AR(P) : modèle source-filtre (2/4)

- Propriétés : Il s'agit d'un filtre à temps discret de type IIR (Infinite Impulse Response)





Modèle AR(P) : Densité Spectrale de P. (3/4)

- La densité spectrale de puissance du signal disponible en sortie d'un modèle AR(P) est obtenue à partir de la formule des interférences

$$R_{ss}[k] = h[k] * h^*[-k] * R_{ww}[k] \Rightarrow S_{ss}(z) = H(z)H^*\left(\frac{1}{z^*}\right)S_{ww}(z)$$

- Soit encore pour un filtre causal, **stable**, à coefficients réels : $z = e^{j2\pi f}$ appartient au domaine de convergence de $H(z)$, soit :

$$S_{ss}\left(e^{j2\pi f}\right) = \left|H\left(e^{j2\pi f}\right)\right|^2 S_{ww}\left(e^{j2\pi f}\right) \Rightarrow S_{ss}\left(e^{j2\pi f}\right) = \frac{S_{ww}\left(e^{j2\pi f}\right)}{\left|\sum_{m=0}^{P} a[m]e^{-j2\pi mf}\right|^2}$$

- En prenant une **hypothèse neutre** sur le processus ayant généré le signal d'observation, on a

$$\boxed{S_{ss}\left(e^{j2\pi f}\right) = \frac{\sigma_w^2}{\left|\sum_{m=0}^{P} a[m]e^{-j2\pi mf}\right|^2}}$$

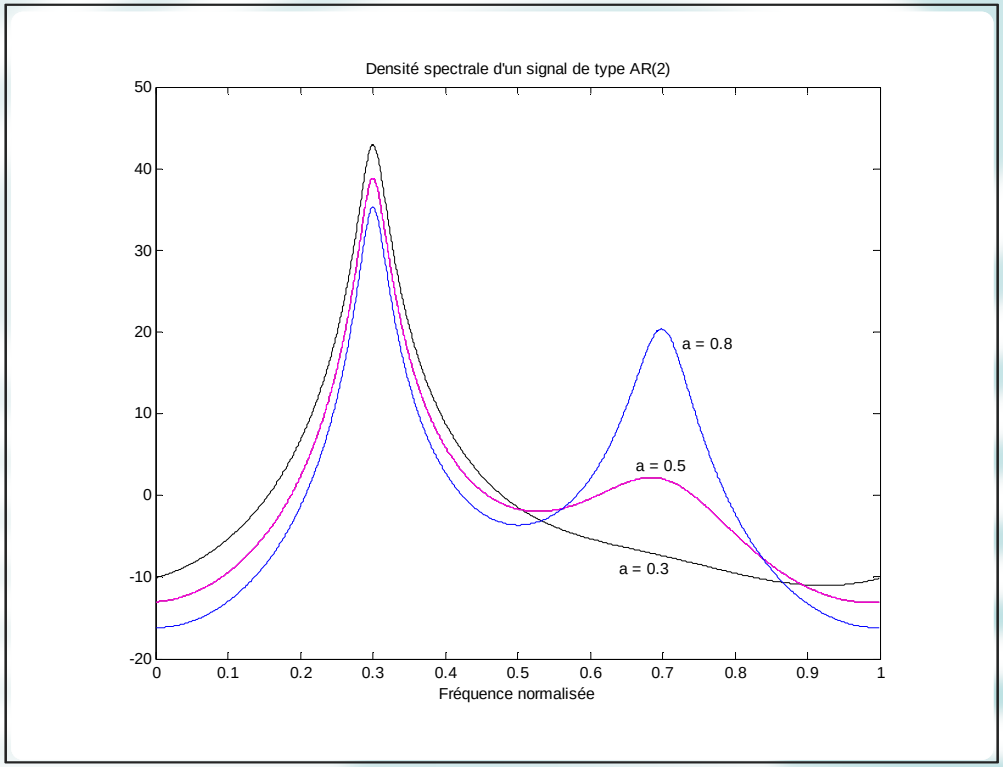
- La modification des coefficients du modèle va donc modifier la position des pôles de la fonction de transfert $H(z)$ soit donc **la position des maxima spectraux** de la densité spectrale $S_{ss}\left(e^{j2\pi f}\right)$

Modèle AR(P) : Densité Spectrale de P. (4/4)

- Exemple de DSP d'un processus AR(2)
  - Entrée = bruit blanc de puissance unitaire
  - 2 pôles dont un est fixe

$$\sigma_w^2 = 1$$
$$p_1 = 0.9\, e^{j2\pi\, 0.3}$$
$$p_2 = \mathrm{a}\, e^{j2\pi\, 0.7}$$

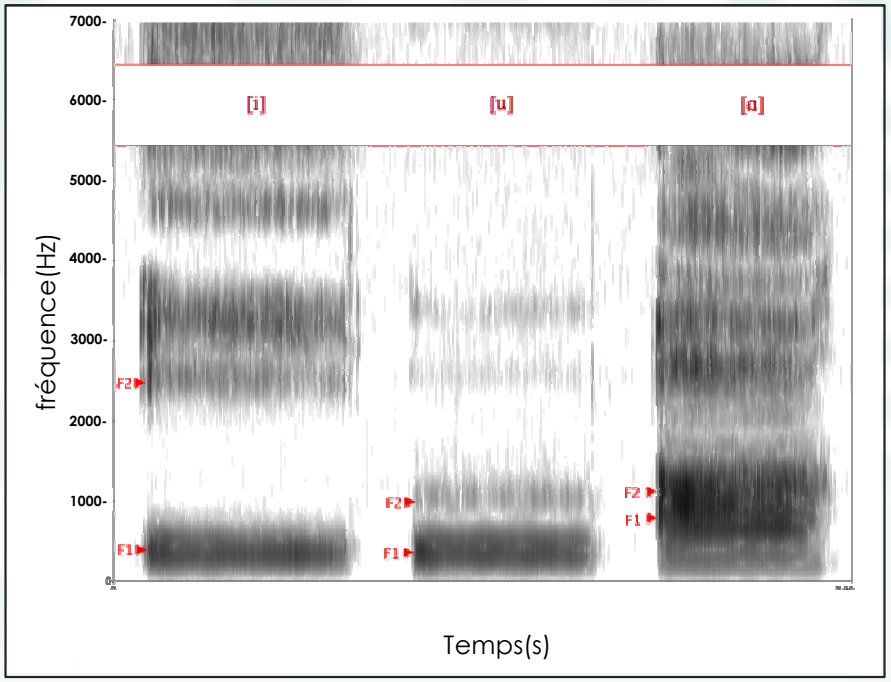
- Le paramètre $a \in [0,1[$ de manière à ce que le filtre $H(z)$ soit causal et stable
- Si de plus les pôles du filtre $H(z)$ sont conjugués alors la DSP $S_{ss}\left(e^{j2\pi f}\right)$ est paire

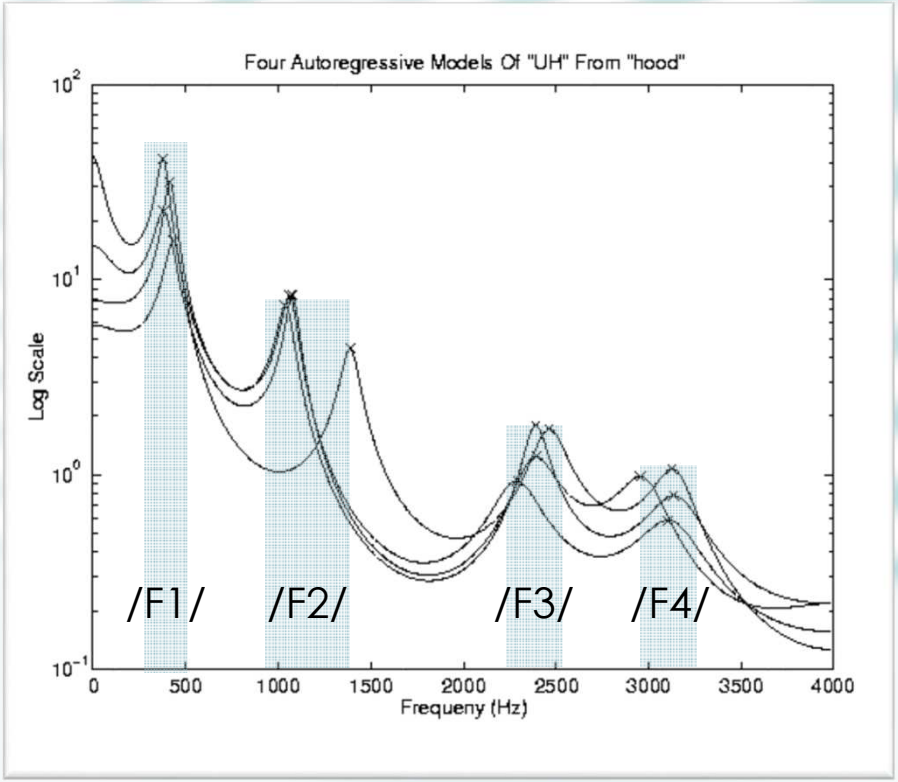


- AR(P) $\equiv P$ maximas spectraux sur $S_{ss}\left(e^{j2\pi f}\right)$ pour $f \in \left[-\frac{1}{2}, +\frac{1}{2}\right]$

Modèle AR(P) : Exemple utilisation (5/5)

- Modélisation paramétrique des signaux audio
  - Sur des trames de 20 ms (quasi-stationnarité)
  - Modélisation AR (8) : 4 zones formantiques (de résonnance) dans $f \in [0,4\text{kHz}]$





Modèle MA(Q) : modèle source-filtre (1/4)

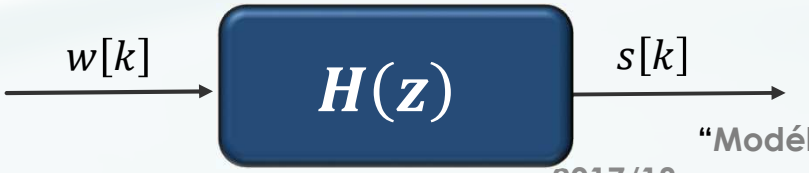
- Propriétés
  - Les **coefficients** du modèle sont dédiés à la représentation du **signal non prédictible**
  - Le signal **prédictible** est réduit à sa **plus simple expression : zéro**

- Relation entrée/sortie : $s[k] = \sum_{m=0}^{P} b[m]w[k-m]$

- On introduit un coefficient fictif $\mathrm{b}[0]$=1. On peut alors écrire :

$$H(z) = \frac{S(z)}{W(z)} \Longleftrightarrow \boxed{H(z) = B(z) \quad \text{avec} \quad B(z) = \sum_{m=0}^{P} b[m]z^{-m}}$$

- Il s'agit d'un filtre à temps discret de type FIR (Finite Impulse Response)



Modèle MA(Q) : Densité Spectrale de P. (2/4)

- La densité spectrale de puissance du signal disponible en sortie d'un modèle MA(Q) est donnée par

$$S_{ss}(z) = H(z)H^*\left(\frac{1}{z^*}\right)S_{ww}(z)$$

- Pour un filtre causal, **stable**, à coefficients réels : $z = e^{j2\pi f}$ appartient au domaine de convergence de $H(z)$, soit :

$$S_{ss}\left(e^{j2\pi f}\right) = \left|H\left(e^{j2\pi f}\right)\right|^2 S_{ww}\left(e^{j2\pi f}\right) \Rightarrow S_{ss}\left(e^{j2\pi f}\right) = S_{ww}\left(e^{j2\pi f}\right)\left|\sum_{m=0}^{Q} b[m]e^{-j2\pi mf}\right|^2$$

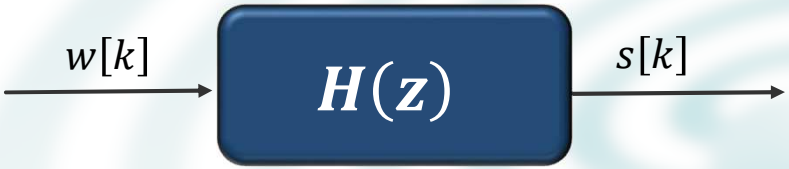
- En prenant une **hypothèse neutre** sur le processus ayant généré le signal d'observation, on a

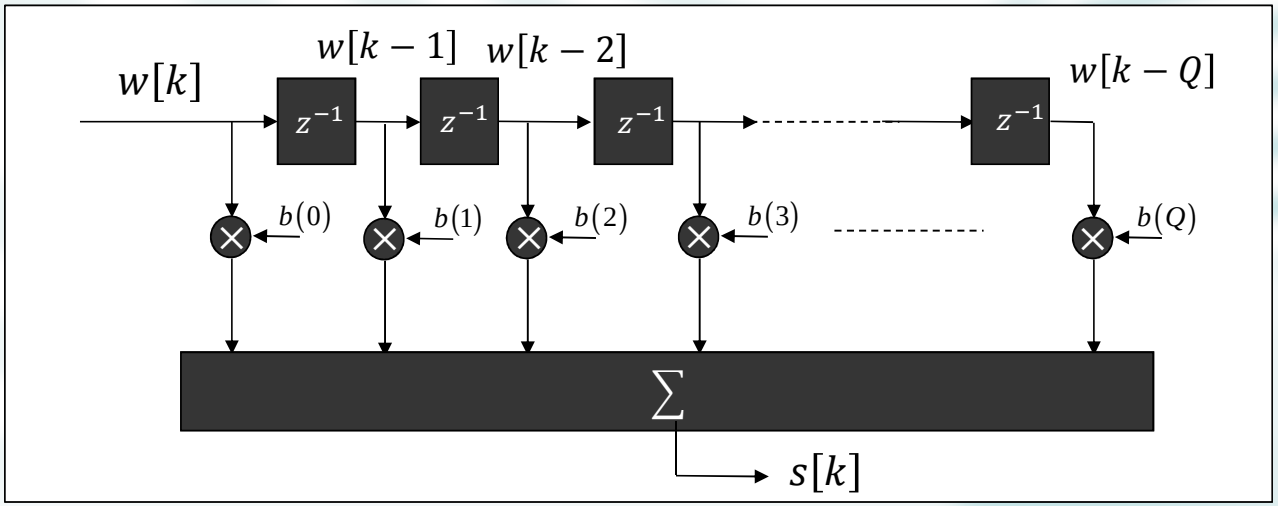
$$\boxed{S_{ss}\left(e^{j2\pi f}\right) = \sigma_w^2\left|\sum_{m=0}^{Q} b[m]e^{-j2\pi mf}\right|^2}$$

- La modification des coefficients du modèle va donc modifier la position des pôles de la fonction de transfert $H(z)$ soit donc **la position des minima spectraux** de la densité spectrale $S_{ss}\left(e^{j2\pi f}\right)$

Modèle MA(Q) : modèle source-filtre (3/4)

- Propriétés : Il s'agit d'un filtre à temps discret de type FIR (Finite Impulse Response)

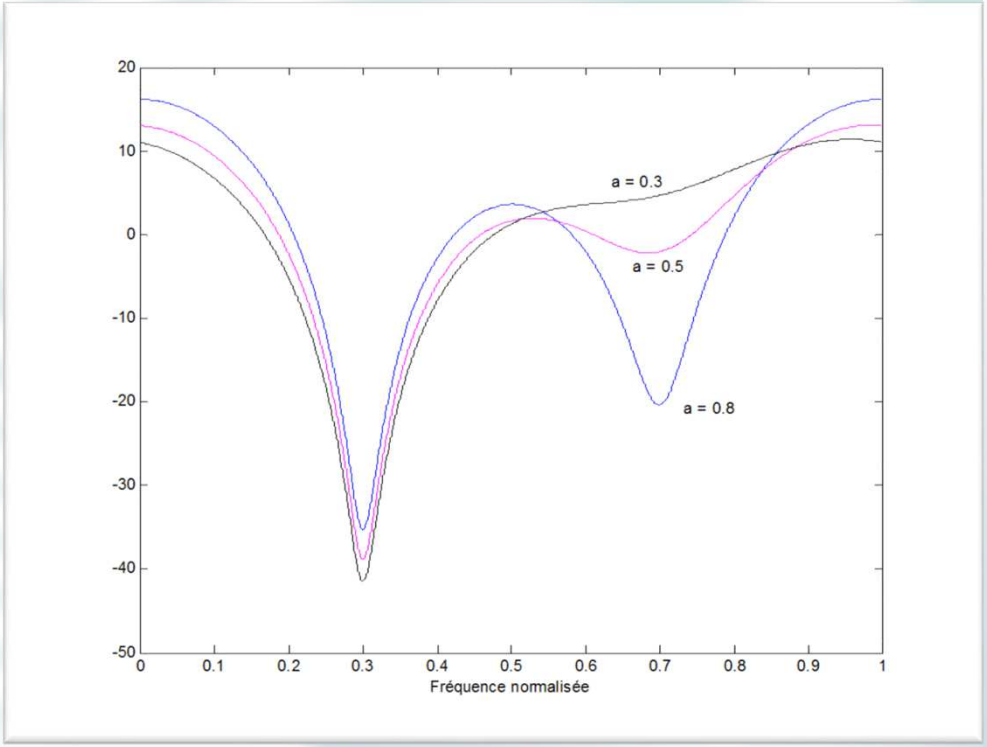




Modèle MA(Q) : Densité Spectrale de P. (4/4)

- Exemple de DSP d'un processus MA(2)
  - Entrée = bruit blanc de puissance unitaire
  - 2 zéros dont un est fixe

$$\sigma_w^2 = 1$$
$$z_1 = 0.9\, e^{j2\pi\, 0.3}$$
$$z_2 = \mathrm{a}\, e^{j2\pi\, 0.7}$$

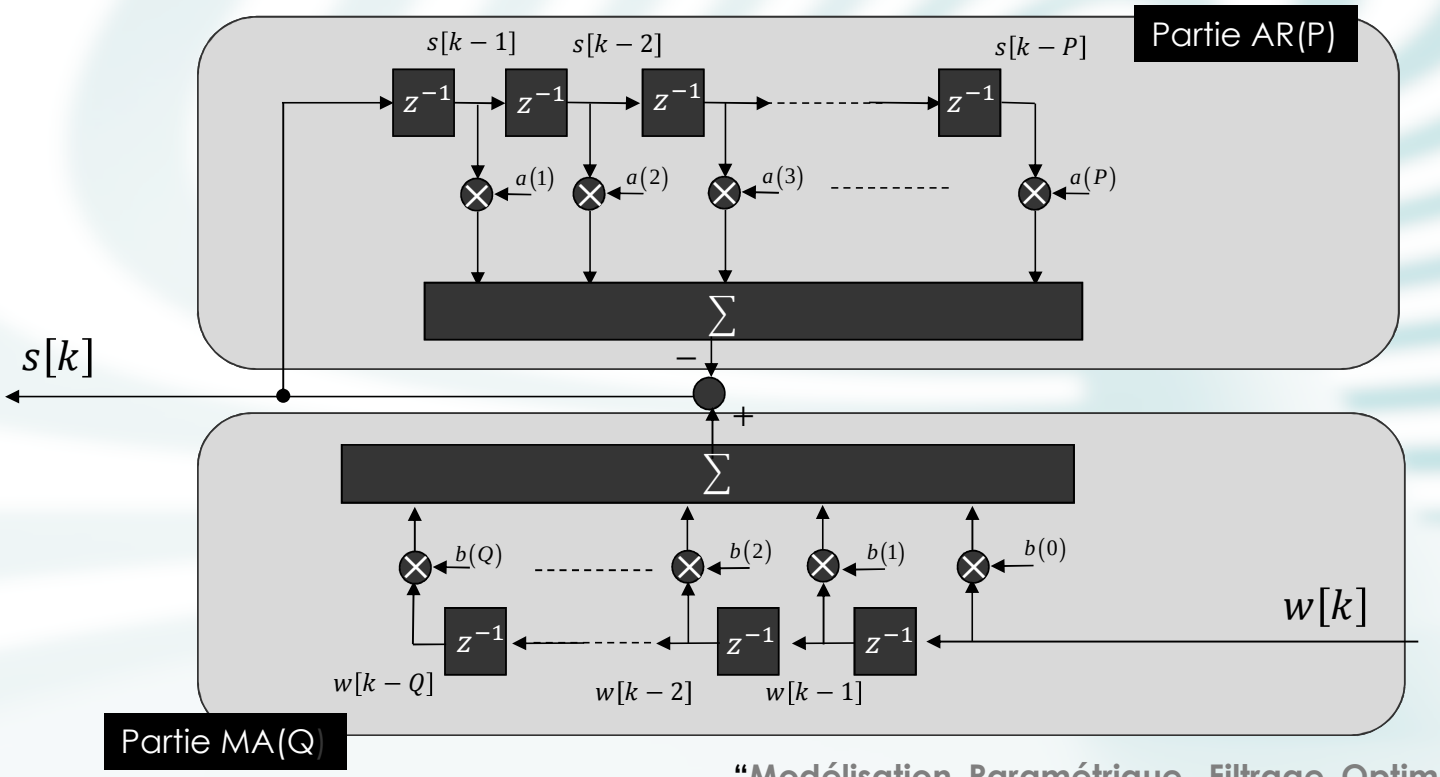


  - Si de plus les pôles du filtre $H(z)$ sont conjugués alors la DSP $S_{ss}\left(e^{j2\pi f}\right)$ est paire

- MA(P) $\equiv P$ minimas spectraux sur $S_{ss}\left(e^{j2\pi f}\right)$ pour $f \in \left[-\frac{1}{2}, +\frac{1}{2}\right]$

Le modèle ARMA(P,Q)

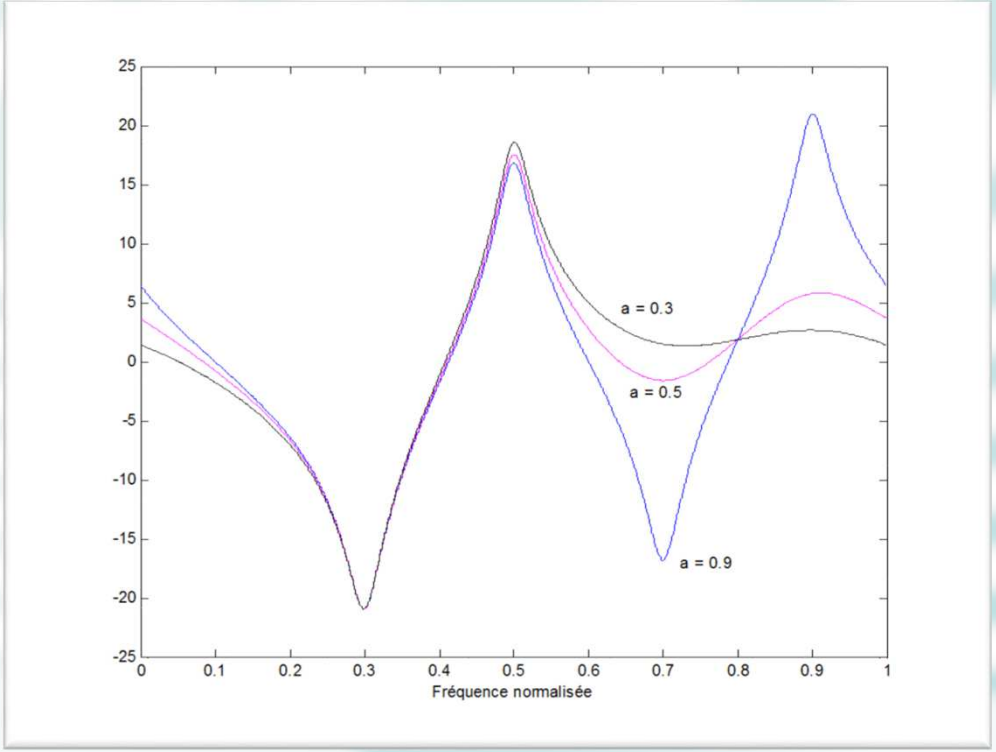
- La modélisation ARMA(P,Q) correspond au cas où le filtre $H(z)$ possède à la fois que Q zéros et P pôles, la réponse impulsionnelle associée est infinie (RII)
- Structure :



Modèle ARMA(P,Q)

- Exemple de DSP d'un processus ARMA(2,2)
  - Entrée = bruit blanc de puissance unitaire
  - 2 zéros et 2 pôles

$$\sigma_w^2 = 1$$
$$z_1 = 0.9\, e^{j2\pi\, 0.3}\,, z_2 = \mathrm{a}\, e^{j2\pi\, 0.7}$$
$$p_1 = 0.9\, e^{j2\pi\, 0.5}, p_2 = \mathrm{a}\, e^{j2\pi\, 0.9}$$



Comment obtenir les paramètres $\{a_k, b_k\}$?

- Etudions la relation entre les $(a[k])_{k=0}^{P}$ et $(b[k])_{k=0}^{Q}$ et les $\{R_{ss}[k], k = 0,1, \dots\}$
- Considérons un modèle général de type ARMA(P,Q)

$$S_{ss}(z) = H(z)H^*\left(\frac{1}{z^*}\right)S_{ww}(z) \Rightarrow S_{ss}(z) = H(z)H^*\left(\frac{1}{z^*}\right)\sigma_w^2$$

$$\Rightarrow S_{ss}(z) = \frac{B(z)}{A(z)}H^*\left(\frac{1}{z^*}\right)\sigma_w^2$$

$$\Rightarrow a[k] * R_{ss}[k] = \sigma_w^2 \;\; b[k] \; * h^*[-k]$$

$$\Rightarrow \sum_{m=0}^{P} a[m]\, R_{ss}[k-m] = \sigma_w^2 \;\; \sum_{i=0}^{Q} b[i]\, h^*[-(k-i)]$$

- Or le modèle est supposé causal

$$h[k] = 0 \quad \text{pour} \quad k = -1, -2, \dots \Rightarrow h[i-k] = 0 \quad \text{pour} \quad 0 \leq i \leq k-1$$

Comment obtenir les paramètres $\{a_k, b_k\}$?

- D'où la relation entre les $(a[k])_{k=0}^{P}$ et $(b[k])_{k=0}^{Q}$ et les $\{R_{ss}[k], k = 0,1, \dots\}$

$$\Rightarrow \sum_{m=0}^{P} a[m]\, R_{ss}[k-m] = \begin{cases} 0 & si \;\; 0 \le Q \le k-1 \\ \sigma_w^2 \sum_{i=0}^{Q} b[i]\, h^*[-(k-i)] & si \;\; 0 \le k-1 < Q \end{cases}$$

- Soit

$$\Rightarrow \sum_{m=0}^{P} a[m]\, R_{ss}[k-m] = \begin{cases} 0 & si \;\; k \ge Q+1 \\ \sigma_w^2 \sum_{i=0}^{Q} b[i]\, h^*[-(k-i)] & si \;\; 0 \le \; k < Q+1 \end{cases}$$

- Le problème posé : Comme la fonction d'autocorrélation $\{R_{ss}[k], k = 0,1, \dots\}$ peut être connue par estimation, « **comment calculer les $(a[k])_{k=0}^{P}$ et $(b[k])_{k=0}^{Q}$ lorsque l'on connaît $\{\widehat{R}_{ss}[k], k = 0, 1, \dots\}$** » ?

Comment obtenir les paramètres $\{a_k, b_k\}$?

- Ce problème étant difficile, on cherche une solution **sous-optimale** :
  - **Solution A**: Déterminer (Phase n°1) les $(b[k])_{k=0}^{Q}$ en supposant que $A(z) = 1$, puis (Phase n°2) déterminer les $(a[k])_{k=0}^{P}$ en connaissant les $(b[k])_{k=0}^{Q}$
  - **Solution B**: Déterminer (Phase n°1) les $(a[k])_{k=0}^{P}$ en supposant que $B(z) = 1$, puis (Phase n°2) déterminer les $(b[k])_{k=0}^{Q}$ en connaissant les $(a[k])_{k=0}^{P}$
- On montre que la solution A conduit à un problème non-linéaire. Aussi, on cherche ci-après à **déterminer la solution B**

Pour $B(z) = 1$ et Q=0, on a : $$\sum_{m=0}^{P} a[m]\, R_{ss}[k-m] = \begin{cases} 0 & si \;\; k \geq 1 \\ \sigma_w^2 h^*[-k] & si \;\; 0 \leq k < 1 \end{cases}$$

soit encore : $$\sum_{m=0}^{P} a[m]\, R_{ss}[k-m] = \begin{cases} 0 & si \;\; k \geq 1 \\ \sigma_w^2 h^*[0] & si \;\; k = 0 \end{cases}$$

Comment obtenir les paramètres $\{a_k, b_k\}$?

- Pour déterminer $h[0]$, on note que

$$H(z) = \frac{1}{A(z)} \quad \Rightarrow h[0] + h[1]z^{-1} + h[2]z^{-2} + \cdots = \frac{1}{a[0]} + \cdots$$

- Donc $h[0] = 1$ car $a[0]$=1. Pour résoudre le système linéaire précédent , il suffit d'exprimer P équations

$$\left.\begin{array}{l} R_{ss}[1] + a[1]R_{ss}[0] + \cdots + a[P]R_{ss}[1-P] = 0 \\ R_{ss}[2] + a[1]R_{ss}[1] + \cdots + a[P]R_{ss}[2-P] = 0 \\ \vdots \\ R_{ss}[P] + a[1]R_{ss}[P-1] + \cdots + a[P]R_{ss}[0] = 0 \end{array}\right\}$$

Equations de Yule-Walker

$$\Rightarrow \begin{pmatrix} R_{ss}[0] & \cdots & R_{ss}[1-P] \\ \vdots & \ddots & \vdots \\ R_{ss}[P-1] & \cdots & R_{ss}[0] \end{pmatrix} \begin{pmatrix} a[1] \\ \vdots \\ a[P] \end{pmatrix} = \begin{pmatrix} -R_{ss}[1] \\ \vdots \\ -R_{ss}[P] \end{pmatrix}$$



Equations de Yule-Walker

- Par construction, la matrice d'autocorrélation est semi-définie positive (cf. T.51-52 mais dans la majorité des applications on considère qu'elle est non-singulière). Alors **les coefficients du modèle AR(P)** sont donnés par :

$$\underline{\boldsymbol{a}} = \boldsymbol{R}_{ss}^{-1}\,\underline{\boldsymbol{r}}_{ss}$$

- Différentes **implémentations** existent pour effectuer cette inversion matricielle
  - La matrice $\boldsymbol{R}_{ss}$ est hermitienne (auto-adjointe) c'est-à-dire que $\boldsymbol{R}_{ss}^{H} = \boldsymbol{R}_{ss}$
  - La matrice $\boldsymbol{R}_{ss}$ est une matrice de Toeplitz (ses diagonales sont constantes). On utilise alors **l'algorithme de Levinson** qui permet d'inverser le système en $o(P^2)$ opérations au lieu d'utiliser la méthode de Gauss-Jordan en $o(P^3)$. Cette méthode a ensuite été améliorée par **Durbin**. Mais elle reste sensible à une représentation en **virgule fixe**.
  - Une autre solution vise à utiliser la **décomposition de Schur** $\boldsymbol{R}_{ss} = \boldsymbol{QUQ}^{-1}$valable pour les matrices carrées à valeurs complexes. Ceci conduit à un algorithme récursif sur l'ordre dont les coefficients ne sont pas directement calculés car l'algorithme utilise des coefficients modifiés (**les coefficients de réflexion**) qui possèdent la bonne propriété d'être compris entre +1 et -1)
  - les variables internes de l'algorithme de **SHUR** (ou **Le Roux-Gueguen**) sont mieux conditionnées ce qui permet une implémentation en virgule fixe sur DSP.

Equivalence entre modèles

- Equivalence **ARMA(P,Q)** ↔ **AR(∞)**
  - On cherche : $\frac{B(z)}{A(z)} = \frac{1}{C(z)} \Leftrightarrow A(z) = C(z)\,B(z)$
  - Soit $a[k] = c[k] * b[k] = \sum_{m=0}^{Q} b[m]c[k-m]$

$$\Leftrightarrow c[k] = a[k] - \sum_{m=1}^{Q} b[m]c[k-m]$$

- Equivalence **ARMA(P,Q)** ↔ **MA(∞)**

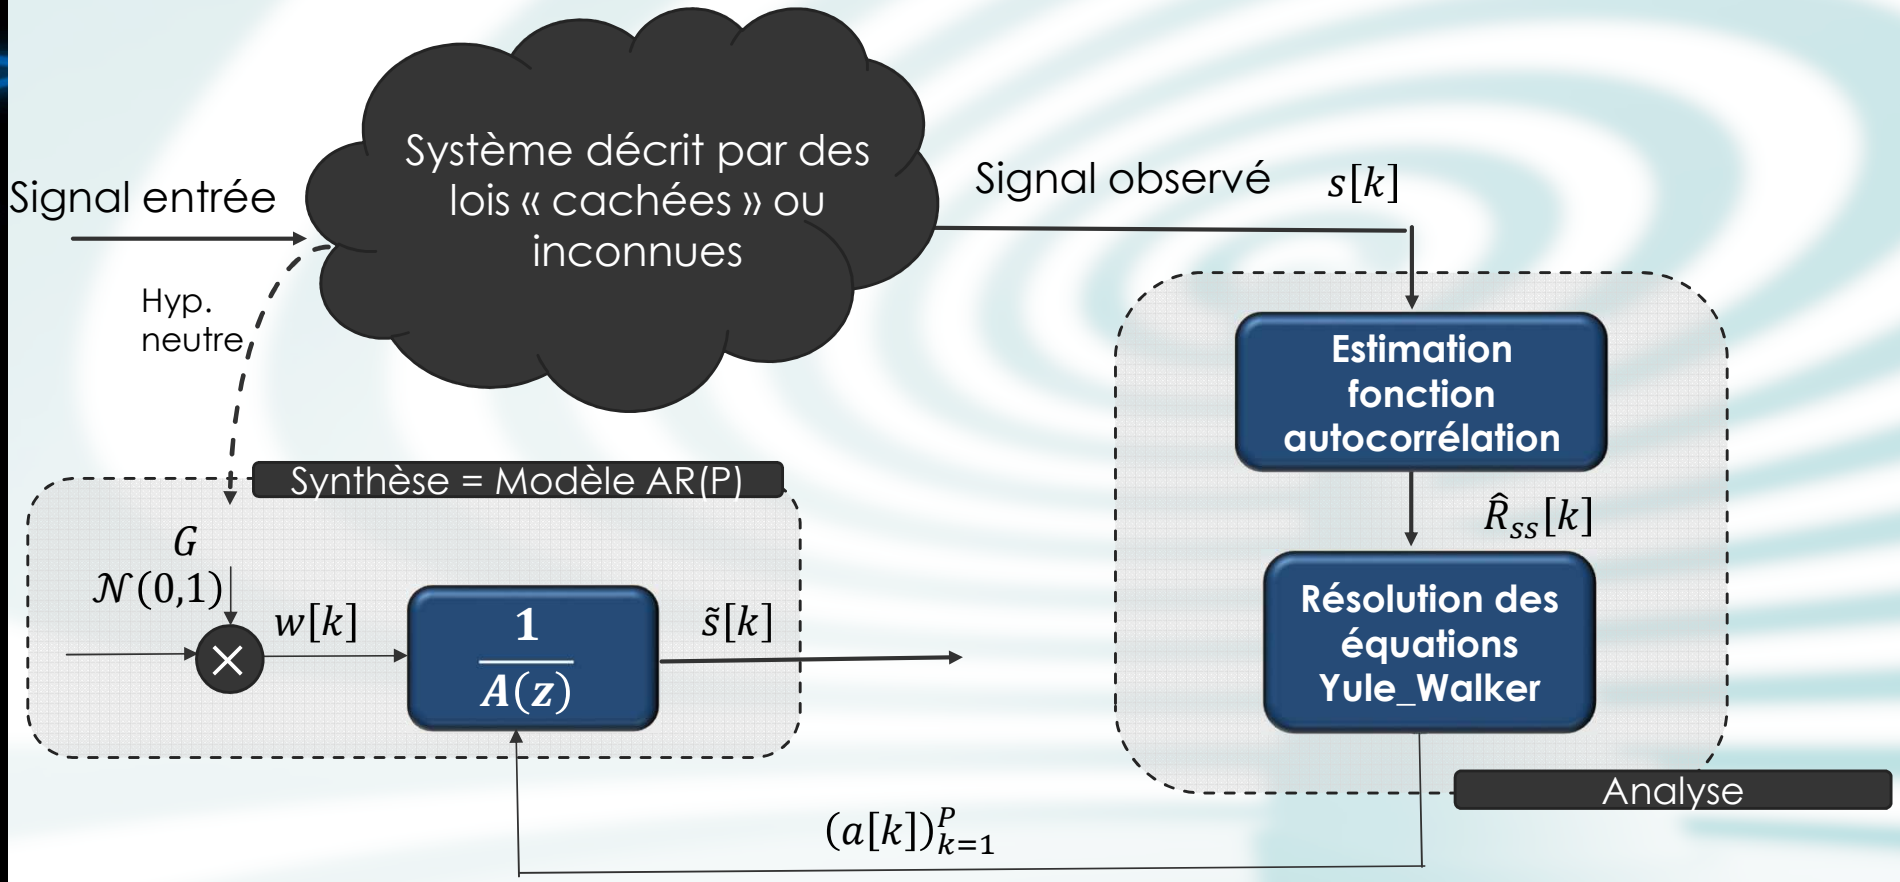
$$\frac{B(z)}{A(z)} = C(z) \qquad \Leftrightarrow c[k] = b[k] - \sum_{m=1}^{P} a[m]c[k-m]$$



Conclusions du chapitre

- **La majorité des méthodes d'estimation des paramètres de modèles AR, MA ou ARMA sont basées la résolution des équations de Yule-Walker**
- Si on souhaite un modèle AR, alors on calcule les coefficients **d'un modèle auto-régressif** AR(P) à l'aide d'algorithmes performants (d'un point de vue complexité) et stables tels que **Levinson-Durbin** ou bien **Schur** (**Le Roux-Gueguen**)
- Si on souhaite travailler avec un modèle de type **ARMA(P,Q)** alors on procède en 2 étapes :
  - On cherche tout d'abord les coefficients $(c[k])_{k=0}^{+\infty}$ d'un modèle auto-régressif d'ordre élevé **AR**(∞) qui correspond aux données
  - On cherche ensuite durant la Phase n°1 (i.e. en supposant que $B(z) = 1$) les coefficients $(a[k])_{k=0}^{P}$ d'un modèle auto-régressif d'ordre limité **AR**$(\boldsymbol{P})$ qui correspond aux données
  - La phase n°2 qui consiste à calculer les coefficients $(b[k])_{k=0}^{Q}$ sont alors évalués à partir de la relation d'équivalence entre modèles **ARMA(P,Q)** $\leftrightarrow$ **AR**(∞)
- Cette méthodologie permet de trouver les paramètres $(a[k])_{k=0}^{P}$ et $(b[k])_{k=0}^{Q}$ de tout modèle de type **ARMA(P,Q)**

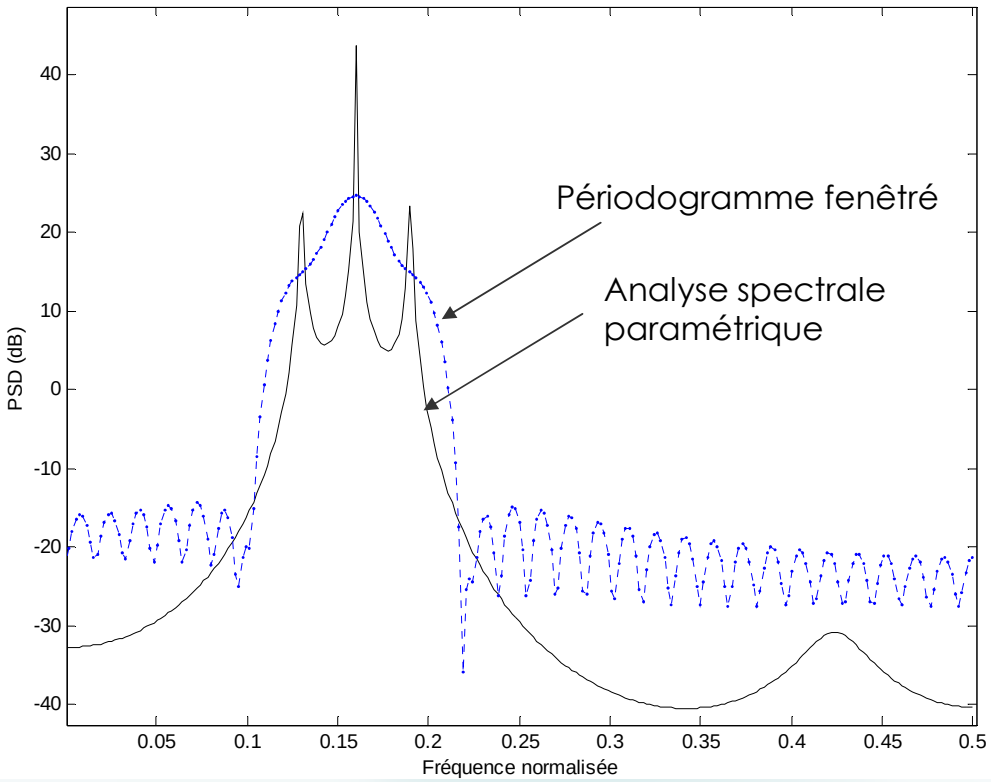
Le problème général



Analyse Spectrale Paramétrique

- Soit un signal d'observation réel s(n) composé de 64 échantillons générés par la somme de 3 sinusoïdes
  - Phases à l'origine aléatoires
  - Fréquences normalisées 0.13, 0.16 et 0.19
  - Puissance –10, 0 et 10 dB (respectivement)
- Comparaison de l'estimation spectrale par **périodogramme fénêtré** (FFT 512 points et fenêtrage de Hamming (donc **zero-padding**) et par **analyse spectrale paramétrique** de type AR (P=8) avec la méthode covariance

$$s[n] = \sum_{p=1}^{3} A_p sin(2\pi f_p n + \theta_p) \qquad n = 0,1,\dots 63$$



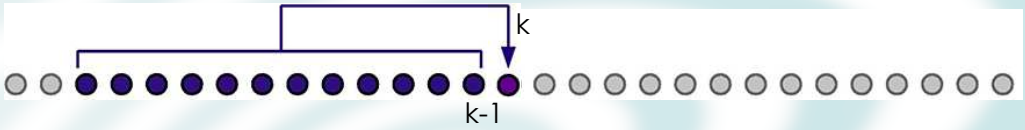


Prédiction… linéaire

Différents types de prédicteurs linéaires

- Prédiction linéaire **directe**, **à un pas** et **d'ordre P**

$$\hat{s}[k] = \sum_{m=1}^{P} a[m]s[k-m]$$



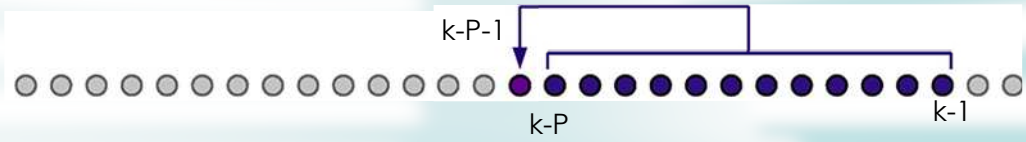
- Prédiction linéaire **directe**, **à L pas** et **d'ordre (P-1)**

$$\hat{s}[k+L-1] = \sum_{m=1}^{P} a[m]s[k-m]$$



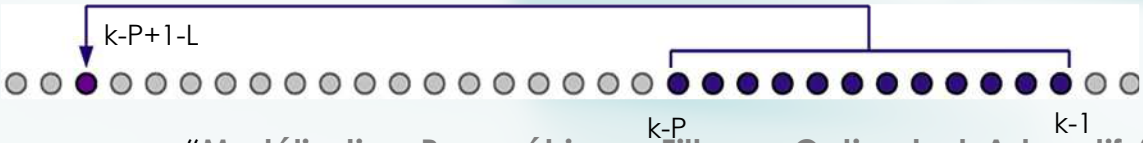
- Prédiction linéaire **rétrograde**, **à un pas** et **d'ordre P**

$$\hat{s}[k-P-1] = \sum_{m=1}^{P} a[m]s[k-m]$$



- Prédiction linéaire **rétrograde**, **à L pas** et **d'ordre P**

$$\hat{s}[k-P-L] = \sum_{m=1}^{P} a[m]s[k-m]$$



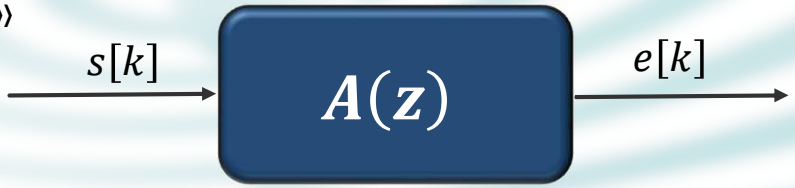
Etude du prédicteur linéaire direct à 1 pas

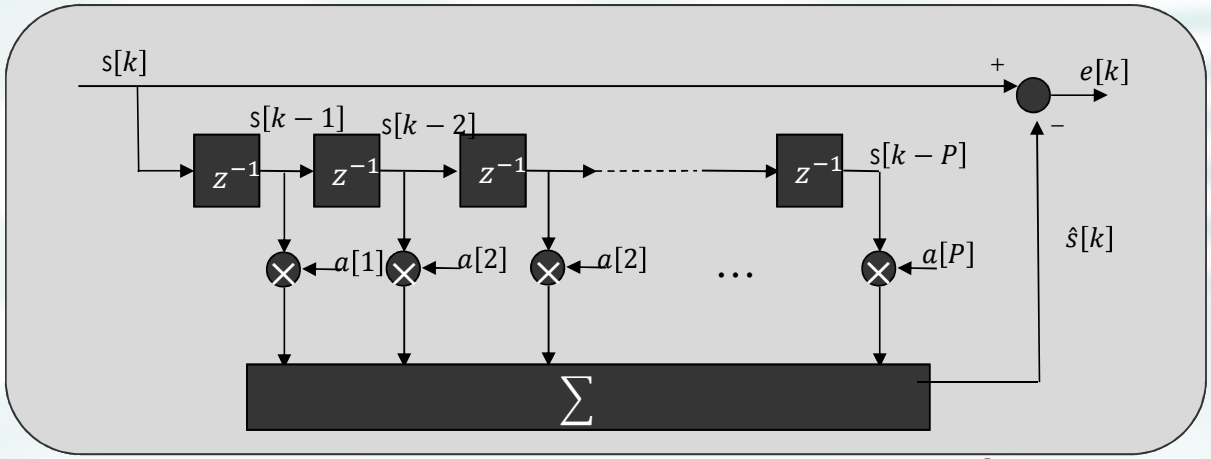
- Prédiction linéaire **directe**, **à un pas** et **d'ordre P.** On définit l'erreur de prédiction linéaire par :

$$e[k] = s[k] - \hat{s}[k] \qquad \text{avec} \quad \hat{s}[k] = \sum_{m=1}^{P} a[m]s[k-m]$$

- Le filtre ainsi constitué est de type « tous zéros »

$$A(z) = 1 - a[1]z^{-1} - \cdots - a[P-1]z^{-(P-1)}$$





Etude du prédicteur linéaire direct à 1 pas

- Il nous faut un critère afin de déterminer les coefficients de prédiction $(a[k])_{k=0}^{P}$
- Le critère retenu sera de minimiser la puissance de l'erreur de prédiction. Ce critère sera celui de **l'erreur quadratique moyenne minimale (EQMM)**

$$J(\underline{\boldsymbol{a}}) = \mathbb{E}\left((e[k])^2\right) = \mathbb{E}\left((s[k] - \hat{s}[k])^2\right)$$

où $\hat{s}[k] = \sum_{m=1}^{P} a[m]s[k-m] = \underline{\boldsymbol{a}}^T \underline{\boldsymbol{s}}[k-1]$

Avec les notations vectorielles suivantes :

$$\underline{\boldsymbol{a}} = \begin{pmatrix} a[1] \\ a[2] \\ \vdots \\ a[P] \end{pmatrix} \qquad \underline{\boldsymbol{s}}[k-1] = \begin{pmatrix} s[k-1] \\ s[k-2] \\ \vdots \\ s[k-P] \end{pmatrix}$$

Etude du prédicteur linéaire direct à 1 pas

- Pour déterminer les coefficients de prédiction $(a[k])_{k=0}^{P}$ qui minimisent **l'erreur quadratique moyenne (EQM)** seront obtenus lorsque les conditions suivantes au 1er (nullité du gradient) et au 2nd ordre (positivité de la matrice Hessienne) sont vérifiées :

$$\begin{cases} \nabla_{\boldsymbol{a}} \; J(\underline{\boldsymbol{a}}) = \underline{\mathbf{0}} \\ \nabla^2_{\boldsymbol{a},\boldsymbol{a}} \; J(\underline{\boldsymbol{a}}) > 0 \end{cases}$$

or $$J(\underline{\boldsymbol{a}}) = \mathbb{E}\left((e[k])^2\right) \Rightarrow \nabla_{\boldsymbol{a}} \; J(\underline{\boldsymbol{a}}) = 2\,\mathbb{E}\left(e[k] \times \nabla_{\boldsymbol{a}} \; e[k]\right) = -2\,\mathbb{E}\left(e[k]\underline{\boldsymbol{s}}[k-1]\right)$$

- La condition de nullité du gradient de l'erreur quadratique moyenne se traduit par le **principe général d'orthogonalité** suivant : « *A l'optimum, l'erreur de prédiction est orthogonale aux données présentes dans la mémoire du filtre* »

$$\mathbb{E}\left(e[k]\underline{\boldsymbol{s}}[k-1]\right) = 0 \Rightarrow \begin{pmatrix} \mathbb{E}(e[k]s[k-1]) \\ \mathbb{E}(e[k]s[k-2]) \\ \mathbb{E}(e[k]s[k-P]) \end{pmatrix} = \underline{\mathbf{0}} \quad \Rightarrow \quad \boxed{\mathbb{E}(e[k]s[k-i]) = 0 \quad i = 1, \ldots, P}$$

Principe d'orthogonalité : Conséquences

- Le principe d'orthogonalité décrit ci-avant peut encore s'exprimer selon :

$$\mathbb{E}(e[k]s[k-i]) = 0 \quad i = 1, \dots, P$$

$$\Rightarrow \mathbb{E}\left(\left(s[k] - \sum_{m=1}^{P} a[m]s[k-m]\right)s[k-i]\right) = 0 \qquad i = 1, \dots, P$$

$$\Rightarrow \mathrm{R}_{ss}[i] - \sum_{m=1}^{P} a[m]\mathrm{R}_{ss}[i-m] = 0 \qquad i = 1, \dots, P$$

- Ce qui nous conduit encore une fois **aux équations de Yule-Walker** parfois appelées ***équations normales***

$$\begin{pmatrix} \mathrm{R}_{ss}[1] \\ \vdots \\ \mathrm{R}_{ss}[P] \end{pmatrix} - \begin{pmatrix} \mathrm{R}_{ss}[0] & \cdots & \mathrm{R}_{ss}[1-P] \\ \vdots & \ddots & \vdots \\ \mathrm{R}_{ss}[P-1] & \cdots & \mathrm{R}_{ss}[0] \end{pmatrix} \begin{pmatrix} a[1] \\ \vdots \\ a[P] \end{pmatrix} = 0$$

- Les coefficients du **prédicteur optimal à 1 pas d'ordre P** sont les mêmes que ceux du **modèle autorgressif AR(P)**

Principe d'orthogonalité : Conséquences

- Si la matrice d'autocorrélation n'est pas singulière, nous obtenons la **solution optimale**

$$\Rightarrow \underline{a}^{opt} = \boldsymbol{R}_{ss}^{-1}\,\underline{\boldsymbol{r}}_{ss}$$

- L'analyse des conditions au second ordre donne

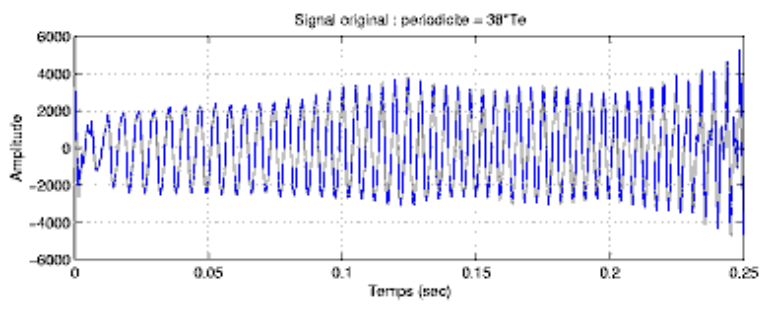
$$\nabla^2_{\boldsymbol{a},\boldsymbol{a}}\; J(\underline{\boldsymbol{a}}) = 2\;\boldsymbol{R}_{ss}$$

- Or nous verrons T.51-52 que la matrice d'autocovariance est, par construction, une matrice semi-définie positive mais elle peut être considérée comme définie positive dans la plupart des applications
  - La fonction de coût $J(\underline{\boldsymbol{a}})$ est donc strictement convexe
  - Les coefficients de prédiction correspondent donc à **une solution unique** du problème

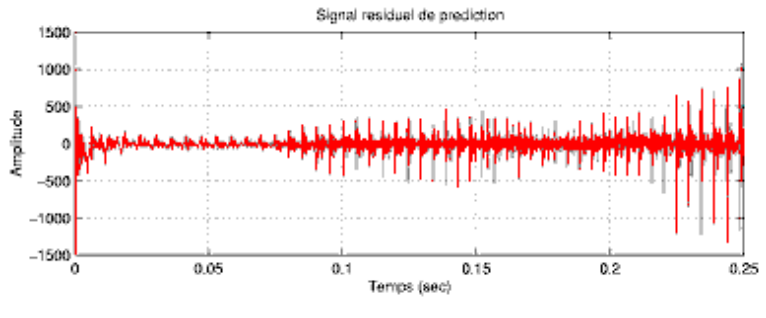
$$\underline{a}^{opt} = \underset{\underline{\boldsymbol{a}} \in \mathbb{R}^{\boldsymbol{P}}}{\operatorname{argmin}} J(\underline{\boldsymbol{a}}) \quad \text{et} \quad J_{min} = \min_{\underline{\boldsymbol{a}} \in \mathbb{R}^{\boldsymbol{P}}} J(\underline{\boldsymbol{a}})$$

Prédiction de la parole

- Signal original $x[k]$



- Erreur de prédiction linéaire e$[k]$



- Gain de prédiction en fonction de l'ordre P

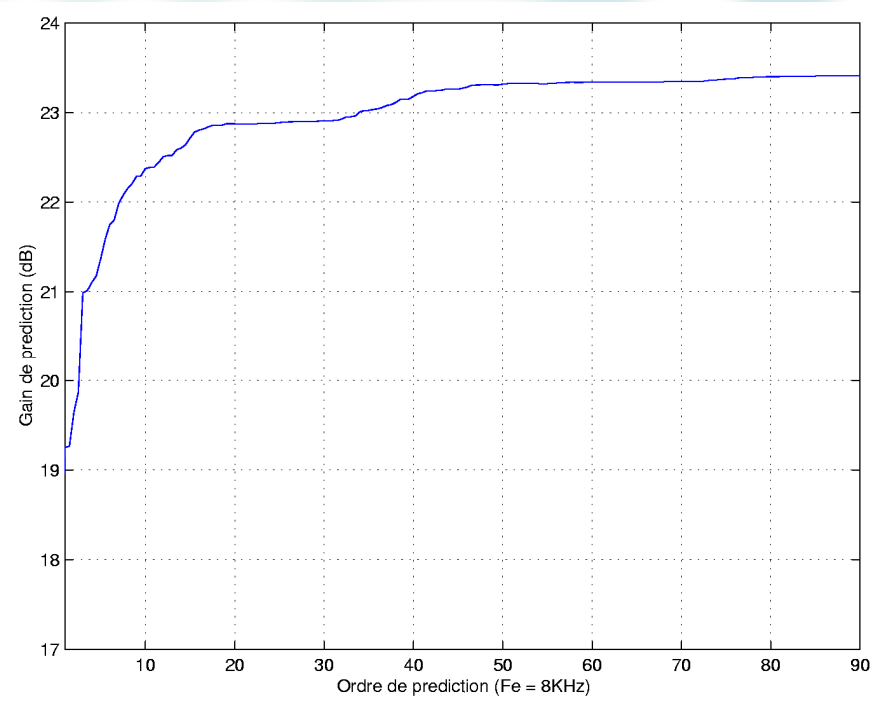
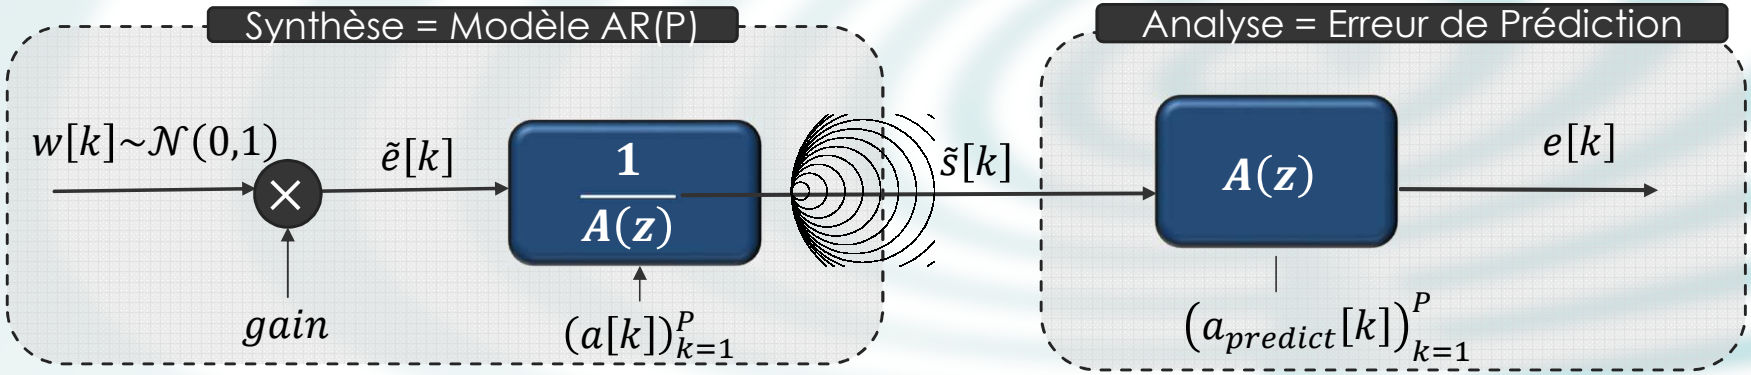


Schéma d'analyse/synthèse (1/2)

- Les opérations de « synthèse d'un modèle AR(P) » et d' « erreur de prédiction linéaire » sont **duales** : c'est le **schéma d'analyse/synthèse**

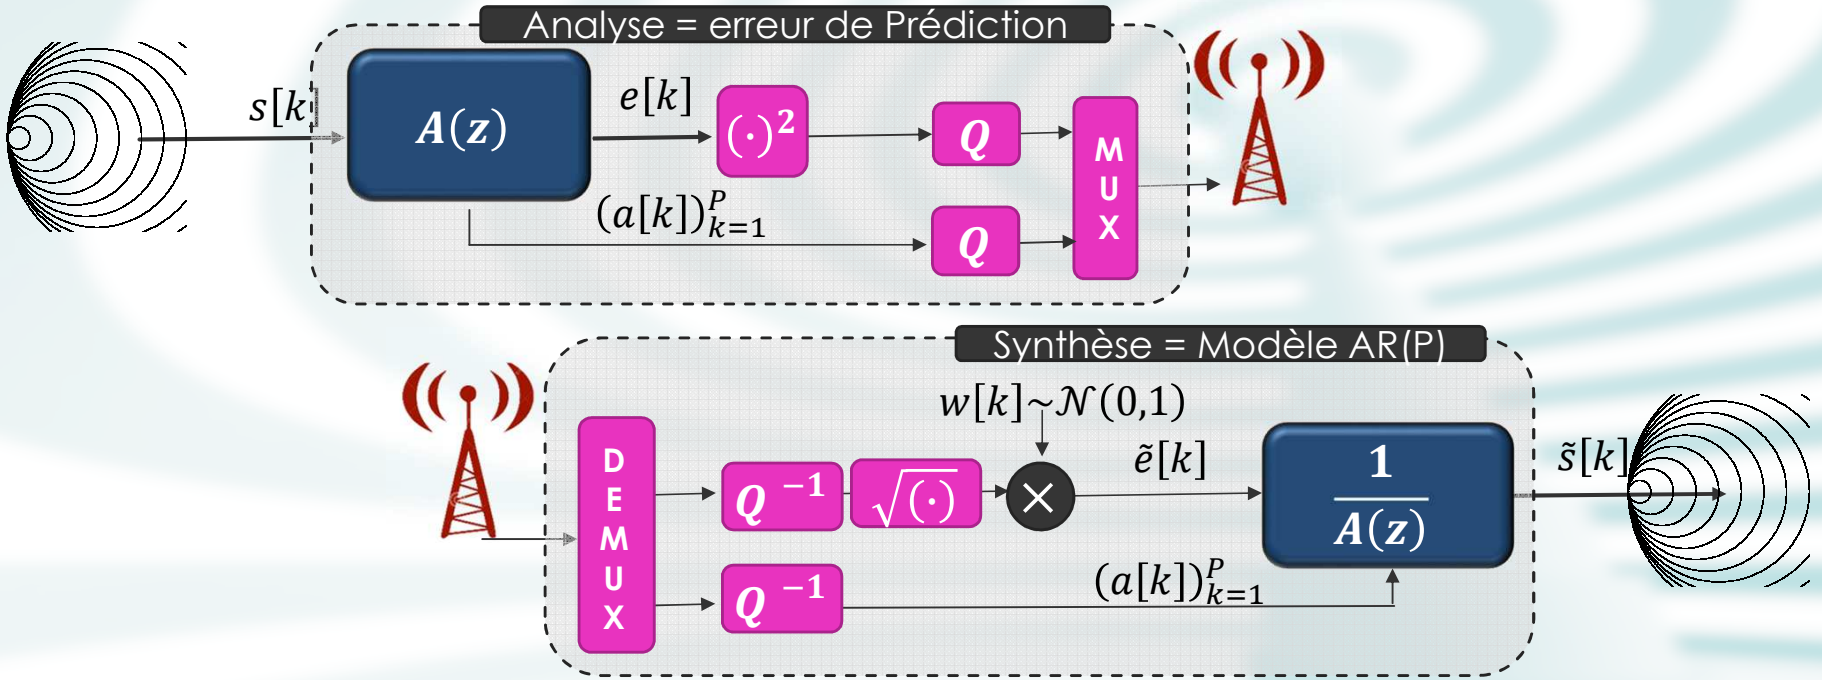



```
>> % paramètres du modèles AR
>> G=0.2;N=2^10;
>> A= [1,-0.75,0.5];
>> % génération du signal AR(2)
>> w=randn(N,1)
>> s=filter(1,A,G*w);
>> plot(s)
```

```
>> % analyse par prédiction d'ordre P
>> P=2
>> [Apredic,NoiseVariance]=aryule(s,P)
>> % refaire la démo avec N=2^20
>>
>> P=10
>> [Apredic,NoiseVariance]=aryule(s,P)
```

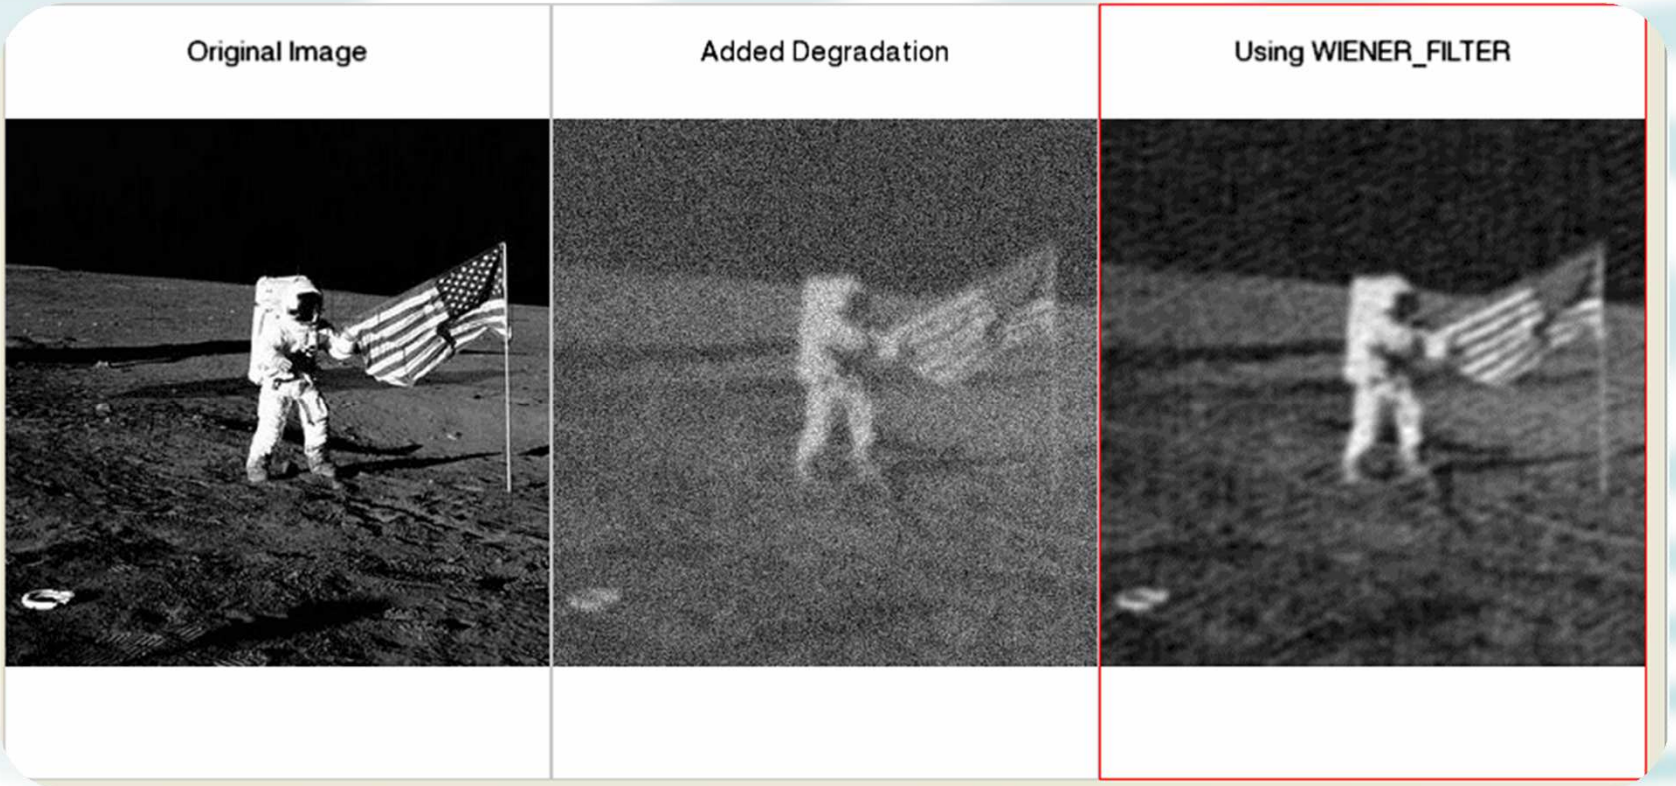
Schéma d'analyse/synthèse (2/2)

- Dans de nombreuses applications, on réalise souvent une opération d'analyse suivie d'une opération de synthèse : c'est le **schéma d'analyse/synthèse**
- Exemple : génération de **« bruit de confort »** pour les mobiles 2G, 3G, et 4G



- le filtre A(z) doit alors être à minimum de phase (pôles et zéros appartiennent à C_1) pour garantir la stabilité de la procédure d'analyse-synthèse





Généralisation
Filtrage optimal de Wiener

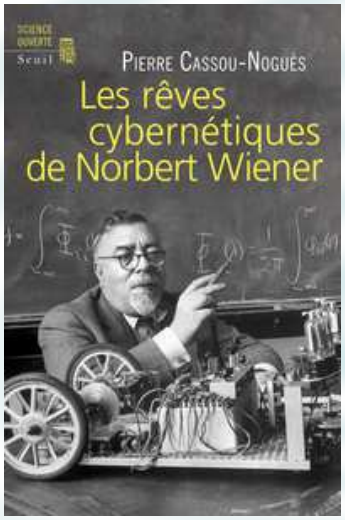
Norbert Wiener



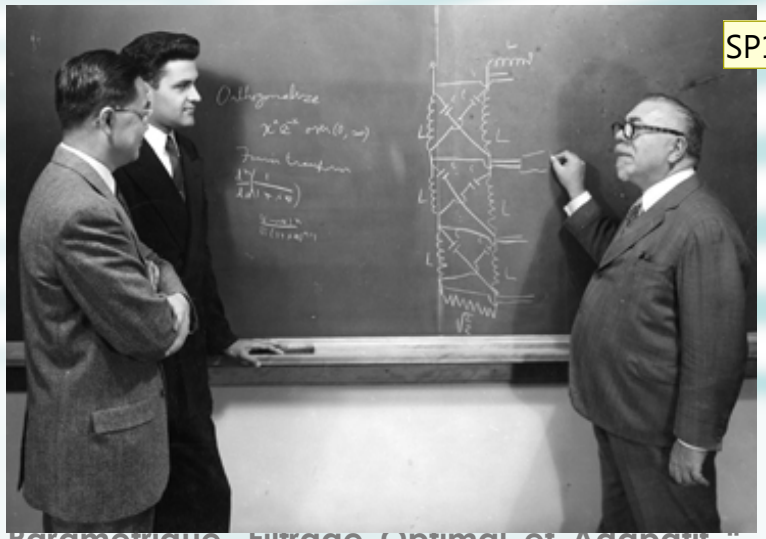
Norbert Wiener (1894-1964), USA – Harward – MIT

- mathématicien américain, à 18 ans le plus jeune docteur (Ph.D.) de Harward
- père fondateur de la cybernétique en introduisant, en sciences, la notion de « *feedback* », base de l'automatique et de la robotique et de l'intelligence artificielle
- pionnier dans l'étude stochastique et du bruit
- Il refusa de participer au projet de bombe nucléaire, tout en travaillant activement au programme de lutte antiaérienne à travers l'élaboration d'un calculateur permettant un système efficace de DCA
- Il est aussi bien étudié en mathématiques qu'en philosophie, sociologie, sciences cognitives ou économie. Il a notamment étudié la formation des bulles spéculatives

Un livre : « Les rêves cybernétiques de Norbert Wiener » , par Pierre Cassou-Noguès, ISBN : 2021090280, Éditeur : Editions du Seuil (2014)







Wiener with two of his proteges: Yuk Wing Lee, left, who did much to make the difficult mathematics of Wiener's pioneering work accessible to a broader audience, and Amar Bose (one of his doctoral student), who went on to a long tenure as an MIT professor — and, incidentally, founded the Bose Corporation.

Diapositive 44

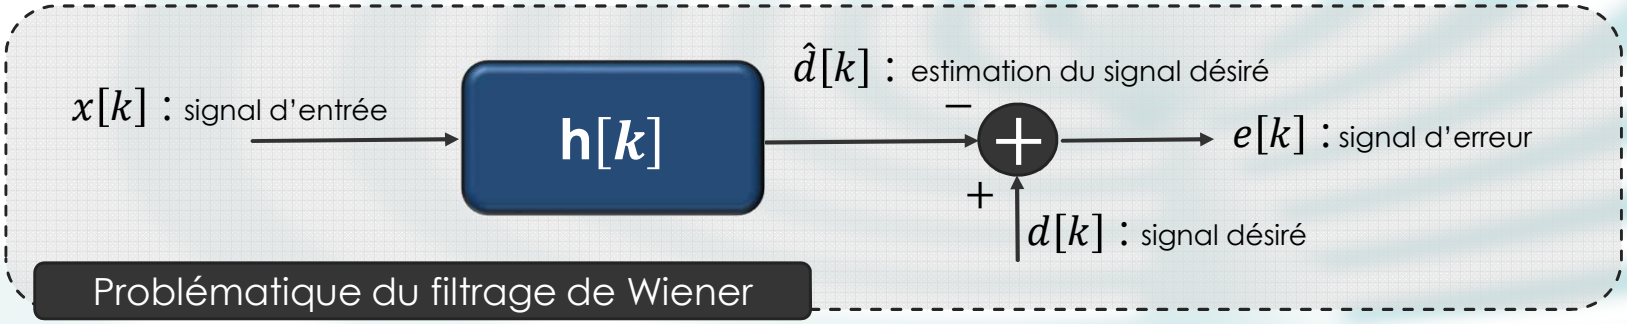
SP1 SCALART Pascal; 27/06/2016

La problématique de Wiener

"*This theory arises when there are two related signals and it is desired to estimate the one signal from the other in real time*", that is, without delay.

Phrase introductive au cours "Wiener Hopf Theory" du prof. Lloyd Richard Welch à California State University

- La figure suivante illustre la problématique générale



Dans ce cours,, on restreint l'analyse de Wiener au cas de signaux à temps discret, et on recherche des solutions causales

- Le signal d'entrée $x[k]$ est lié (statistiquement) à un autre signal, i.e. le signal désiré $\mathrm{d}[k]$, et on cherche le filtre qui permet d'estimer « au mieux » ce signal désiré à partir de la seule connaissance du signal d'entrée
- Le « au mieux » est traduit par « au sens du minimum d'erreur quadratique moyenne (EQMM) » ou an anglais MMSE (Minimum Mean Square Error)

La problématique de Wiener

- Les hypothèses de travail
  - Le signal d'entrée est un signal **aléatoire**, causal, à temps discret et stationnaire au 2nd ordre
  - Le filtre de réponse impulsionnelle finie (RIF) à L coefficients $(h[k])_{k=0}^{L-1}$ est **stable**, **linéaire**, **invariant dans le temps**
- Le problème mathématique à résoudre : minimiser la puissance de l'erreur d'estimation

$$J(\underline{\boldsymbol{h}}) = \mathbb{E}\left((e[k])^2\right) = \mathbb{E}\left(\left(d[k] - \hat{d}[k]\right)^2\right)$$

où $$\hat{d}[k] = \sum_{m=0}^{L-1} h[m]\, x[k-m] = \underline{\boldsymbol{h}}^T \underline{x}[k]$$

Avec les notations vectorielles suivantes : $\underline{\boldsymbol{h}} = \begin{pmatrix} h[0] \\ h[1] \\ \vdots \\ h[L-1] \end{pmatrix}$ $\underline{\boldsymbol{x}}[k] = \begin{pmatrix} x[k] \\ x[k-1] \\ \vdots \\ x[k-L+1] \end{pmatrix}$

Résolution du problème

- En effectuant le même raisonnement que celui qui a été mené au cours du chapitre précédent, les conditions d'optimalité sont données par :

$$\begin{cases} \nabla_{\boldsymbol{h}}\ J(\underline{\boldsymbol{h}}) = \underline{\mathbf{0}} \\ \nabla^2_{h,\boldsymbol{h}}\ J(\underline{\boldsymbol{h}}) > 0 \end{cases}$$

$$\text{or} \quad J(\underline{\boldsymbol{h}}) = \mathbb{E}\left((e[k])^2\right) \Rightarrow \nabla_{\boldsymbol{h}}\ J(\underline{\boldsymbol{h}}) = 2\,\mathbb{E}\left(e[k] \times \nabla_{\boldsymbol{h}}\ e[k]\right) = -2\,\mathbb{E}\left(e[k]\underline{\boldsymbol{x}}[k]\right)$$

- La condition de nullité du gradient de l'erreur quadratique moyenne se traduit par le **principe général d'orthogonalité** suivant : « *A l'optimum, l'erreur de prédiction est orthogonale aux données présentes dans la mémoire du filtre* »

$$\mathbb{E}\left(e[k]\underline{\boldsymbol{x}}[k]\right) = 0 \Rightarrow \begin{pmatrix} \mathbb{E}(e[k]x[k]) \\ \mathbb{E}(e[k]x[k-1]) \\ \mathbb{E}(e[k]x[k-P+1]) \end{pmatrix} = \underline{\mathbf{0}} \quad \Rightarrow \boxed{\mathbb{E}(e[k]x[k-i]) = 0 \quad i = 0, \dots, P-1}$$

Résolution du problème

- Les P équations précédentes conduisent au système suivant

$$\mathbb{E}(e[k]x[k-i]) = 0 \quad i = 0, \dots, P-1$$

$$\Rightarrow \mathbb{E}\left(\left(d[k] - \sum_{m=0}^{P-1} h[m]x[k-m]\right)x[k-i]\right) = 0 \qquad i = 0, \dots, P-1$$

$$\Rightarrow \mathrm{R}_{dx}[i] - \sum_{m=0}^{P-1} h[m]\mathrm{R}_{xx}[i-m] = 0 \qquad i = 0, \dots, P-1$$

- Nous obtenons donc le système

$$\begin{pmatrix} \mathrm{R}_{dx}[0] \\ \vdots \\ \mathrm{R}_{dx}[P-1] \end{pmatrix} - \begin{pmatrix} \mathrm{R}_{xx}[0] & \cdots & \mathrm{R}_{xx}[1-P] \\ \vdots & \ddots & \vdots \\ \mathrm{R}_{xx}[P-1] & \cdots & \mathrm{R}_{xx}[0] \end{pmatrix} \begin{pmatrix} h[0] \\ \vdots \\ h[P-1] \end{pmatrix} = 0 \quad \Leftrightarrow \quad \underline{\boldsymbol{r}}_{dx} = \boldsymbol{R}_{xx}\,\underline{\boldsymbol{h}}$$

- Si la matrice d'autocorrélation n'est pas singulière, nous obtenons la **solution optimale**

$$\underline{\boldsymbol{h}}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{dx}$$

Solution de Wiener

EQM Minimale

- Lorsque les coefficients $(h[m])_{m=0}^{P-1}$ correspondent aux coefficients optimaux $(h^{opt}[m])_{m=0}^{P-1}$ alors l'EQM est minimale (par définition) et on a :

$$
\begin{aligned}
J_{min} = J(\underline{\boldsymbol{h}}^{opt}) &= \mathbb{E}\left((d[k] - \underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{h}}^{opt})e[k]\right) \\
&= \mathbb{E}\left((d[k] - \underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{h}}^{opt})e[k]\right) \\
&= \mathbb{E}(d[k]e[k]) \\
&= \mathbb{E}\left(d[k]\left(d[k] - \underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{h}}^{opt}\right)\right) \\
&= \mathbb{E}(d^2[k]) - \mathbb{E}\left(d[k]\underline{\boldsymbol{x}}^T[k]\right)\underline{\boldsymbol{h}}^{opt} \\
&= \mathbb{E}(d^2[k]) - \underline{\boldsymbol{r}}_{dx}^T\ \boldsymbol{R}_{xx}^{-1}\ \underline{\boldsymbol{r}}_{dx}
\end{aligned}
$$

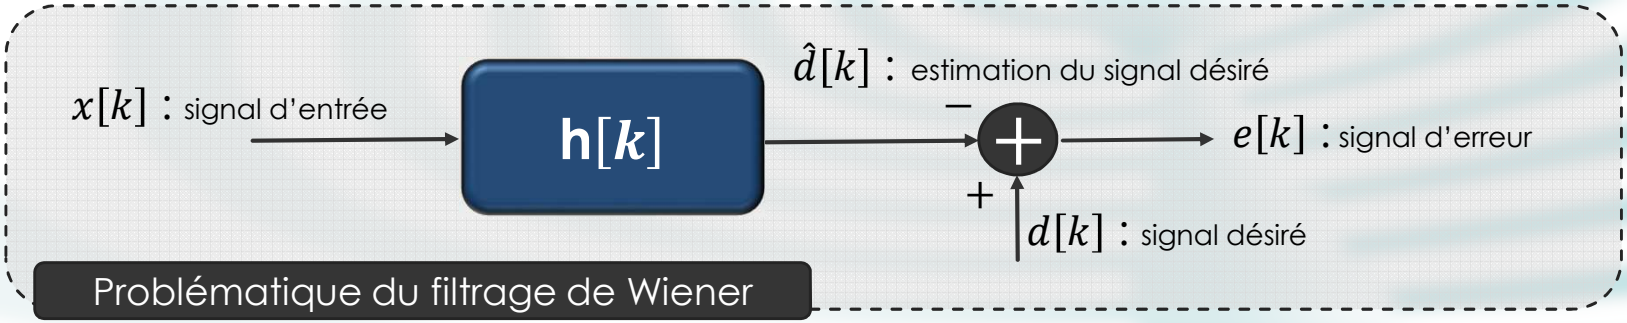
$$
\Rightarrow J_{min} = \mathbb{E}(d^2[k]) - \underline{\boldsymbol{r}}_{dx}^T\ \boldsymbol{R}_{xx}^{-1}\ \underline{\boldsymbol{r}}_{dx}
$$

Retour sur le problème de Wiener

"*This theory arises when there are two related signals and it is desired to estimate the one signal from the other in real time*", that is, without delay.

Phrase introductive au cours "Wiener Hopf Theory"du prof. Lloyd Richard Welch à California State University

- La figure suivante illustre la problématique générale





Le filtre de Wiener $\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{dx}$ est donc le filtre linéaire qui permet d'estimer « au mieux » d$[k]$à partir de $x[k]$

Inversibilité de la matrice d'auto-corrélation ?

- On démontre la propriété suivante : « *Soit* $\mathbf{R}_{xx} = (R_{xx}[i-j])_{i,j\in[\![0,P-1]\!]^2}$ *une matrice d'autocorrélation appartenant à* $\mathcal{M}_P(\mathbb{C})$.

  Alors la matrice $\mathbf{R}_{xx}$ *est semi définie positive.* »

- Démonstration : soit $\mathbf{R}_{xx}$ *la matrice d'autocorrélation appartenant à* $\mathcal{M}_P(\mathbb{C})$ relative au signal $x[n]$ et soit $\mathbf{C} = \begin{pmatrix} c_0 & \dots . c_{P-1} \end{pmatrix}^{\boldsymbol{T}}$ un vecteur quelconque de $\mathbb{C}^P$.

  On s'intéresse à la puissance du signal $y[n]$ obtenu à partir de la combinaison linéaire suivante : $y[k] = \sum_{j=0}^{P-1} c_j^* \, x[k-j] = \mathbf{C}^H \underline{\boldsymbol{x}}[k]$

  Alors on a :

$$\begin{aligned}\mathbb{E}(|y[k]|^2) = \mathbb{E}(y[k]\, y[k]^*) &= \mathbb{E}\left(\mathbf{C}^H \underline{\boldsymbol{x}}[k] \mathbf{C}^T \underline{\boldsymbol{x}}^*[k]\right) = \mathbb{E}\left(\mathbf{C}^H \underline{\boldsymbol{x}}[k] \underline{\boldsymbol{x}}^H[k] \mathbf{C}\right) \\ &= \mathbf{C}^H \mathbb{E}\left(\underline{\boldsymbol{x}}[k] \underline{\boldsymbol{x}}^H[k]\right) \mathbf{C} = \mathbf{C}^H \mathbb{E}\left(\underline{\boldsymbol{x}}[k] \underline{\boldsymbol{x}}^H[k]\right) \mathbf{C} \\ &= \mathbf{C}^H \mathbf{R}_{xx} \mathbf{C} \geq 0\end{aligned}$$

Conclusion : la *matrice* $\mathbf{R}_{xx}$ *est semi définie positive. Elle est définie positive ssi* $\mathbf{R}_{xx}$ est de rang plein

Inversibilité de la matrice d'auto-corrélation ?

- On démontre la propriété suivante : « *Soit* $\mathbf{A} = (a_{ij})$ *une matrice de* $\mathcal{M}_P(\mathbb{C})$ *qui vérifie la propriété suivante*

$$\forall i \in [\![0, P-1]\!], \sum_{j \neq i} |a_{ij}| < |a_{ii}|$$

alors la matrice $\mathbf{A}$ *est inversible*. »

- Par l'absurde, on suppose $\mathbf{A}$ non inversible, alors l'endomorphisme f de $\mathbb{C}^P$ de matrice $\mathbf{A}$ n'est pas bijectif et on sait, qu'en dimension finie, ceci est équivalent à f non injectif. Il existe donc dans $\mathbb{C}^P$ un vecteur $\mathbf{X} \neq 0$ tel que $\mathbf{AX} = \mathbf{0}$ car on rappelle que "f injective $\Leftrightarrow \operatorname{Ker} f = \{\mathbf{0}\}$".

  Soit $k \in [\![0, P-1]\!]$ tel que $|x_k| = \max|x_i|$, on a $\sum_{j \neq k} a_{kj} x_j = -a_{kk} x_k$. En prenant les modules

$$|a_{kk}|\,|x_k| \leq \left|\sum_{j \neq k} a_{kj}\, x_j\right| \leq \sum_{j \neq k} |a_{kj}|\,|x_j| \leq \sum_{j \neq k} |a_{kj}|\,|x_k|$$

En divisant chaque terme par $|x_k| \neq 0$, on a $|a_{kk}| \leq \sum_{j \neq k} |a_{kj}|$ ce qui est contraire aux hypothèses.

Conclusion : $\mathbf{A}$ est inversible

Résolution du problème

- Pour construire cette solution optimale, il suffit donc de connaître (ou estimer)
  - la **matrice d'autocorrélation** $\boldsymbol{R}_{xx}$ du signal d'entrée
  - le **vecteur d'intercorrélation** $\underline{\boldsymbol{r}}_{dx}$ entre le signal d'entre

- Si l'on revient sur les conditions au second ordre, on montre que la matrice hessienne est donnée par :

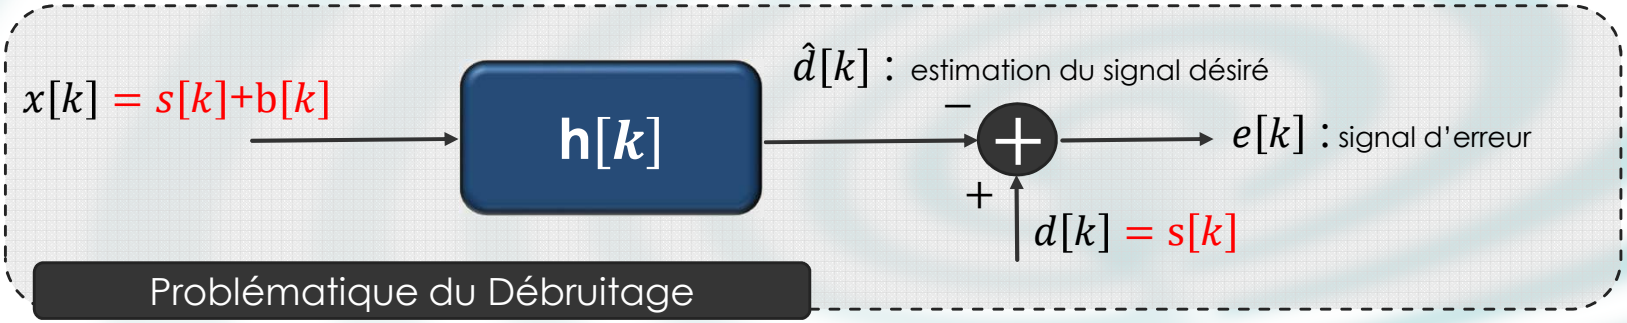
$$\nabla^2_{h,\boldsymbol{h}}\ J\left(\underline{\boldsymbol{h}}\right) = 2\ \boldsymbol{R}_{xx}$$

  dont la positivité (dans la majorité des applications) garantit que le caractère **unique** de la solution de Wiener.

- Les principales applications de cette technique de filtrage (cf. T5) sont :
  - Les problèmes de **débruitage**
  - Les problèmes de **déconvolution** (ou **égalisation**)
  - Les problèmes d'i**nterpolation**
  - Les problèmes de **prédiction**

Débruitage (1/4)

- Dans ce cas on précise les signaux d'entrée et désiré :



- on a alors :

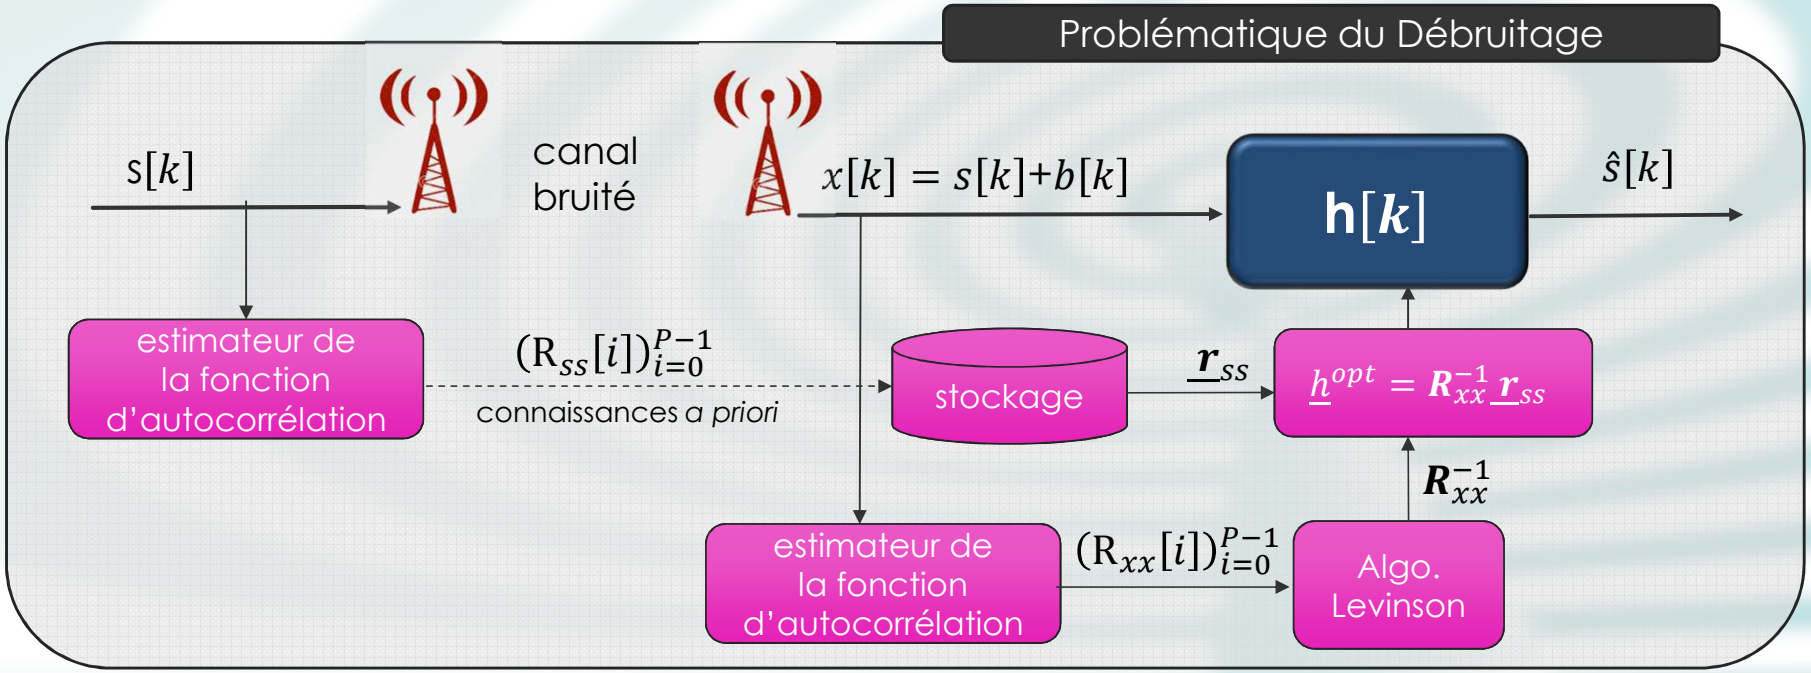
$$R_{dx}[i] = \mathbb{E}(d[k]x[k-i]) = \mathbb{E}\big(\mathrm{s}[k](s[k-i]+\mathrm{b}[k-i])\big) = R_{ss}[i]$$

- La solution de Wiener peut alors s'écrire selon:

$$\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{dx} \Rightarrow \boxed{\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{ss}} \quad \text{avec} \quad \underline{\boldsymbol{r}}_{ss} = \begin{pmatrix} \mathrm{R}_{ss}[0] \\ \vdots \\ \mathrm{R}_{ss}[P-1] \end{pmatrix}$$

Débruitage (2/4)

- En pratique, le filtre de Wiener est donc implémenté suivant :



- Analyse en fréquence

$$\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\underline{\boldsymbol{r}}_{ss} \xrightarrow{TFD} H^{opt}(e^{j2\pi f}) = \frac{S_{ss}(e^{j2\pi f})}{S_{xx}(e^{j2\pi f})} = \frac{S_{ss}(e^{j2\pi f})}{S_{ss}(e^{j2\pi f}) + S_{bb}(e^{j2\pi f})}$$

Débruitage (3/4)

- On peut alors définir le rapport signal à bruit sur chaque composante fréquentielle

$$RSBf\left(e^{j2\pi f}\right) = \frac{S_{ss}\left(e^{j2\pi f}\right)}{S_{bb}\left(e^{j2\pi f}\right)}$$

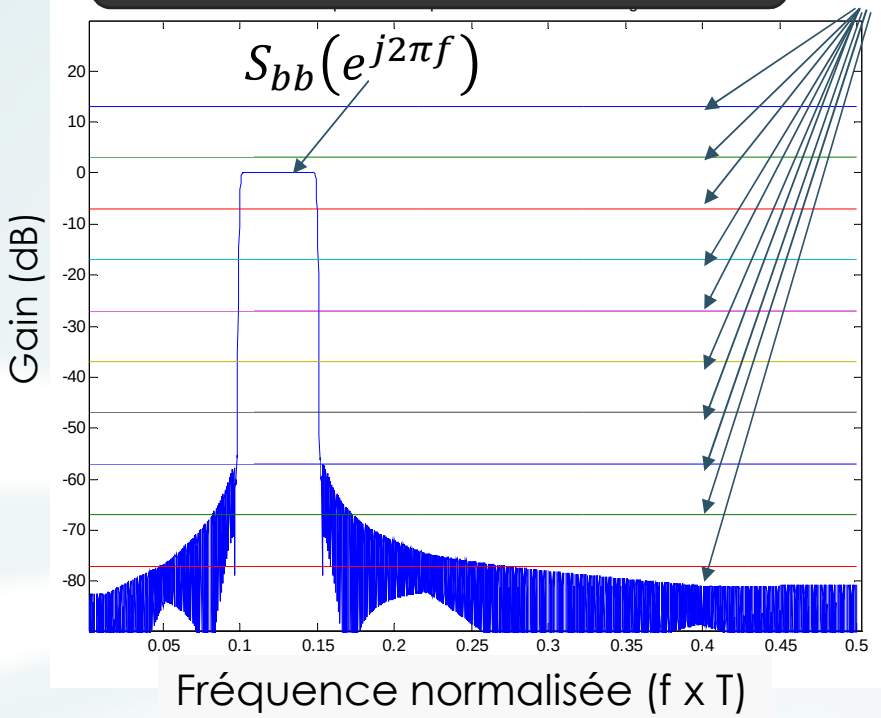
on alors $$H^{opt}\left(e^{j2\pi f}\right) = \frac{RSBf\left(e^{j2\pi f}\right)}{1 + RSBf\left(e^{j2\pi f}\right)}$$

- Le fonctionnement du filtre de réduction de bruit de Wiener est le suivant:
  - Lorsque $RSBf\left(e^{j2\pi f}\right) \longrightarrow 0$ alors $H^{opt}\left(e^{j2\pi f}\right) \longrightarrow 0$ et donc la composante spectrale est supprimée
  - Lorsque $RSBf\left(e^{j2\pi f}\right) \longrightarrow \infty$ alors $H^{opt}\left(e^{j2\pi f}\right) \longrightarrow 1$ et donc la composante spectrale est conservée

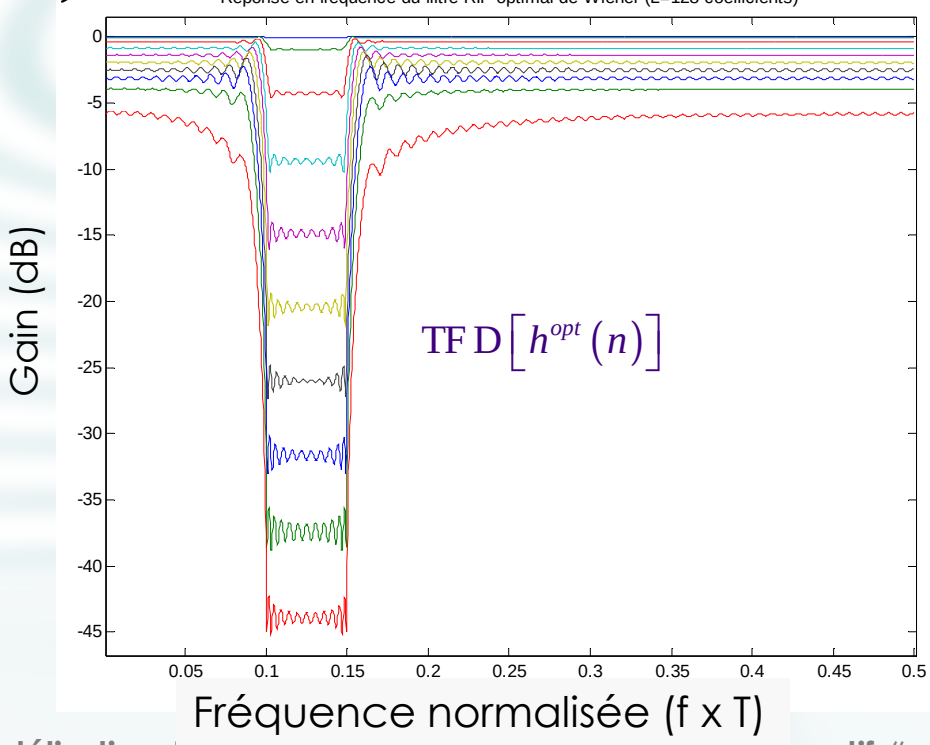
Débruitage (4/4)

- Cas d'un bruit à bande étroite et d'un signal utile à large bande : **le filtre de Wiener s'adapte « automatiquement »** aux signaux observés

Densité spectrale de puissance du bruit et du signal utile

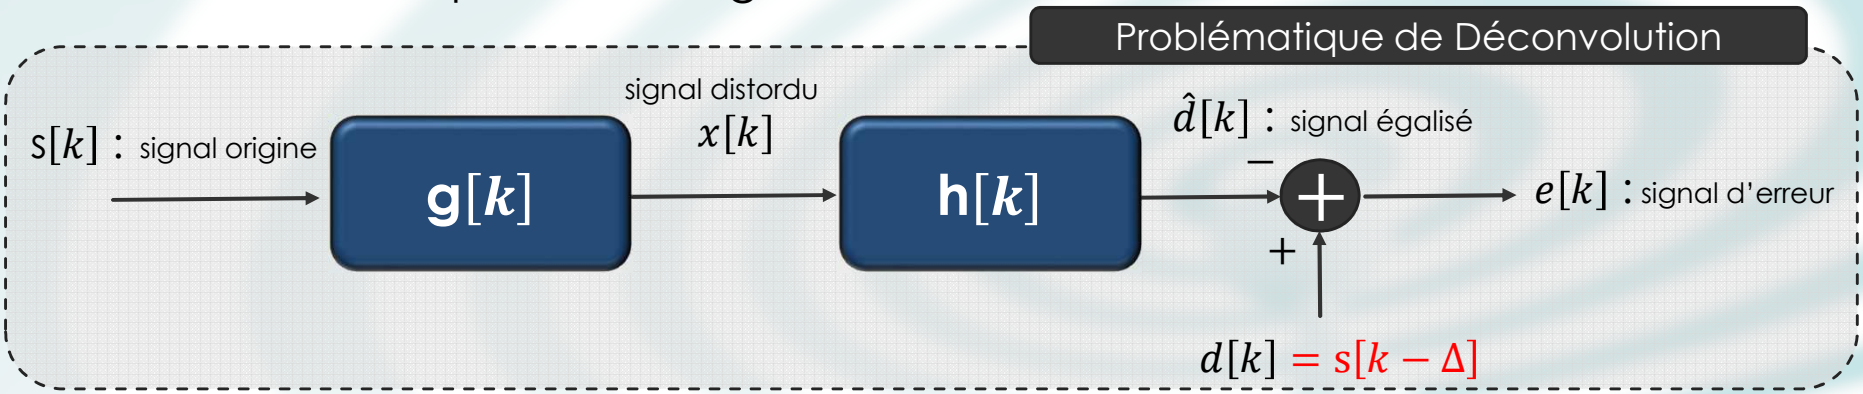


Réponse fréquentielle du filtre linéaire optimal de Wiener



Déconvolution (1/3)

- Dans ce cas on précise les signaux d'entrée et désiré :



- on a alors :

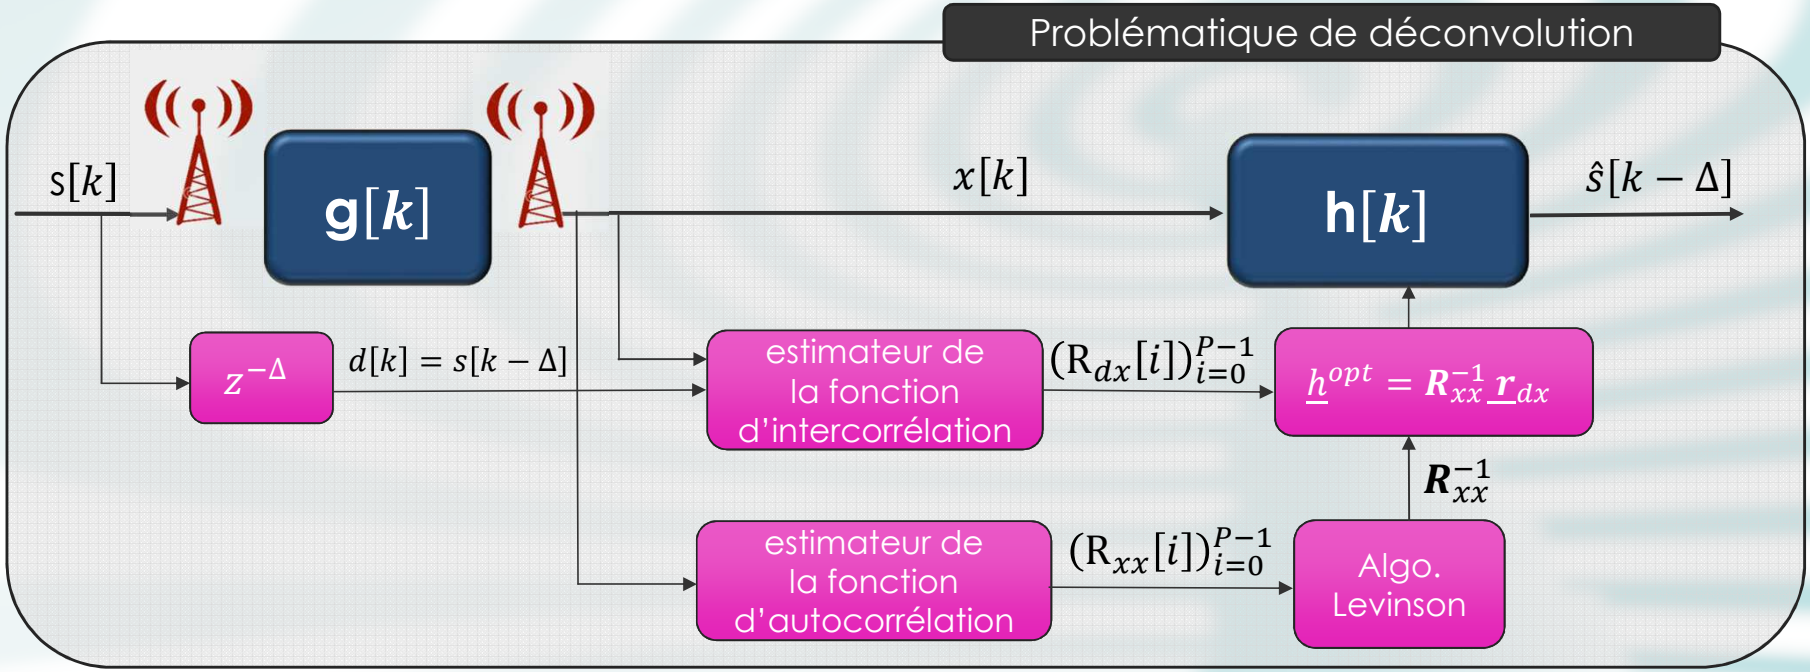
$$R_{dx}[i] = \mathbb{E}(d[k]x[k-i]) = \mathbb{E}\left(s[k-\Delta]\sum_{j=0}^{+\infty} g[j]s[k-i-j]\right) = \sum_{j=0}^{+\infty} g[j]R_{ss}[i+j-\Delta]$$

- La solution de Wiener peut alors s'écrire selon:

$$\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{dx}$$

Déconvolution (2/3)

- En pratique, le filtre de Wiener est donc implémenté suivant :



- Il n'est donc pas nécessaire de connaître la rep. Imp. g[k] pour être capable d'« inverser » le canal de transmission. On estime « off-line » le filtre égaliseur.

Déconvolution (3/3)

- Simulations

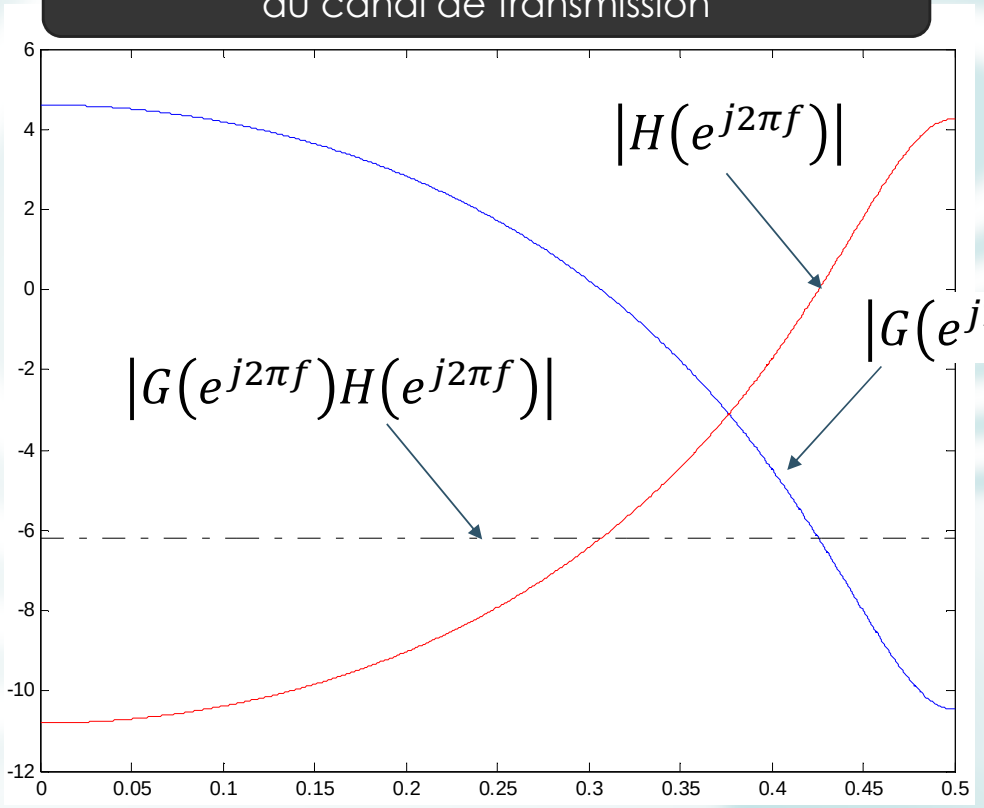
$$G[z] = 1 + \alpha z^{-1}$$

$$\alpha = 0.7$$

$$\Delta = 3$$

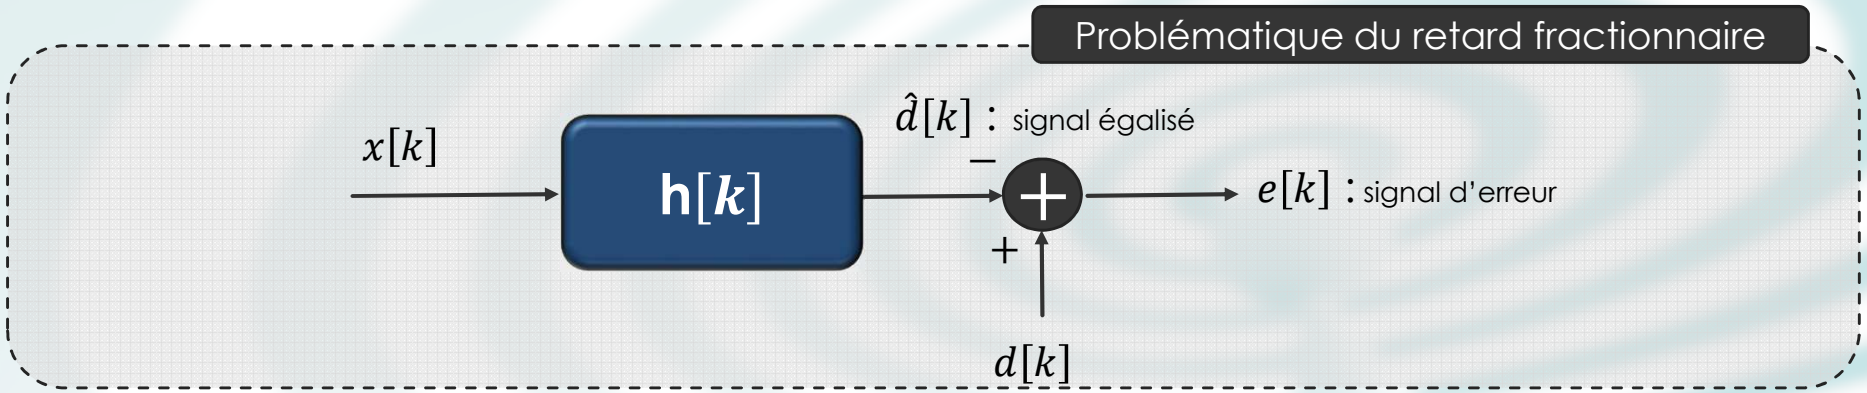
L=30

Réponses fréquentielles du filtre égaliseur et du canal de transmission



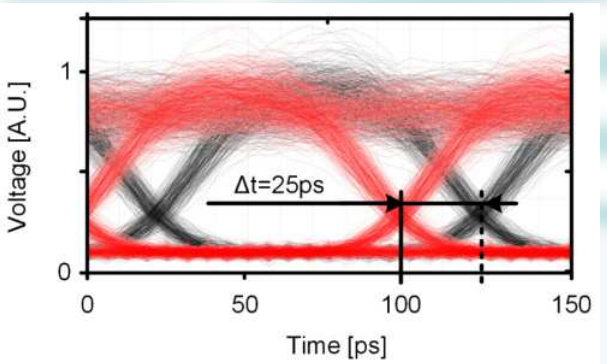
Filtre à retard fractionnaire

- Dans ce cas on a le schéma suivant :



- on considère les signaux : $x[k] = x(nT_e)$ et $d[k] = x(nT_e + \tau)$ avec $\tau \in]0, T_e[$
- La solution de Wiener peut alors s'écrire selon:

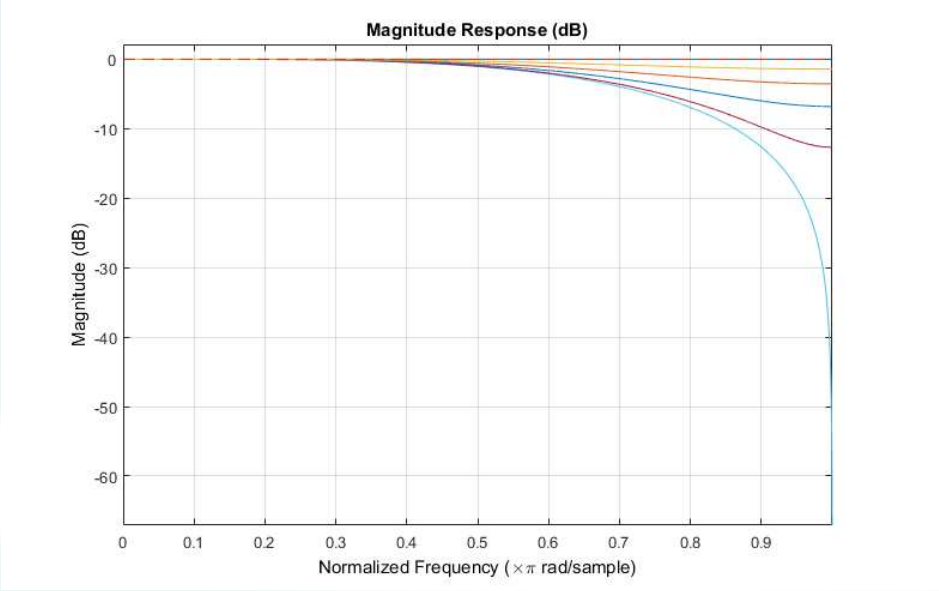
$$\underline{h}^{opt} = \boldsymbol{R}_{xx}^{-1}\, \underline{\boldsymbol{r}}_{dx}$$

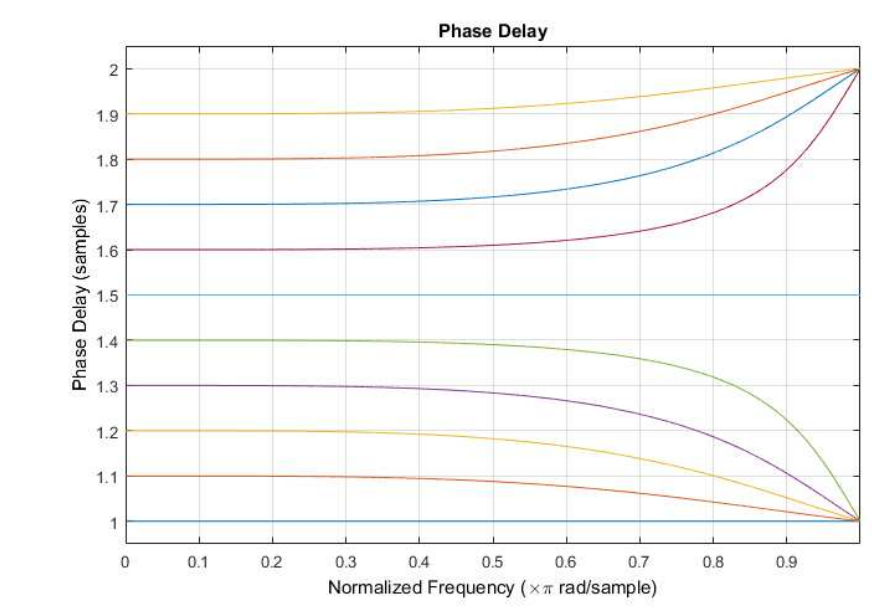


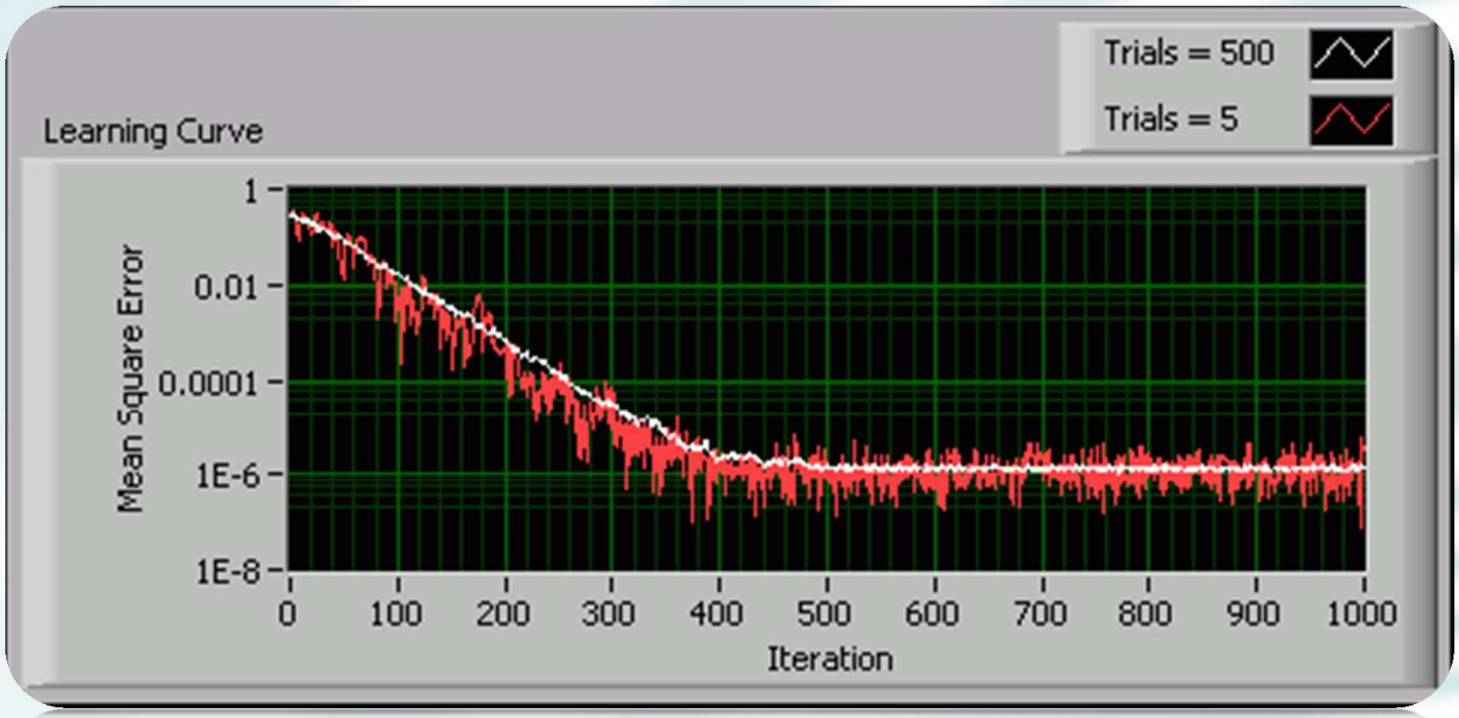
- De tels filtres sont très utilisés au sein des récepteurs numériques pour optimiser le choix de l'instant optimal d'échantillonnage

Filtre à retard fractionnaire

- FIR design, structure de Farrow, L=4







Filtrage adaptatif



Motivation pour le filtrage adaptatif

- Nous avons vu que le calcul du filtre optimal de Wiener était possible si
  - **des connaissances a priori** sont disponibles sur les caractéristiques statistiques des signaux traités, notamment la fonction d'auto- et/ou d'inter-corrélation entre signaux
  - ces caractéristiques sont **stationnaires** et donc n'évoluent pas au cours du temps
- Dans la pratique, ces conditions ne sont pas forcément remplies. Le traitement séquentiel du signal permet
  - d'estimer les paramètres statistiques du signal lorsqu'ils sont **inconnus** (par exemple les fonctions de corrélation)
  - de faire évoluer les paramètres du filtre lorsque les signaux (ou les systèmes) sont **non-stationnaires**, i.e. adapter le filtre à la statistique du signal → De tels filtres sont très utilisés au sein des récepteurs numériques pour s'adapter en permanence aux propriétés du signal reçu.



Motivation pour le filtrage adaptatif

- Deux grandes familles d'algorithmes sont couramment utilisés
  - Les **algorithmes du gradient** ou **algorithmes des moindres carrés moyennés** conduisant aux algorithmes de la classe des « Least Mean Squares » (LMS)
  - Les **algorithmes des moindres carrés récursifs (MCR)** ou **algorithmes des moindres carrés exacts**
- De nombreuses variantes existent :
  - Algorithmes fréquentiels ou temporels
  - Algorithmes dits « Rapides » ou non
  - Algorithmes avec pré-blanchiment, algorithmes de projection affine (APA),…

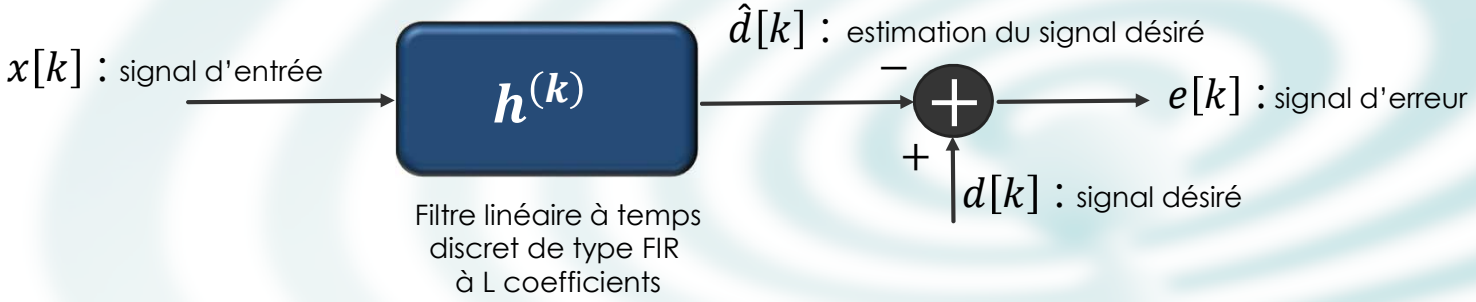


Filtrage adaptatif

1- Algorithme du gradient déterministe

Algorithme du Gradient déterministe

- Reprenons la problématique du filtrage de Wiener



- Mais maintenant la réponse impulsionnelle du filtre **varie à chaque instant** n. On note $\underline{\boldsymbol{h}}^{(k)}$ le vecteur des coefficients du filtre à l'instant kT_e

$$\underline{\boldsymbol{h}}^{(k)} = \begin{pmatrix} h^{(k)}[0] \\ h^{(k)}[1] \\ \vdots \\ h^{(k)}[L-1] \end{pmatrix}$$

D'où : $\hat{d}[k] = \sum_{m=0}^{L-1} h^{(k)}[m]\, x[k-m] = \underline{\boldsymbol{x}}[k]^T \underline{\boldsymbol{h}}^{(k)} = \underline{\boldsymbol{h}}^{(k)^T} \underline{\boldsymbol{x}}[k]$

$$\Rightarrow e[k] = d[k] - \underline{\boldsymbol{x}}[k]^T \underline{\boldsymbol{h}}^{(k)}$$

Résolution du problème

- La recherche itérative de la solution optimale est effectuée en utilisant un **algorithme du gradient** encore appelé **algorithme suivant la plus grande pente** (ou *steepest descent algoritm*).

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)} - \mu \nabla_{\boldsymbol{h}} \; J\left(\underline{\boldsymbol{h}}\right) \qquad \text{pour} \qquad k = 0,1,2, \ldots$$

où $J\left(\underline{\boldsymbol{h}}\right)$ est le critère à optimiser et $\mu > 0$ désigne le pas de l'algorithme. Nous recherchons une solution qui minimise l'EQM $J\left(\underline{\boldsymbol{h}}\right) = \mathbb{E}(e^2[k])$, ce qui conduit à :

Algorithme du Gradient déterministe

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)} +2\mu \; \mathbb{E}\left(e[k]\underline{\boldsymbol{x}}[k]\right) \qquad \text{pour} \qquad k = 0,1,2, \ldots$$

- Notes :
  - Les coefficients de l'algorithme sont initialisés à l'instant k=0 à une valeur quelconque $\underline{\boldsymbol{h}}^{(0)}$ (souvent une valeur nulle) et ensuite on itère à l'infini l'équation de mise à jour précédente
  - Si les coefficients s'approchent de l'optimum, alors on sait que ceux-ci ne vont plus beaucoup évoluer d'après le **principe général d'orthogonalité**

L'algorithme du gradient déterministe

- L'**algorithme du gradient déterministe** est alors défini par les opérations suivantes :

Algorithme du gradient déterministe

1) A l'itération k, réception d'un nouvel échantillon $x[k]$ et formation du vecteur d'entrée

$$\underline{\boldsymbol{x}}[\boldsymbol{k}] = (x[k] \;\; x[k-1] \ldots x[k-L+1])^T$$

2) Calcul du signal en sortie de filtre

$$\hat{d}[k] = \sum_{m=0}^{L-1} h^{(k)}[m]\, x[k-m]$$

3) Calcul de l'erreur (dite *a priori*) : $e[k] = d[k] - \hat{d}[k]$

4) Mise à jour des coefficients pour l'itération suivante : $\underline{\boldsymbol{h}}^{(\boldsymbol{k+1})} = \underline{\boldsymbol{h}}^{(\boldsymbol{k})} + 2\mu\, \mathbb{E}\left(e[k]\underline{\boldsymbol{x}}[k]\right)$

5) k=k+1 et retour à l'étape n°1

Gradient déterministe : convergence ?

- Transformons l'équation de mise à jour des coefficients :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+2\mu\ \mathbb{E}\left(\left(d[k]-\underline{\boldsymbol{x}}[k]^T\underline{\boldsymbol{h}}^{(n)}\right)\underline{\boldsymbol{x}}[k]\right)$$

$$\Leftrightarrow \underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+2\mu\ \mathbb{E}\left(d[k]\underline{\boldsymbol{x}}[k]\right)-2\mu\ \mathbb{E}\left(\underline{\boldsymbol{x}}[k]\ \underline{\boldsymbol{x}}[k]^T\right)\underline{\boldsymbol{h}}^{(n)}$$

Soit encore :

$$\underline{\boldsymbol{h}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{R_{xx}})\underline{\boldsymbol{h}}^{(k)}+2\mu\ \underline{r}_{dx}$$

Version II Algorithme du Gradient déterministe

Avec les notations suivantes :

- La matrice d'autocorrélation : $\boldsymbol{R_{xx}}=\mathbb{E}\left(\underline{\boldsymbol{x}}[k]\ \underline{\boldsymbol{x}}[k]^T\right)=\begin{pmatrix}\mathrm{R}_{xx}[0] & \cdots & \mathrm{R}_{xx}[1-L]\\ \vdots & \ddots & \vdots\\ \mathrm{R}_{xx}[L-1] & \cdots & \mathrm{R}_{xx}[0]\end{pmatrix}$

- Le vecteur d'intercorrélation E/S: $\underline{\boldsymbol{r}}_{\boldsymbol{dx}}=\mathbb{E}\left(d[k]\ \underline{\boldsymbol{x}}[k]^T\right)=\begin{pmatrix}\mathrm{R}_{dx}[0]\\ \vdots\\ \mathrm{R}_{dx}[L-1]\end{pmatrix}$

Propriétés matrice auto-covariance

- la matrice d'autocovariance est diagonalisable: sa forme canonique se décompose en éléments propres valable pour toute **matrice carrée** ($\boldsymbol{R_{xx}}$ et $\mathbf{U}$ sont semblables)

$$\boldsymbol{R_{xx}} = \mathbf{U}\,\boldsymbol{\Sigma}\,\mathbf{U}^{-1}$$

  - $\mathbf{U} = (\underline{\boldsymbol{v}}_1 \quad \cdots \quad \underline{\boldsymbol{v}}_L)$ désigne la matrice $(L \times L)$ des vecteurs propres de $\boldsymbol{R_{xx}}$
  - $\boldsymbol{\Sigma}$ désigne la matrice diagonale $(L \times L)$ des valeurs propres telle que

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\lambda_1} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \ddots & \mathbf{0} & \vdots \\ \vdots & \mathbf{0} & \ddots & \mathbf{0} \\ \mathbf{0} & \dots & \mathbf{0} & \boldsymbol{\lambda_L} \end{pmatrix}$$

- $\boldsymbol{R_{xx}}$ étant **hermitienne** (i.e. **auto-adjointe**), ses valeurs propres sont réelles
- $\boldsymbol{R_{xx}}$ étant **définie (semie-)positive**, ses valeurs propres sont strictement positives
- de plus, on a les propriétés suivantes :
  - La matrice $\mathbf{U}$ est une **matrice normale** (commute avec sa matrice adjointe) : $\mathbf{U}^{\boldsymbol{H}}\mathbf{U} = \mathbf{U}\mathbf{U}^{\boldsymbol{H}}$
  - La matrice $\mathbf{U}$ est une **matrice unitaire** : $\mathbf{U}^{\boldsymbol{H}}\mathbf{U} = \boldsymbol{I}_L \Rightarrow \mathbf{U}^{\boldsymbol{H}} = \mathbf{U}^{-1} \Rightarrow \mathbf{U}\mathbf{U}^{\boldsymbol{H}} = \boldsymbol{I}_L$
  - Inversion : $\boldsymbol{R}_{\boldsymbol{xx}}^{-1} = \left(\mathbf{U}\,\boldsymbol{\Sigma}\,\mathbf{U}^{\boldsymbol{H}}\right)^{-1} = \left(\mathbf{U}^{\boldsymbol{H}}\right)^{-1}(\mathbf{U}\,\boldsymbol{\Sigma}\,)^{-1} = \mathbf{U}\,(\mathbf{U}\,\boldsymbol{\Sigma}\,)^{-1} = \mathbf{U}\,(\,\boldsymbol{\Sigma}\,)^{-1}(\mathbf{U}\,)^{-1} = \mathbf{U}\,\boldsymbol{\Sigma}^{-1}\mathbf{U}^{\boldsymbol{H}}$
  - Si la matrice $\mathbf{U}$ est unitaire à coefficients réels alors c'est une **matrice orthogonale**

Convergence algo. gradient déterministe ?

- Utilisation la décomposition canonique vue précédemment

$$\underline{\boldsymbol{h}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{R_{xx}})\underline{\boldsymbol{h}}^{(k)}+2\mu\,\underline{r}_{dx}$$

$$\Rightarrow \mathbf{U}^{H}\underline{\boldsymbol{h}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})\mathbf{U}^{H}\,\underline{\boldsymbol{h}}^{(k)}+2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

On effectue le changement de variable suivant :

1- rotation

$$\underline{\widehat{\boldsymbol{h}}}^{(k)}=\mathbf{U}^{H}\underline{\boldsymbol{h}}^{(k)}$$

On obtient :

$$\underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})\,\underline{\widehat{\boldsymbol{h}}}^{(k)}+2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

Version III Algorithme du Gradient déterministe

En déroulant la récursion, on obtient:

$$\underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})\left((\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})\,\underline{\widehat{\boldsymbol{h}}}^{(k-1)}+2\mu\mathbf{U}^{H}\underline{r}_{dx}\right)+2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

$$\Rightarrow \underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{2}\;\underline{\widehat{\boldsymbol{h}}}^{(k-1)}+\left((\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})+(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{0}\right)2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

$$\Rightarrow \underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{k+1}\;\underline{\widehat{\boldsymbol{h}}}^{(0)}+\left((\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{k}+\cdots+(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{0}\right)2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

$$\Rightarrow \underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{k+1}\;\underline{\widehat{\boldsymbol{h}}}^{(0)}+\frac{\boldsymbol{I_L}-(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{k+1}}{2\mu\,\boldsymbol{\Sigma}}\,2\mu\mathbf{U}^{H}\underline{r}_{dx}$$

$$\Rightarrow \underline{\widehat{\boldsymbol{h}}}^{(k+1)}=(\boldsymbol{I_L}-2\mu\,\boldsymbol{\Sigma})^{k+1}\;\left(\underline{\widehat{\boldsymbol{h}}}^{(0)}-\boldsymbol{\Sigma}^{-1}\mathbf{U}^{H}\underline{r}_{dx}\right)+\boldsymbol{\Sigma}^{-1}\mathbf{U}^{H}\underline{r}_{dx}$$

Convergence algo. gradient déterministe ?

- On note que la solution de Wiener s'écrit :

$$\underline{\boldsymbol{h}}^{opt} = \boldsymbol{R}_{xx}^{-1}\,\underline{\boldsymbol{r}}_{dx} \Rightarrow \underline{\widehat{\boldsymbol{h}}}^{opt} = \mathbf{U}^{\boldsymbol{H}}\left(\mathbf{U}\,\boldsymbol{\Sigma}^{-1}\mathbf{U}^{\boldsymbol{H}}\right)\underline{\boldsymbol{r}}_{dx} = \boldsymbol{\Sigma}^{-1}\mathbf{U}^{\boldsymbol{H}}\,\underline{\boldsymbol{r}}_{dx}$$

On effectue le changement de variable suivant :

2- changement origine

$$\underline{\Delta\widehat{\boldsymbol{h}}}^{(n)} = \underline{\widehat{\boldsymbol{h}}}^{(k)} - \underline{\widehat{\boldsymbol{h}}}^{opt}$$

Et on obtient :

$$\underline{\Delta\widehat{\boldsymbol{h}}}^{(k+1)} = (\boldsymbol{I}_L - 2\mu\,\boldsymbol{\Sigma}\,)^{k+1}\,\underline{\Delta\widehat{\boldsymbol{h}}}^{(0)}$$

Version IV Algorithme du Gradient déterministe

- Avec les 2 changements de notations, l'espace de représentation correspond à l'espace propre (décomposition de ***Karhunen–Loève***) du signal et donc l'équation de mise à jour des coefficients du filtre (version IV) fait alors intervenir une **matrice diagonale**
- On peut alors facilement exprimer la convergence de la kème composante de $\underline{\Delta\widehat{\boldsymbol{h}}}^{(k+1)}$: on dit que la **convergence est modale**

$$\Delta\widehat{h}^{(k+1)}[m] = (1 - 2\mu\,\lambda_k\,)^{k+1}\Delta\widehat{h}^{(0)}[m] \qquad \text{pour} \quad m = 0,1,..,L-1$$

Convergence algo. gradient déterministe ?

- Lorsque la relation précédente converge, on a :

Convergence vers solution de Wiener

$$\lim_{k\to+\infty} \widehat{\Delta h}^{(k+1)}[m] = \widehat{\Delta h}^{(0)}[m] \lim_{k\to+\infty} (1-2\mu\,\lambda_k)^{k+1} = 0 \Rightarrow \lim_{k\to+\infty} h^{(k+1)}[m] = h^{(opt)}[m]$$

- La condition de convergence de chaque composante est alors donnée par

$$|1-2\mu\,\lambda_k| < 1 \Leftrightarrow \mu < \frac{1}{\lambda_k} \qquad k = 0,1,..,L-1$$

Ce qui conduit à la condition globale de convergence du filtre :

$$\mu < \frac{1}{\lambda_{max}} \leq \cdots \leq \frac{1}{\lambda_{min}} \quad \Longrightarrow \quad 0 < \mu < \frac{1}{\lambda_{max}}$$

Bornes (théorie) de convergence

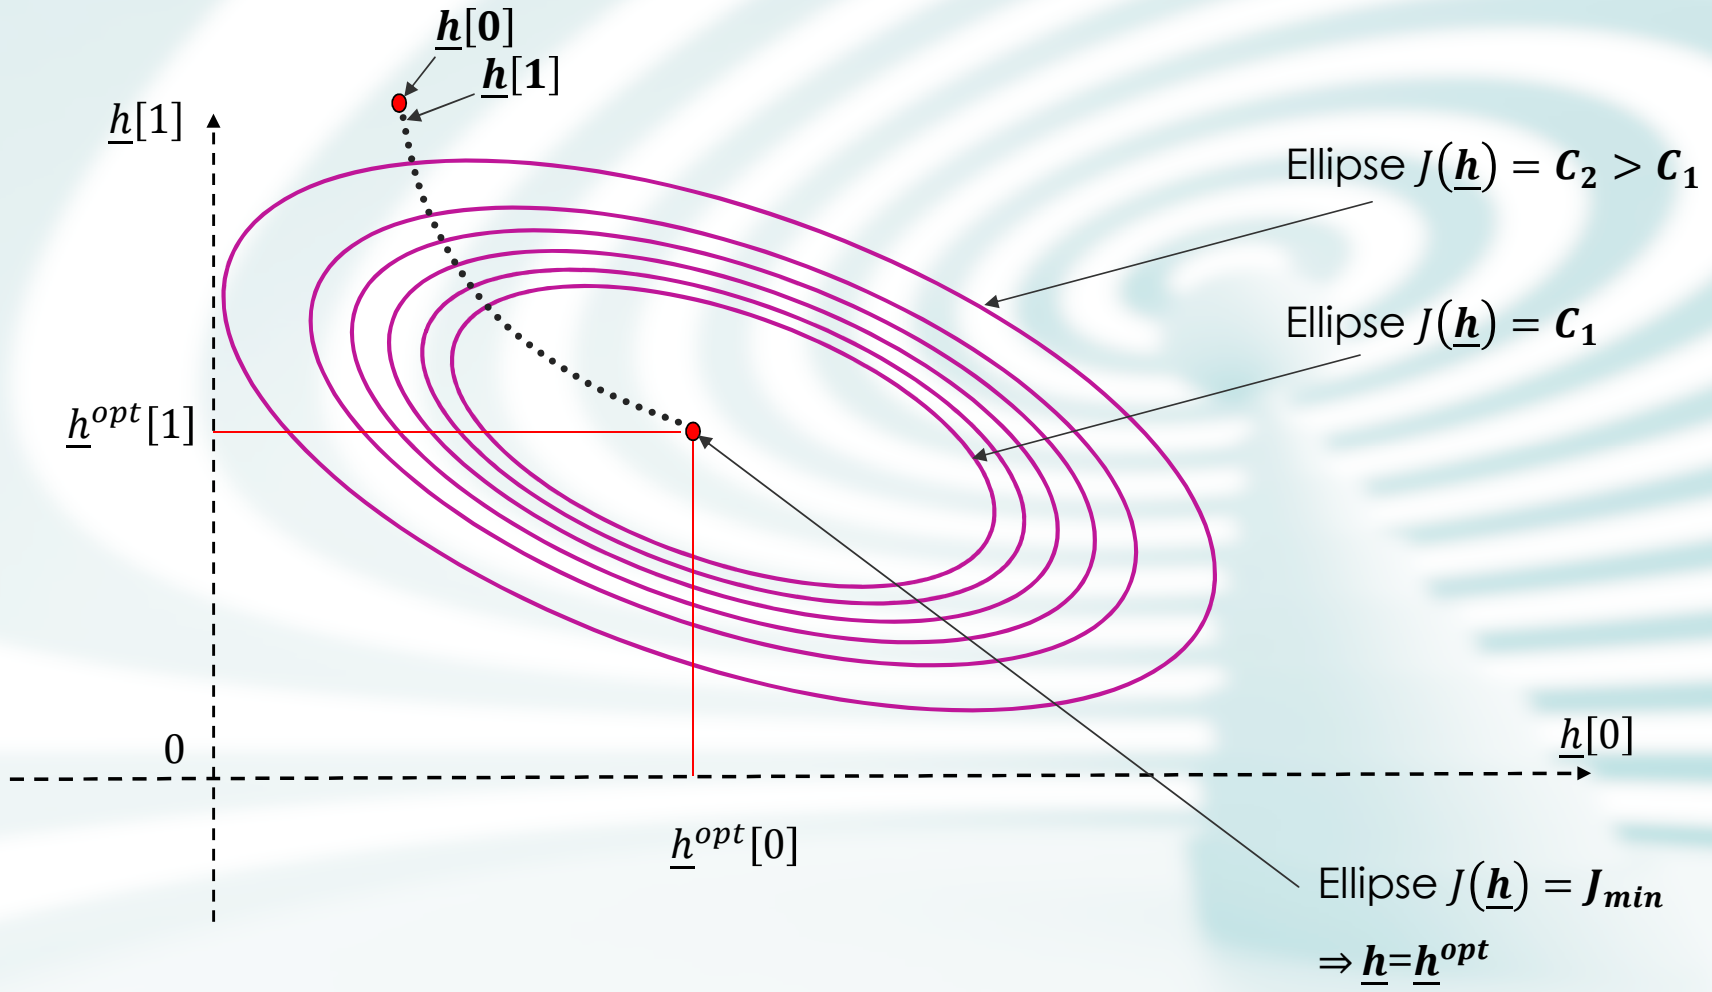
- En pratique, on préfère souvent travailler avec la borne suivante plus stricte:

$$\mu < \frac{1}{tr(\boldsymbol{R_{xx}})} \leq \frac{1}{\lambda_{max}} \quad \text{où} \quad tr(\boldsymbol{R_{xx}}) = L(\sigma_x^2+\mu_x^2) = tr\left(\mathbf{U\,\Sigma\,U^{-1}}\right) = tr\left(\mathbf{\Sigma\,U^{-1}U}\right) = tr(\mathbf{\Sigma}) \sum_k \lambda_k$$

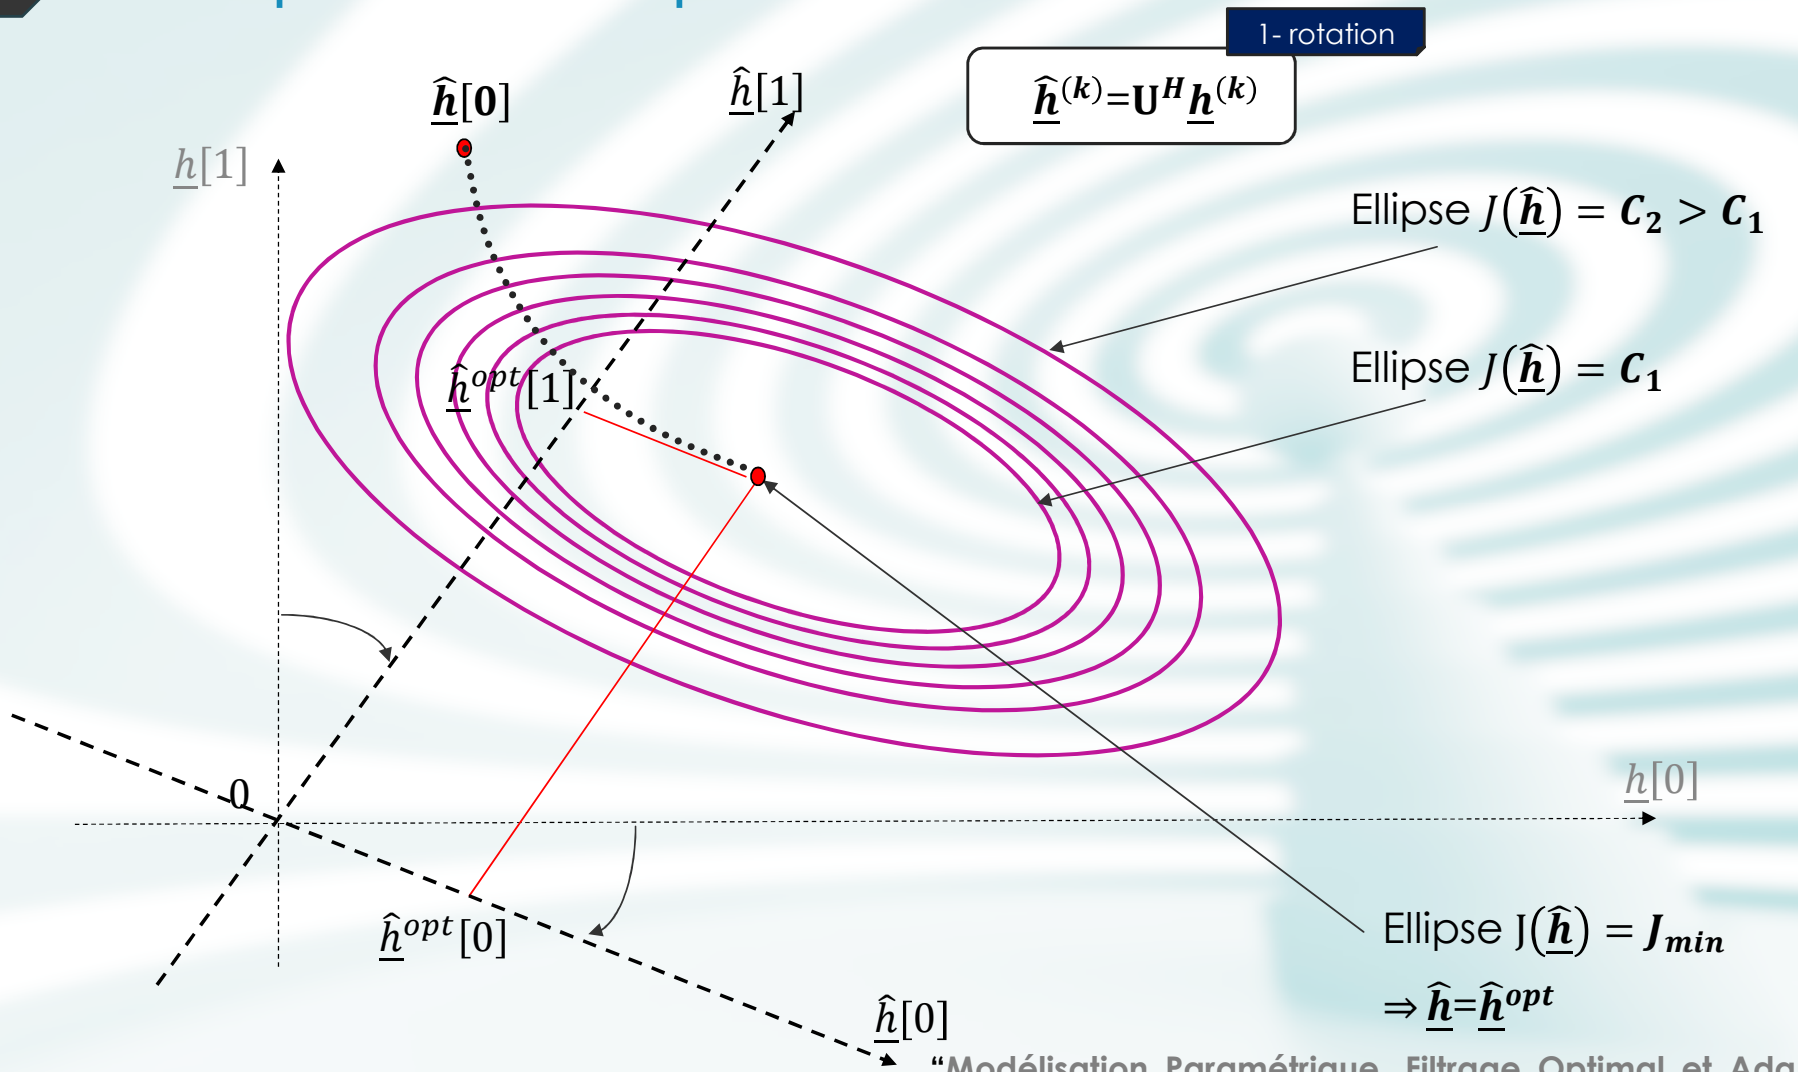
$$\Rightarrow \quad 0 < \mu < \frac{1}{L(\sigma_x^2+\mu_x^2)}$$

Bornes (pratique) de convergence

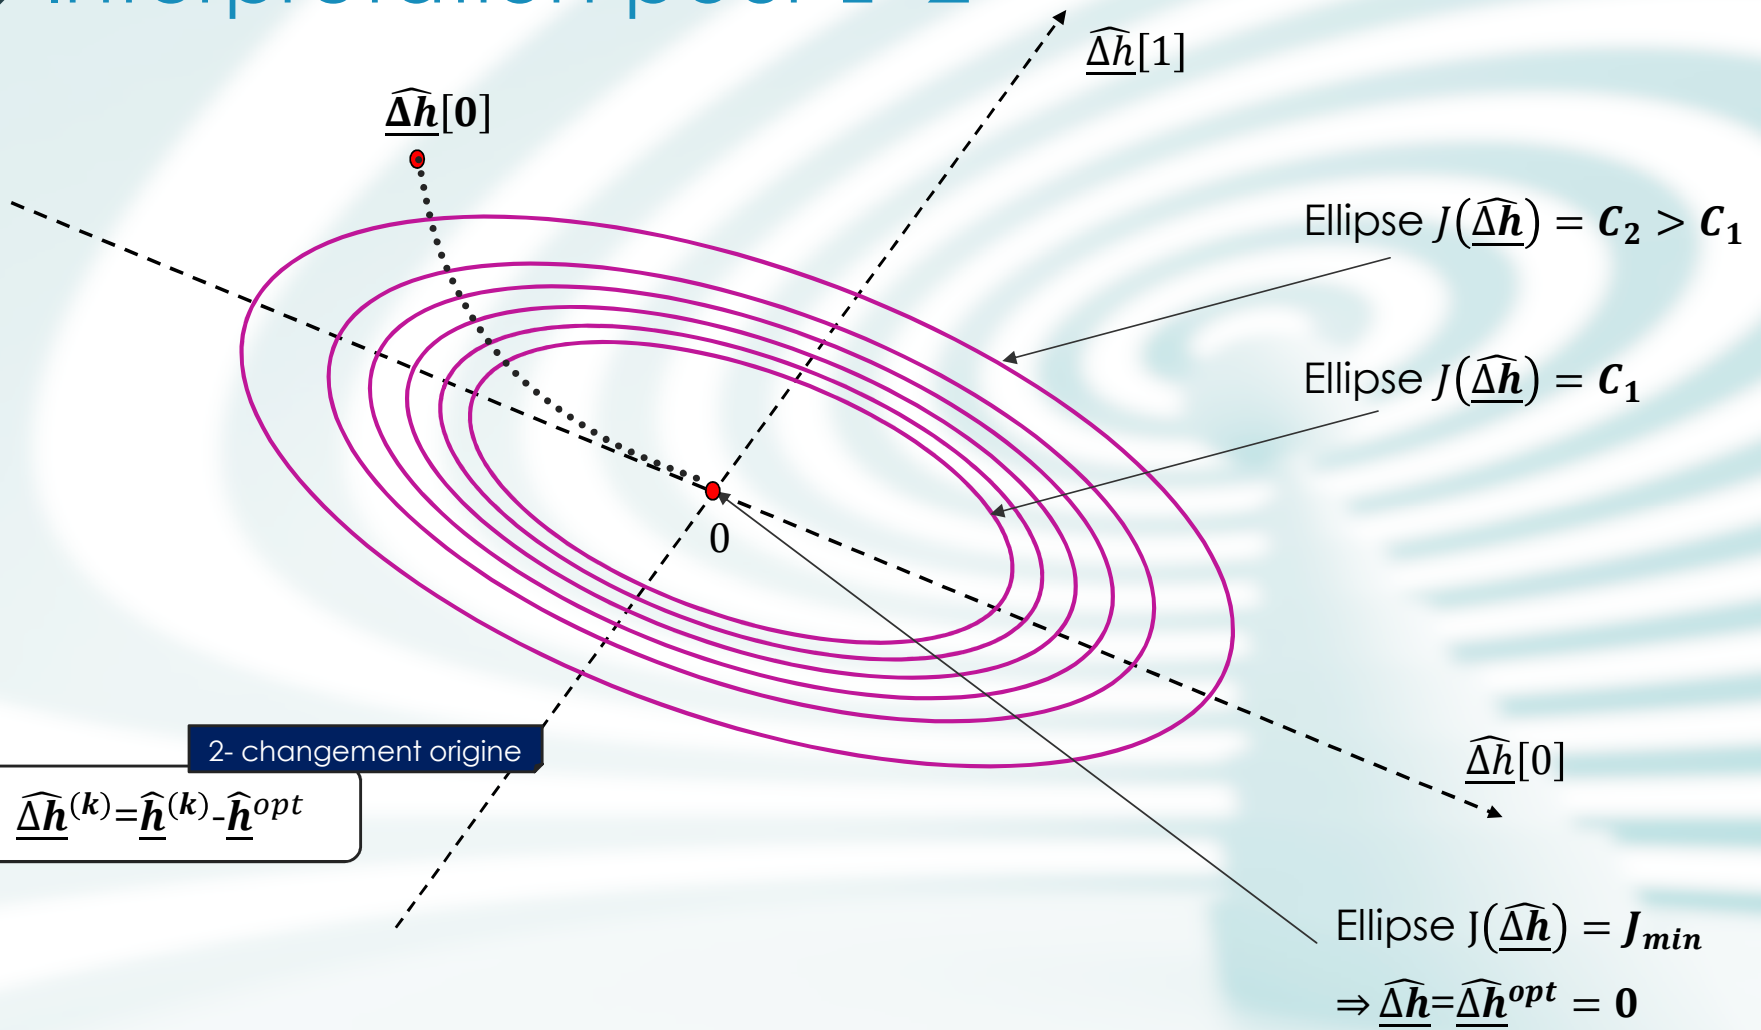
Interprétation pour L=2



Interprétation pour L=2

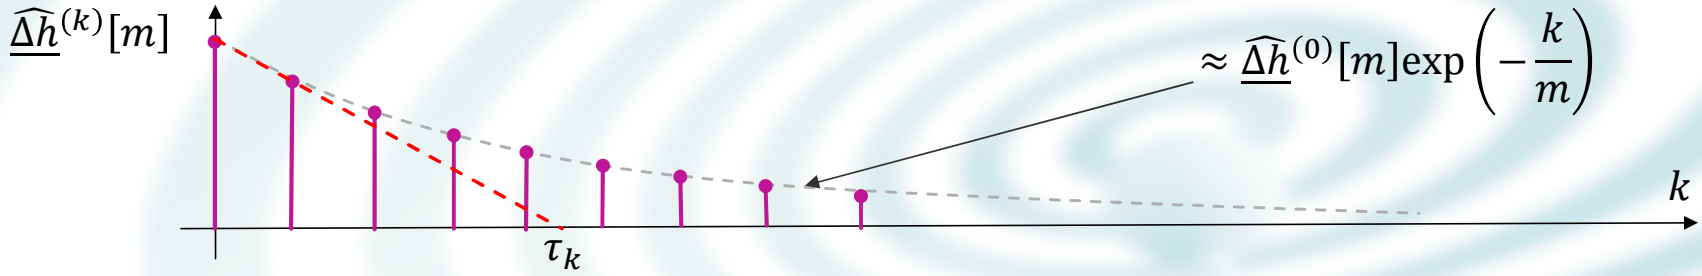


Interprétation pour L=2



Constantes de temps modales (1/2)

- Si l'on s'intéresse à la convergence de la composante numéro m, on a :



- On définit alors la constante de temps de convergence du mode m selon :

$$\underline{\widehat{\Delta h}}^{(k)}[m] = (1 - 2\mu\,\lambda_m)^{k}\,\widehat{\Delta h}^{(0)}[m] \leq \frac{\widehat{\Delta h}^{(0)}[m]}{e} \quad \Rightarrow k \leq \tau_m = \frac{-1}{\log|(1 - 2\mu\,\lambda_m)|}$$

En posant $\mu = \alpha/(2\lambda_{max})$, l'algorithme converge ssi $\alpha \in [0,2]$ et la constante de temps devient:

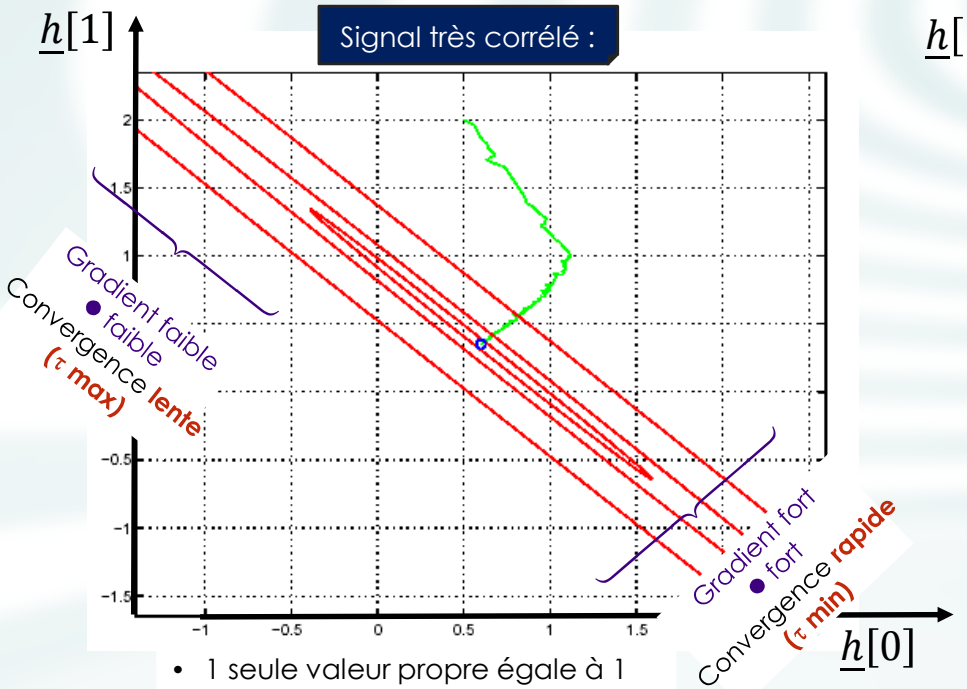
$$\Rightarrow \boxed{\tau_m = \frac{-1}{\log\left|\left(1 - \alpha\frac{\lambda_m}{\lambda_{max}}\right)\right|} \quad \text{pour} \quad m = 0,1,\ldots,L-1}$$

Constantes de temps modales

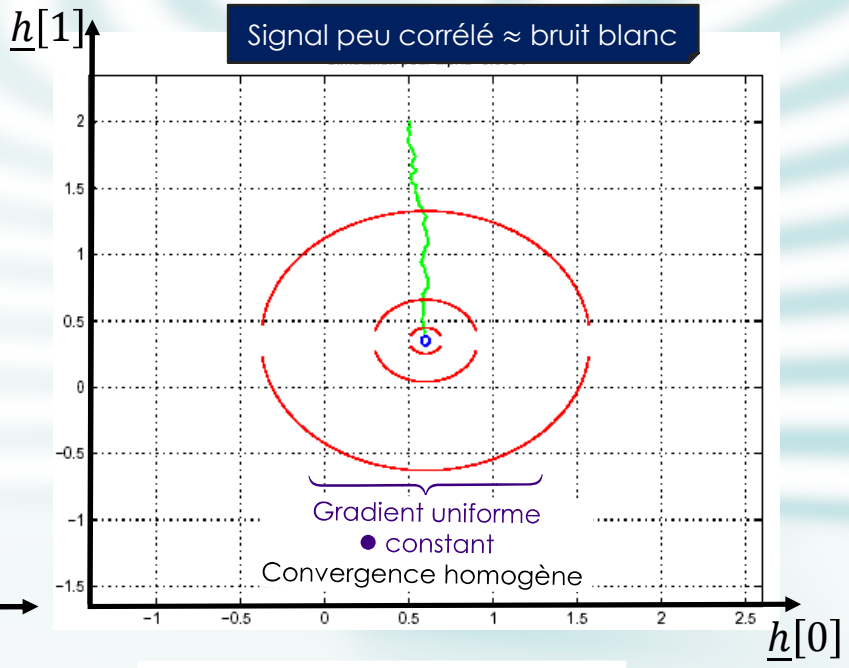
Constantes de temps modales (2/2)

- La convergence de l'algorithme est donc dictée par **le conditionnement** de la matrice $\boldsymbol{R_{xx}}$ d'autocorrélation

$$\kappa(\boldsymbol{R_{xx}}) = \|\boldsymbol{R_{xx}}\| \times \left\|\boldsymbol{R_{xx}}^{-1}\right\| \xrightarrow{\text{si } \boldsymbol{R_{xx}} \text{ normale et si } \|\cdot\|_2 \text{ sur } \ell^2} \kappa(\boldsymbol{R_{xx}}) = \frac{\lambda_{max}}{\lambda_{min}}$$



- 1 seule valeur propre égale à 1
- L-1 valeurs propres égales à ε



- L valeurs propres égales à $1/L$



Filtrage adaptatif

2- Algorithme du gradient stochastique

Mise au point

- Revenons (T. 65) sur l'algorithme du **gradient déterministe** qui est défini par les relations suivantes

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)} - \mu \nabla_{\boldsymbol{h}} \; J\left(\underline{\boldsymbol{h}}\right) \qquad \text{pour} \qquad n = 0,1,2, \ldots$$

lorsque $J\left(\underline{\boldsymbol{h}}\right)$ correspond au critère de l'EQM $J\left(\underline{\boldsymbol{h}}\right) = \mathbb{E}(e^2[k])$, le calcul du gradient conduit à :

$$\nabla_{\boldsymbol{h}} \; J\left(\underline{\boldsymbol{h}}\right) = -2 \, \mathbb{E}\left(e[k]\underline{\boldsymbol{x}}[k]\right)$$

- En pratique, il nous faut donc remplacer l'opérateur mathématique $\mathbb{E}(\cdot)$ par une certaine forme de moyenne temporelle (hypothèse d'**ergodicité**). Comment le faire ?
  - On utilise la démarche de **l 'approximation stochastique** introduite par Robbins et Monroe (1951) sur un problème d'estimation statistique de la moyenne d'une v.a monodimensionnelle
  - Dans le contexte du filtrage adaptatif, cette démarche a été proposée par B. Widrow et conduit à l'algorithme à **l'algorithme du gradient stochastique** encore appelé **algorithme LMS** (pour Least-Mean Square)
  - **Approximation stochastique** : le gradient $\nabla_{\boldsymbol{h}} \; J\left(\underline{\boldsymbol{h}}\right)$ est alors remplacé par sa valeur instantanée soit $-2e[k]\underline{\boldsymbol{x}}[k]$

L'algorithme LMS

- En insérant l'approximation stochastique précédente dans l'équation de mise à jour des coefficients, on obtient l'**algorithme du gradient stochastique (ou LMS)** défini par les opérations suivantes :

Algorithme du gradient stochastique (LMS)

1) A l'itération k, réception d'un nouvel échantillon $x[k]$ et formation du vecteur d'entrée

$$\underline{\boldsymbol{x}}[\boldsymbol{k}] = (x[k] \;\; x[k-1] \ldots x[k-L+1])^T$$

2) Calcul du signal en sortie de filtre

$$\hat{d}[k] = \sum_{m=0}^{L-1} h^{(k)}[m]\, x[k-m] = \underline{\boldsymbol{x}}^{\boldsymbol{T}}[k]\, \underline{\boldsymbol{h}}^{(\boldsymbol{k})}$$

3) Calcul de l'erreur (dite *a priori*) : $e[k] = d[k] - \hat{d}[k]$

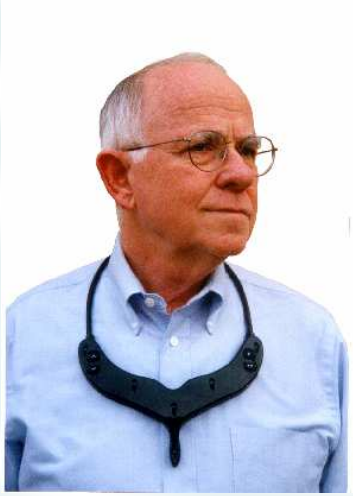
4) Mise à jour des coefficients pour l'itération suivante : $\underline{\boldsymbol{h}}^{(\boldsymbol{k+1})} = \underline{\boldsymbol{h}}^{(\boldsymbol{k})} + \mu \;\; e[k]\underline{\boldsymbol{x}}[k]$

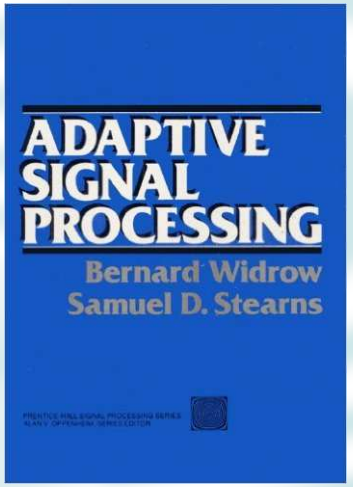
5) k=k+1 et retour à l'étape n°1

Bernard Widrow

Bernard Widrow, (1929-xx) USA – Standford – MIT

- Etudes au MIT (Ms C'51, Ph. D. '56)
- Depuis 1956, prof. Genie Electrique à Standford
- Co-inventeur de l'algorithme adaptatif LMS de Widrow-Hoff proposé en 1962 durant la thèse de Marcian Esward "Ted" Hoff (12ème employé de Intel et inventeur en 1969 du pemier microprocessor universel -l'Intel 4004
- Inventeur des réseaux de neurone ADELINE (**Ada**ptive **Li**near **Ne**uron) et MADALINE (**M**any A**DELINE**) à la base des réseaux de neurones actuels





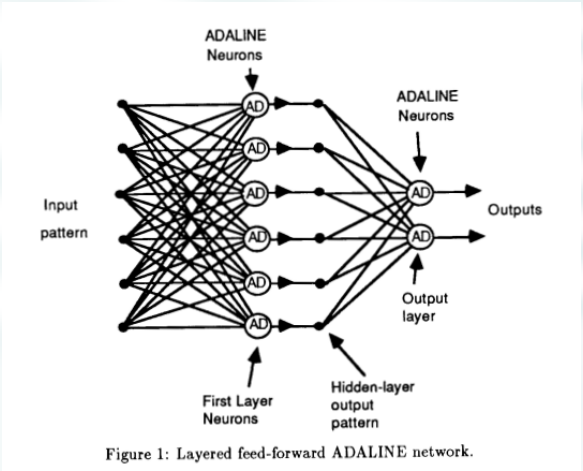


Figure 1: Layered feed-forward ADALINE network.

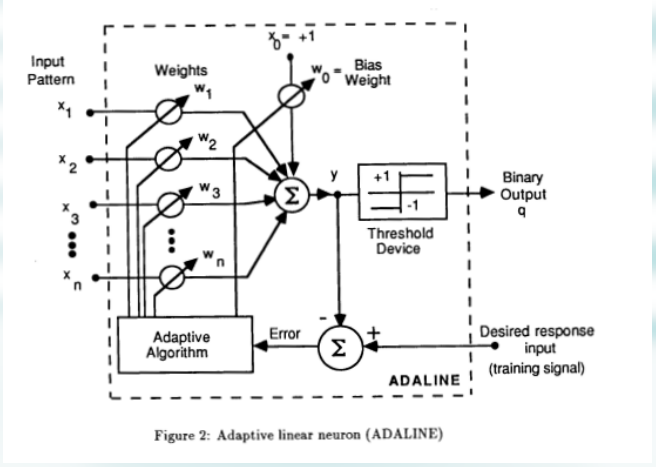


Figure 2: Adaptive linear neuron (ADALINE)

Analyse du LMS

- 2 remarques importantes
  - avec cette approximation stochastique, les coefficients $\underline{\boldsymbol{h}}^{(k)}$ du filtre sont maintenant **des variables aléatoires** (car $e[k]$ et $\underline{\boldsymbol{x}}[k]$ le sont)
  - L'algorithme LMS possède **une faible complexité** : il nécessite à chaque itération uniquement $2L$ multiplications et $(2L+1)$ additions

- Au sujet de l'analyse de la convergence, deux critères statistiques sont généralement étudiés
  - La **convergence en moyenne** des coefficients : $\lim_{k\to+\infty} \mathbb{E}\left(\underline{\boldsymbol{h}}^{(k)}\right)$
  - La convergence du critère $J(\underline{\boldsymbol{h}})$ (en **moyenne quadratique**) : $\lim_{k\to+\infty} J\left(\underline{\boldsymbol{h}}^{(k)}\right)$

Convergence en moyenne de $\underline{\boldsymbol{h}}^{(k)}$ (1/3)

- Considérons l'équation de mise à jour du LMS

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ e[k]\underline{\boldsymbol{x}}[k] \qquad \text{où} \qquad e[k]=d[k]-\underline{\boldsymbol{x}}^{T}[k]\,\underline{\boldsymbol{h}}^{(k)}$$

Le signal de référence $d[k]$ peut s'écrire selon : $d[k]=\underline{\boldsymbol{x}}^{T}[k]\,\underline{\boldsymbol{h}}^{opt}+\varepsilon[k]$ car $\underline{\boldsymbol{h}}^{opt}$ correspond au filtre linéaire qui permet d'estimer « au mieux » $d[k]$ à partir de x$[k]$ (cf. définition du filtre de Wiener). Le signal $\varepsilon[k]$ correspond quant à lui à un bruit centré, non-corrélé avec le signal $\underline{\boldsymbol{x}}[k]$

- On obtient ainsi :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ \underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{T}[k]\left(\underline{\boldsymbol{h}}^{opt}-\underline{\boldsymbol{h}}^{(k)}\right)+\mu\,\varepsilon[k]\underline{\boldsymbol{x}}[k]$$

$$\Rightarrow \underline{\Delta\boldsymbol{h}}^{(k+1)}=\underline{\Delta\boldsymbol{h}}^{(k)}-\mu\ \underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{T}[k]\,\underline{\Delta\boldsymbol{h}}^{(k)}+\mu\,\varepsilon[k]\underline{\boldsymbol{x}}[k] \qquad \text{où} \quad \underline{\Delta\boldsymbol{h}}^{(k)}=\underline{\boldsymbol{h}}^{(k)}-\underline{\boldsymbol{h}}^{opt}$$

- Soit pour une analyse « en moyenne »

$$\mathbb{E}\left(\underline{\Delta\boldsymbol{h}}^{(k+1)}\right)=\mathbb{E}\left(\left(\boldsymbol{I}-\mu\,\underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{T}[k]\right)\underline{\Delta\boldsymbol{h}}^{(k)}\right)+\mu\ \underbrace{\mathbb{E}\left(\varepsilon[k]\underline{\boldsymbol{x}}[k]\right)}_{=0}$$

Convergence en moyenne de $\underline{\boldsymbol{h}}^{(k)}$ (2/3)

- Pour analyser cette équation, nous devons faire **une hypothèse d'indépendance** entre le signal d'entrée $\underline{\boldsymbol{x}}[k]$ et le vecteur $\underline{\Delta \boldsymbol{h}}^{(k)}$ d'écart à l'optimal

$$\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k+1)}\right)= \mathbb{E}\left(\left(\boldsymbol{I}-\mu \underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{\boldsymbol{T}}[k]\right)\right)\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k)}\right) \Rightarrow \boxed{\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k+1)}\right)=\left(\boldsymbol{I}-\mu\, \underline{\boldsymbol{R}}_{xx}\right)\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k)}\right)}$$

  - Ceci n'est pas strictement vrai puisque la relation l'on a établi que le vecteur des coefficients à l'optimal $\underline{\Delta \boldsymbol{h}}^{(k+1)}$ est directement liée à $\underline{\boldsymbol{x}}[k]$
  - Cependant on peut considérer que cette hypothèse peut être considérée comme valide sous la condition supplémentaire de **pas faible** ou bien d'analyse en **phase asymptotique**

- On obtient ainsi une équation de mise à jour identique à celle étudiée lors de l'analyse de l'algorithme du gradient déterministe. En effet :

$$\mathbf{U}^{\boldsymbol{H}}\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k+1)}\right)=\left(\boldsymbol{I}-\mu\, \boldsymbol{\Sigma}\right)\mathbf{U}^{\boldsymbol{H}}\mathbb{E}\left(\underline{\Delta \boldsymbol{h}}^{(k)}\right) \Rightarrow \boxed{\mathbb{E}\left(\underline{\widehat{\Delta \boldsymbol{h}}}^{(k+1)}\right)=\left(\boldsymbol{I}-\mu\, \boldsymbol{\Sigma}\right)\ \mathbb{E}\left(\underline{\widehat{\Delta \boldsymbol{h}}}^{(k)}\right)} \quad \text{où} \quad \underline{\widehat{\Delta \boldsymbol{h}}}^{(k)} = \mathbf{U}^{\boldsymbol{H}}\underline{\Delta \boldsymbol{h}}^{(k)}$$

Convergence en moyenne de $\underline{\boldsymbol{h}}^{(k)}$ (3/3)

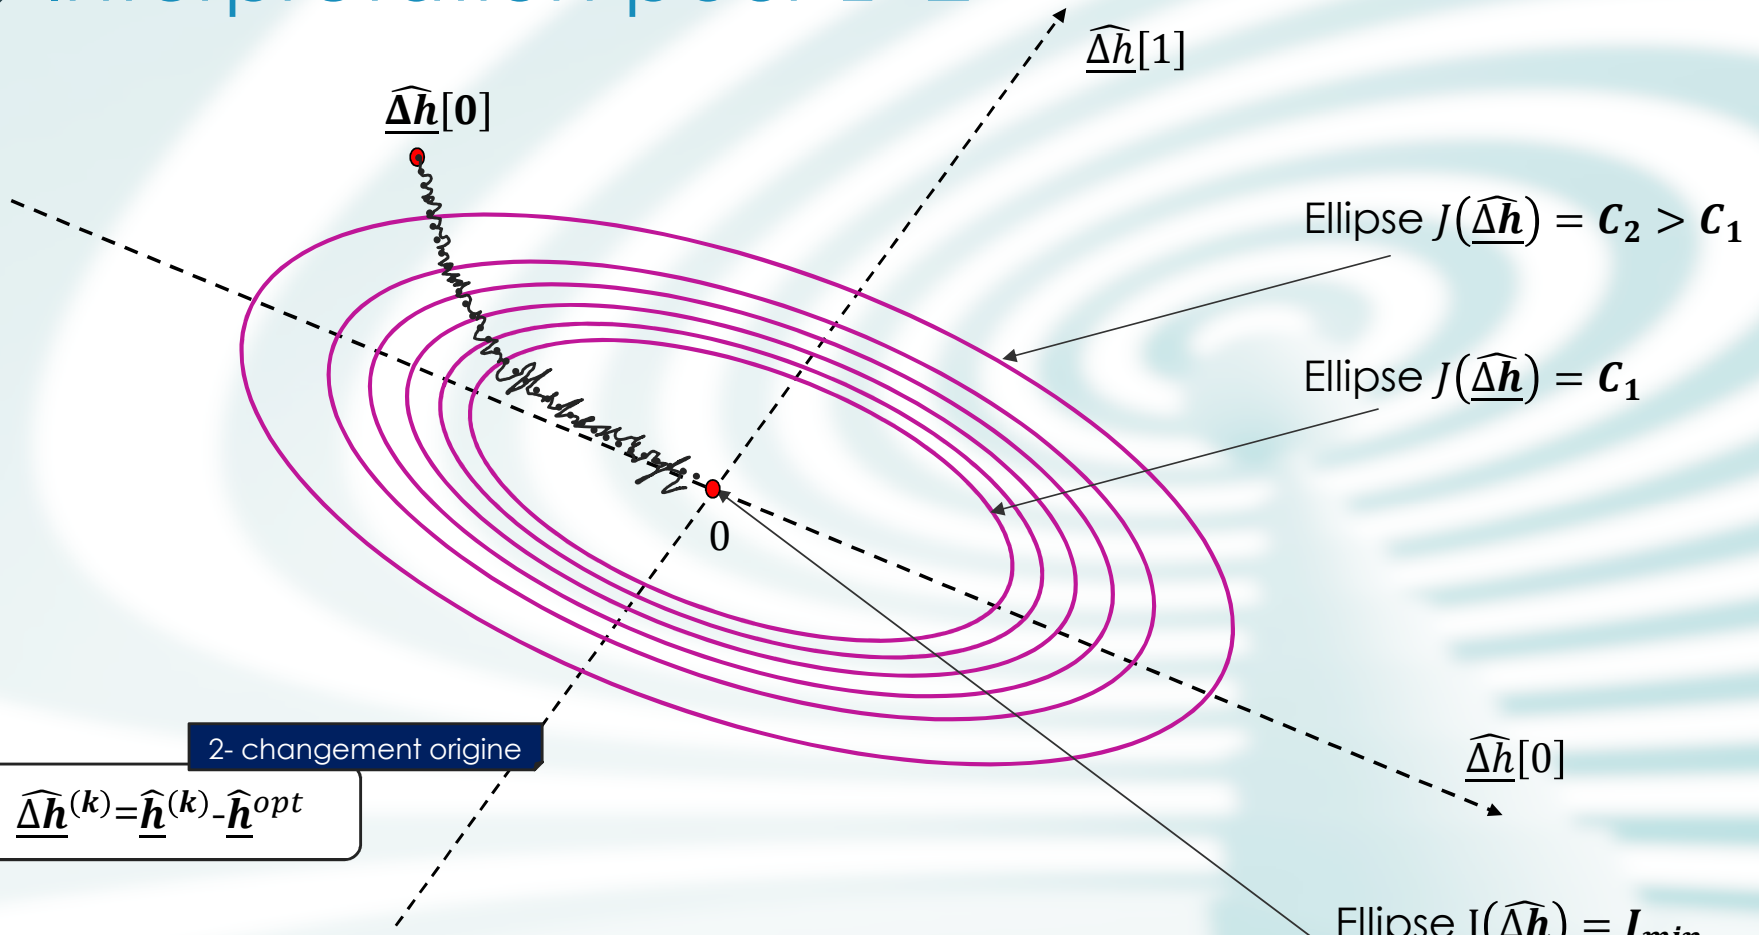
- En réalisant la même analyse que celle effectuée pour l'algorithme du gradient déterministe, nous pouvons conclure à la **convergence en moyenne** de l'algorithme LMS sous les conditions

$$0 < \mu < 2/\lambda_{max} \Rightarrow \lim_{k \to +\infty} \mathbb{E}\left(\widehat{\Delta \underline{\boldsymbol{h}}}^{(k+1)}\right) = \mathbf{0} \Rightarrow \boxed{\lim_{k \to +\infty} \mathbb{E}\left(\underline{\boldsymbol{h}}^{(k+1)}\right) = \underline{\boldsymbol{h}}^{opt}}$$

où λ_{max} désigne la valeur propre maximale de la matrice d'autocorrélation $\underline{\boldsymbol{R}}_{xx}$

- Note : maintenant la convergence de l'algorithme n'est assurée qu'en moyenne (c'est-à-dire qu'une trajectoire prise isolément peut présenter un écart important à l'optimal)

Interprétation pour L=2



Convergence en moyenne quadratique

- L'analyse de la **convergence en moyenne quadratique** $J(k) = \mathbb{E}(e^2[k])$ de l'algorithme LMS n'est pas directe et demande quelques calculs fastidieux. On montre que :
  - L'algorithme converge ssi : $0 < \mu < 2/\lambda_{max}$
  - L'erreur quadratique moyenne asymptotique est donnée sous l'hypothèse **d'indépendance** par

$$\lim_{k \to +\infty} J(k) = \underbrace{J_{min}}_{\text{EQM minimale}} + \underbrace{\mu \, J_{min} \sum_{m=1}^{L} \frac{\lambda_m}{2 - \mu\lambda_m}}_{\text{EQM en excès}}$$

  où λ_m désigne la valeur propre n° m de la matrice d'autocorrélation $\underline{\underline{R}}_{xx}$

- On en déduit les propriétés suivantes :
  - L'erreur quadratique minimale J_{min} est obtenue lorsque le pas μ tend vers zéro
  - pour un signal d'entrée donné ($\underline{\underline{R}}_{xx}$ fixée), plus le pas μ est grand et plus l'erreur quadratique en excès est importante

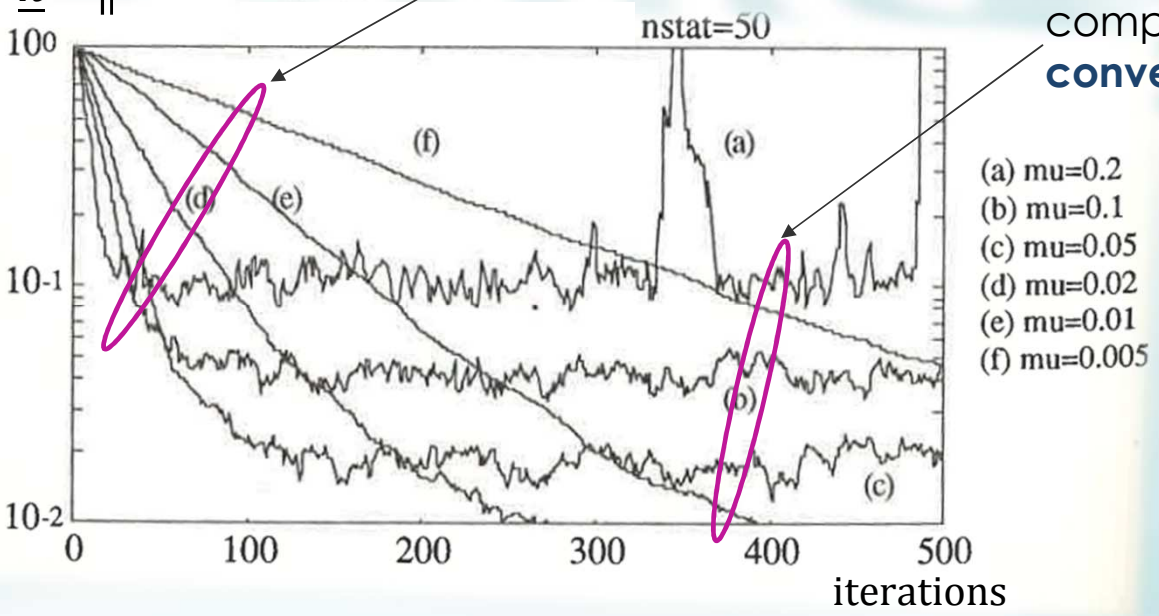
LMS : compromis vitesse-variance RU

- Analyse de la courbe de convergence de l'erreur moyenne quadratique $\|\underline{h}^{(k)} - \underline{h}^{opt}\|^2$ entre coefficients $\underline{h}^{(k)}$ par rapport à l'optimal $\underline{h}^{opt}$ pour différentes valeurs du pas d'adaptation μ

$\|\underline{h}^{(k)} - \underline{h}^{opt}\|^2$

comportement en **convergence initiale**

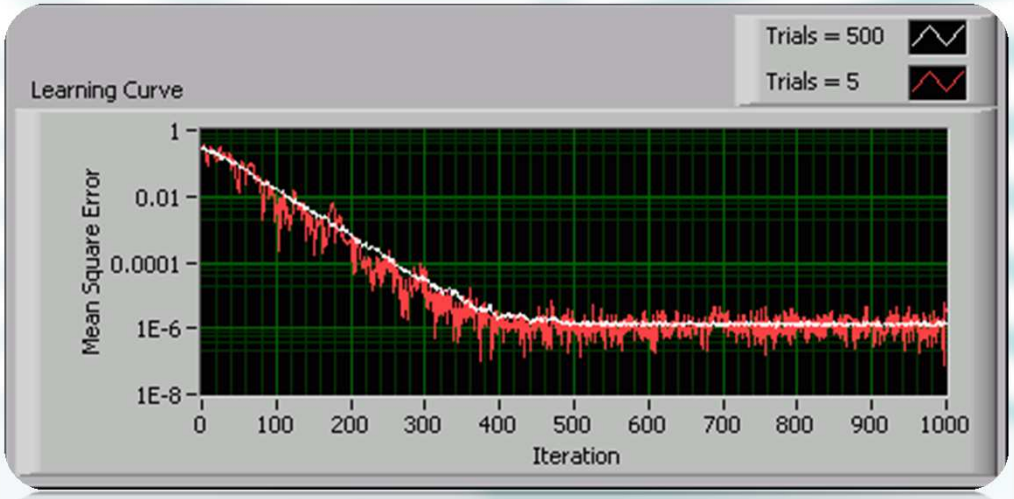
comportement en **convergence asymptotique**





Filtrage adaptatif

3- Variantes du LMS



Variantes du LMS (1/3)

- L'étape 4 de l'**algorithme LMS** est donnée par :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ e[k]\underline{\boldsymbol{x}}[k] \qquad \text{stable pour} \qquad 0<\mu\ll 2/(L\,\sigma_x^2)\ll 2/\lambda_{max}$$

- Lorsque le signal est non-stationnaire (notamment lorsque la puissance $\sigma_x^2(t)$ varie au cours du temps) on préfère utiliser l'**algorithme Normalized-LMS** (NLMS)

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\bar{\mu}\ e[k]\underline{\boldsymbol{x}}[k]/\left(\underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{x}}[k]\right) \qquad \text{stable pour} \qquad 0<\bar{\mu}=\mu\times(L\,\sigma_x^2)\ll 2$$

- Si l'on remplace le critère de l'EQM $J(\underline{\boldsymbol{h}})=\mathbb{E}(e^2[k])$ par le **critère de la moindre valeur absolue** $J_a(\underline{\boldsymbol{h}})=\mathbb{E}(|e[k]|)$, on a alors le gradient

$$\nabla_{\boldsymbol{h}}\,J_a(\underline{\boldsymbol{h}})=-\mathbb{E}\left(\underline{\boldsymbol{x}}[k]\ \text{signe}(e[k])\right)$$

ce qui conduit à l'algorithme stochastique suivant (**algorithme du signe-erreur**) :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ \underline{\boldsymbol{x}}[k]\ \text{signe}(e[k]) \qquad \text{stable pour} \qquad 0<\mu\ll 2|e[k]|/\left(\underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{x}}[k]\right)$$

Variantes du LMS (2/3)

- Une autre façon de simplifier les filtres adaptatifs par gradient consiste à utiliser l'**algorithme signe-donnée** donnée par :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ \ e[k]\ \text{signe}\left(\underline{\boldsymbol{x}}[k]\right) \quad \text{stable pour} \quad 0<\mu\ll 2/\left(\underline{\boldsymbol{x}}^{T}[k]signe\left(\underline{\boldsymbol{x}}[k]\right)\right)$$

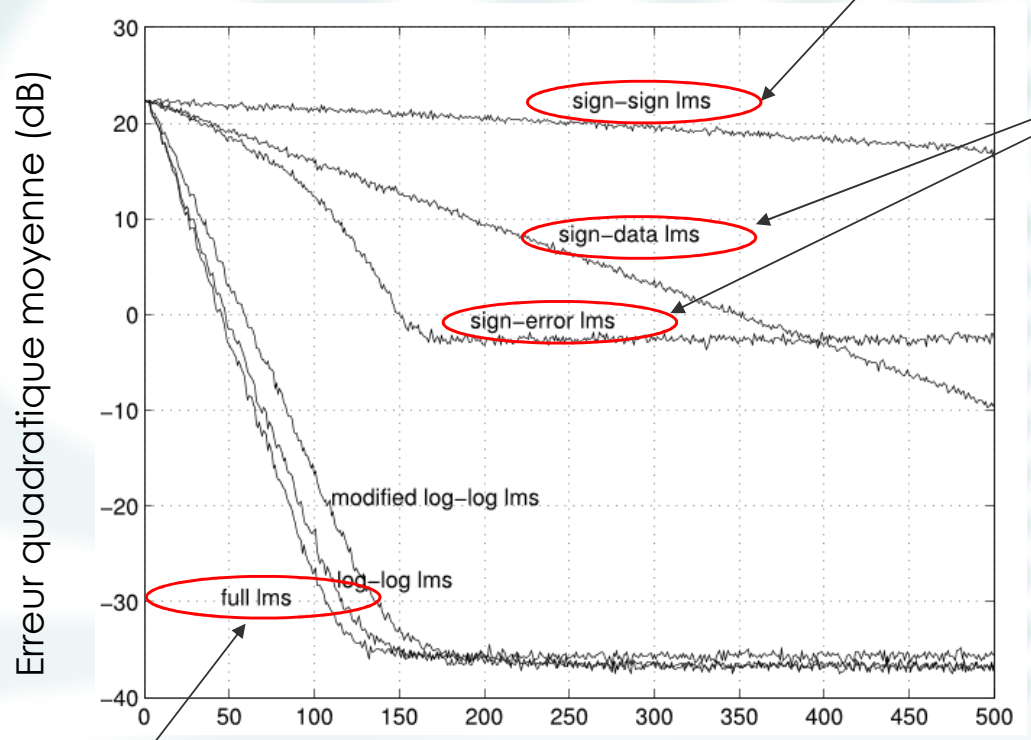
- Ou bien encore l'**algorithme signe-signe** en continuant dans le même esprit

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\mu\ \text{signe}(e[k])\ \text{signe}\left(\underline{\boldsymbol{x}}[k]\right) \quad \text{stable pour} \quad 0<\mu\ll 2|e[k]|/\left(\underline{\boldsymbol{x}}^{T}[k]signe\left(\underline{\boldsymbol{x}}[k]\right)\right)$$

- Une autre variante consiste à imposer

Variantes du LMS (3/3)

- Performances des différentes variantes du LMS :



2- L'algorithme signe-signe possède
Les moins bonnes performances

3- L'opérateur signe appliqué aux données est plus performant que de l'appliquer à l'erreur

"*The log-log LMS algorithm*" S.S. Mahant-Shetti, S. Hosur and A. Gatherer, DSP R & D Center, Texas Instruments Inc., Dallas, International Conference on Acoustic Speech and Signal Processing, 1997.

Problème d'égalisation :

- Taille du filtre : L=10
- Précision 32 bits
- Pas adaptation $\mu = 2^{-11}$
- Rapport signal à bruit 40 dB

1- L'algorithme LMS possède
Les meilleures performances

L'algorithme de Newton (1/2)

- Considérons la mise à jour suivante : $\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}+\underline{\Delta \boldsymbol{h}}[k]$
- L'erreur quadratique moyenne donnée par :

$$\boldsymbol{J}=\mathbb{E}(e^2[k]) \quad \text{avec} \quad e[k]=d[k]-\underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{h}}^{(k)}$$

peut être approximée localement au second ordre :

$$\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k+1)}\right)=\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}+\underline{\Delta \boldsymbol{h}}[k]\right)=\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)++\underline{\Delta \boldsymbol{h}}^T[k]\nabla \boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)+\frac{1}{2}\underline{\Delta \boldsymbol{h}}^T[k]\nabla^2\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)\underline{\Delta \boldsymbol{h}}[k]+o\left(\left\|\underline{\Delta \boldsymbol{h}}^T[k]\right\|^2\right)$$

- On cherche alors l'incrément $\underline{\Delta \boldsymbol{h}}[k]$ qui permet de décroître la fonction de coût ce qui conduit à annuler le gradient :

$$\nabla_{\Delta \boldsymbol{h}}\left(\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k+1)}\right)-\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)\right)=\nabla \boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)+\nabla^2\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)\underline{\Delta \boldsymbol{h}}[k]=0$$

$$\Rightarrow \underline{\Delta \boldsymbol{h}}[k]=-\left(\nabla^2\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)\right)^{-1}\nabla \boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)$$

- On obtient ainsi une nouvelle équation de mise à jour des coefficients selon :

$$\underline{\boldsymbol{h}}^{(k+1)}=\underline{\boldsymbol{h}}^{(k)}-\left(\nabla^2\boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)\right)^{-1}\nabla \boldsymbol{J}\left(\underline{\boldsymbol{h}}^{(k)}\right)$$

L'algorithme de Newton (2/2)

- Or on a vu (cf. filtrage de Wiener) que l'on a :

$$\nabla_{\boldsymbol{h}}\ J(\underline{\boldsymbol{h}}) = -2\,\mathbb{E}\big(e[k]\underline{\boldsymbol{x}}[k]\big) = -2\,\mathbb{E}\Big(\underline{\boldsymbol{x}}[k]\big(d[k] - \underline{\boldsymbol{x}}^T[k]\underline{\boldsymbol{h}}^{(k)}\big)\Big)$$

$$\nabla^2 J(\underline{\boldsymbol{h}}) = 2\,\underline{\boldsymbol{R}}_{xx} \qquad \mu$$

- On introduit alors un « coefficient de rappel » μ, ce qui conduit à **l'algorithme de Newton** donné par :

$$\underline{\boldsymbol{h}}^{(k+1)} = \underline{\boldsymbol{h}}^{(k)} + \mu\,\underline{\boldsymbol{R}}_{xx}^{-1}\ \mathbb{E}\big(e[k]\underline{\boldsymbol{x}}[k]\big)$$



A démontrer :
(a) pour μ =1 l'algorithme de Newton converge vers la solution de Wiener $\underline{\boldsymbol{h}}^{opt}$ **en une seule iteration**
(b) la convergence est assurée ssi

$$|1-\mu| < 1 \Rightarrow 0 < \mu < 1$$

(c) La vitesse de convergence de chaque coefficient est indépendante de l'étalement des valeurs propres de $\underline{\mathbf{R}}_{\mathbf{xx}}$

Ceci est à comparer avec **l'algorithme du gradient déterministe**

$$\underline{\boldsymbol{h}}^{(k+1)} = \underline{\boldsymbol{h}}^{(k)} + \mu\ \mathbb{E}\big(e[k]\underline{\boldsymbol{x}}[k]\big)$$

Les algorithmes quasi-Newton

- On peut estimer la matrice d'autocorrélation par :

$$\underline{\underline{\widehat{\boldsymbol{R}}}}_{\boldsymbol{xx}}[k] = \frac{1}{k}\sum_{i=1}^{k}\underline{\boldsymbol{x}}[i]\underline{\boldsymbol{x}}^{T}[i] = \frac{1}{k}\underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{T}[k] + \left(\frac{k-1}{k}\right)\underline{\underline{\widehat{\boldsymbol{R}}}}_{\boldsymbol{xx}}[k-1]$$

Ergodicité : Remplacement des statistiques d'ensemble par des statistiques temporelles

- On peut alors définir un **algorithme quasi-Newton stochastique** selon:

$$\underline{\boldsymbol{h}}^{(\boldsymbol{k+1})} = \underline{\boldsymbol{h}}^{(\boldsymbol{k})} + \mu\,\underline{\underline{\boldsymbol{R}}}_{\boldsymbol{xx}}^{-1}[k]e[k]\underline{\boldsymbol{x}}[k]$$

$$\underline{\underline{\boldsymbol{R}}}_{\boldsymbol{xx}}[k] = (1-\mu)\underline{\underline{\boldsymbol{R}}}_{\boldsymbol{xx}}[k-1] + \mu\;\underline{\boldsymbol{x}}[k]\underline{\boldsymbol{x}}^{T}[k]$$

- Nous sommes ici à la frontière entre les algorithmes optimisés à partir d'un critère statistique (LMS, NLMS, Newton) et les algorithmes utilisant un critère géométrique de moindres carrés (pondérés)



Filtrage adaptatif

4- Les algorithmes des moindres carrés (Least-Square)

Un critère d'erreur Algébrique

- Le critère des **moindres carrés pondérés** est un **critère en bloc** de type algébrique (et non plus statistique) défini par :

$$J(\underline{\boldsymbol{h}}) = \sum_{i=1}^{k} w[i]\, e^2[i] \qquad \text{avec} \qquad e[i] = d[i] - \underline{\boldsymbol{x}}^T[i]\, \underline{\boldsymbol{h}}$$

Ici, la notion de vecteur $\underline{\boldsymbol{h}}$ variant dans le temps a disparu. On cherche simplement le meilleur vecteur

où $w[i]$ est un facteur de pondération de l'erreur $e[i]$ obtenue à l'instant *i*.

- En pratique, il est fréquent de choisir une **fenêtre de pondération de type exponentielle** soit $w[i] = \lambda^{k-i}$ avec $\lambda \in]0,1]$. Ainsi, la fonction de coût « oublie » le passé et donne plus d'importance aux données récentes
- Un lien avec le critère de l'EQMM qui a servi de base au filtrage optimal de Wiener peut être obtenu à travers la propriété d'**ergodisme**. Par ailleurs, l'utilisation d'un facteur d'oubli permet d'opérer dans un contexte présentant des variations lentes dans le temps.

$$\lim_{k\to+\infty} \frac{1}{k} J(\underline{\boldsymbol{h}})\Big|_{\lambda=1} = \mathbb{E}\left[e^2[i]\right]$$

Un critère d'erreur Algébrique

- Le critère précédent des **moindres carrés pondérés** peut s'écrire de manière vectorielle selon

$$J(\underline{\boldsymbol{h}}) = \sum_{i=1}^{k} \lambda^{k-i} e^2[i] = \underline{\boldsymbol{\varepsilon}}^T[k]\,\underline{\boldsymbol{\varepsilon}}[k] = \left\|\underline{\boldsymbol{\varepsilon}}[k]\right\|^2$$

avec les notations suivantes

$$\underline{\boldsymbol{\varepsilon}}[k] = \underset{k\times 1}{\begin{pmatrix} \lambda^{(k-1)/2}\ d[1] \\ \lambda^{(k-2)/2}\ d[2] \\ \vdots \\ \lambda^{1/2} d[k-1] \\ \lambda^{0/2}\ d[k] \end{pmatrix}} - \underset{k\times L}{\begin{pmatrix} \lambda^{(k-1)/2}\,x[1] & \lambda^{(k-1)/2}\,x[0] & \dots & \lambda^{(k-1)/2}\,x[1-L+1] \\ \lambda^{(k-2)/2}\,x[2] & \lambda^{(k-2)/2}\,x[1] & \dots & \lambda^{(k-2)/2}\,x[2-L+1] \\ \vdots & \ddots & & \vdots \\ \lambda^{1/2}\,x[k-1] & \lambda^{1/2}\,x[k-2] & \dots & \lambda^{1/2}\ x[k-L] \\ \lambda^{0/2}\,x[k] & \lambda^{0/2}\,x[k-1] & \dots & \lambda^{0/2}\,x[k-L+1] \end{pmatrix}} \underset{L\times 1}{\begin{pmatrix} h[0] \\ h[1] \\ \vdots \\ h[L-2] \\ h[L-1] \end{pmatrix}}$$

$$\Leftrightarrow \underline{\boldsymbol{\varepsilon}}[k] = \underline{\tilde{\boldsymbol{d}}}[k] - \underline{\tilde{\mathbf{X}}}[k] \times \underline{\boldsymbol{h}}$$

Un critère d'erreur Algébrique

- Avec cette nouvelle notation, la fonction de coût s'écrit :

$$J(\underline{\boldsymbol{h}}) = \left\|\underline{\boldsymbol{\varepsilon}}[k]\right\|^2 = \left(\underline{\tilde{\boldsymbol{d}}}[k] - \underline{\underline{\tilde{\mathbf{X}}}}[k] \times \underline{\boldsymbol{h}}\right)^T \left(\underline{\tilde{\boldsymbol{d}}}[k] - \underline{\underline{\tilde{\mathbf{X}}}}[k] \times \underline{\boldsymbol{h}}\right)$$

$$= \left\|\underline{\tilde{\boldsymbol{d}}}[k]\right\|^2 + \underline{\boldsymbol{h}}^T \underline{\underline{\tilde{\mathbf{X}}}}^T[k] \underline{\underline{\tilde{\mathbf{X}}}}[k] \underline{\boldsymbol{h}} - 2\, \underline{\tilde{\boldsymbol{d}}}^T[k]\ \underline{\underline{\tilde{\mathbf{X}}}}[k]\ \underline{\boldsymbol{h}}$$

- Minimiser $J(\underline{\boldsymbol{h}}) = \left\|\underline{\boldsymbol{\varepsilon}}[k]\right\|^2$ conduit à annuler le gradient

$$\nabla_{\underline{\boldsymbol{h}}}\, J(\underline{\boldsymbol{h}}) = \mathbf{0} + \mathbf{2}\, \underline{\underline{\tilde{\mathbf{X}}}}^T[k] \underline{\underline{\tilde{\mathbf{X}}}}[k] \underline{\boldsymbol{h}} - 2\ \underline{\underline{\tilde{\mathbf{X}}}}^T[k]\ \underline{\tilde{\boldsymbol{d}}}[k]$$

ce qui conduit à la solution optimale (car $\underline{\underline{\tilde{\mathbf{X}}}}^T[k] \underline{\underline{\tilde{\mathbf{X}}}}[k] > \mathbf{0}$) donnée par la matrice pseudo-inverse

Solution au problème de minimisation des moindres carrés pondérés

$$\underline{\boldsymbol{h}} = \left(\underline{\underline{\tilde{\mathbf{X}}}}^T[k] \underline{\underline{\tilde{\mathbf{X}}}}[k]\right)^{-1} \underline{\underline{\tilde{\mathbf{X}}}}^T[k]\ \underline{\tilde{\boldsymbol{d}}}[k] = \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}^{-1}[k] \underline{\boldsymbol{r}}_{dx}[k]$$

Un critère d'erreur Algébrique

- Avec la matrice de corrélation (déterministe) de dimension (L x L):

$$\underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k] = \underline{\underline{\tilde{\mathbf{X}}}}^{\boldsymbol{T}}[k]\underline{\underline{\tilde{\mathbf{X}}}}[k]$$

$$= \begin{pmatrix} \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x^2[i] & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i]x[i-1] \dots & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i]x[i-L+1] \\ \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-1]x[i] & \sum_{i=1ur}^{k} \lambda^{(k-i)/2}\, x^2[i-1] \dots & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-1]x[i-L+1] \\ \vdots & \ddots & \vdots \\ \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+2]x[i] & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+2]x[i-1] \dots & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+2]x[i-L+1] \\ \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+1]x[i] & \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+1]x[i-1] \dots & \sum_{i=1}^{k} \lambda^{(k-i)/2} x^2[i-L+1] \end{pmatrix}$$

- Et le vecteur d'intercorrélation (déterministe) de dimension (L x 1):

$$\underline{\boldsymbol{r}}_{dx}[k] = \underline{\underline{\tilde{\mathbf{X}}}}^{\boldsymbol{T}}[k]\ \underline{\tilde{\boldsymbol{d}}}[k]$$

$$= \begin{pmatrix} \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i]d[i] \\ \vdots \\ \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+1]d[i] \end{pmatrix}$$

Un critère d'erreur Algébrique

- De plus si les processus aléatoires $x[.]$ et d$[.]$ sont **conjointement stationnaires et ergodiques**, alors: :

$$\lim_{k\to\infty} \frac{1}{k} \underline{\underline{\boldsymbol{\mathcal{R}}}}_{\boldsymbol{xx}}[k]\Big|_{\lambda=1} = \underline{\underline{\mathbf{R}}}_{\boldsymbol{xx}}$$

$$\lim_{k\to\infty} \frac{1}{k} \underline{\boldsymbol{r}}_{\boldsymbol{dx}}[k]\Big|_{\lambda=1} = \underline{\boldsymbol{r}}_{\boldsymbol{dx}}$$

- et donc on a **convergence** de la solution des moindres carrés pondérés vers la solution optimale de Wiener

$$\lim_{k\to\infty} \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}^{-1}[k]\underline{\boldsymbol{r}}_{dx}[k]\Big|_{\lambda=1} = \underline{\underline{\mathbf{R}}}_{xx}^{-1}\ \underline{\boldsymbol{r}}_{\boldsymbol{dx}} = \underline{\boldsymbol{h}}^{\boldsymbol{opt}}$$

Mise en œuvre récursive

- La solution précédente n'est pas optimisée d'un point de vue **complexité** algorithmique car il est nécessaire de calculer, à chaque itération k, l'inverse d'une matrice $\underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k]$ de dimension $(L \times k) \times (k \times L)$ ainsi qu'un vecteur $\underline{\boldsymbol{r}}_{dx}[k]$ de dimension $(L \times k) \times (k \times 1)$
- Il est possible de réaliser ces mêmes calculs de manière plus efficace. On montre alors la **récurrence temporelle** suivante:

$$\underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k] = \lambda\, \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k-1] + \begin{pmatrix} x^2[k] & x[k]x[k-1] & \dots & x[k]x[k-L+1] \\ x[k-1]x[k] & x^2[k-1] \dots & & x[k-1]x[k-L+1] \\ \vdots & \ddots & & \vdots \\ x[k-L+2]x[k] & x[k-L+2]x[k-1] \dots & & x[k-L+2]x[k-L+1] \\ x[k-L+1]x[k] & x[k-L+1]x[k-1] \dots & & x^2[k-L+1] \end{pmatrix}$$

$$\Rightarrow \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k] = \lambda\, \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k-1] + \begin{pmatrix} x[k] \\ \vdots \\ x[k-L+1] \end{pmatrix} (x[k] \quad \dots \quad x[k-L+1])$$

$$\Rightarrow \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k] = \lambda\, \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k-1] + \underline{\boldsymbol{x}}[k]\, \underline{\boldsymbol{x}}[k]^T$$

Mise en œuvre récursive

- De même, on montre :

$$\underline{\boldsymbol{r}}_{dx}[k] = \begin{pmatrix} \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i]d[i] \\ \vdots \\ \sum_{i=1}^{k} \lambda^{(k-i)/2}\, x[i-L+1]d[i] \end{pmatrix} = \lambda\, \underline{\boldsymbol{r}}_{dx}[k-1] + \begin{pmatrix} x[k] \\ \vdots \\ x[k-L+1] \end{pmatrix} d[k]$$

$$\Rightarrow \underline{\boldsymbol{r}}_{dx}[k] = \lambda\, \underline{\boldsymbol{r}}_{dx}[k-1] + \underline{\boldsymbol{x}}[k]d[k]$$

- Ces 2 équations conduisent à la mise en œuvre adaptative suivante :

$$\underline{\boldsymbol{r}}_{dx}[k] = \lambda\, \underline{\boldsymbol{r}}_{dx}[k-1] + \underline{\boldsymbol{x}}[k]d[k]$$

$$\underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k] = \lambda\, \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}[k-1] + \underline{\boldsymbol{x}}[k]\, \underline{\boldsymbol{x}}[k]^T$$

$$\boldsymbol{h}[k] = \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}^{-1}[k]\underline{\boldsymbol{r}}_{dx}[k]$$

1er algorithme des moindres carrés récursifs (MCR) ou Recursive Least Squares (RLS)

Mise en œuvre récursive : 2nd algorithme

- L'algorithme précédent exige un volume de calcul important à chaque itération
- aussi plutôt que de propager la matrice de corrélation (déterministe), nous allons tenter de propager son inverse. Pour cela on utilise **le lemme d'inversion matriciel** où A et B sont 2 matrices symétriques définies positives de dimension $M \times M$ telles que :

$$\begin{cases} \boldsymbol{A = B^{-1} + C\, D^{-1}\, C^T} \\ \boldsymbol{D = D^T > 0} \quad \text{(de dimension L} \times \text{L arbitraire)} \end{cases}$$

alors on a :

$$\boxed{\boldsymbol{A^{-1} = B - BC\left(D + C^T BC\right)^{-1} C^T B}}$$

- Pour notre problème on va donc poser :

$$\boldsymbol{A = \underline{\underline{\mathcal{R}}}_{xx}[k]} \qquad \boldsymbol{C = \underline{x}[k]} \qquad \boldsymbol{B^{-1} = \lambda\, \underline{\underline{\mathcal{R}}}_{xx}[k-1]} \qquad \boldsymbol{D = I_k}$$

Et ainsi

$$\boxed{\underline{\underline{\mathcal{R}}}_{xx}^{-1}[k] = \lambda^{-1}\, \underline{\underline{\mathcal{R}}}_{xx}^{-1}[k-1] - \frac{\lambda^{-2}\, \underline{\underline{\mathcal{R}}}_{xx}^{-1}[k-1]\underline{x}[k]\underline{x}[k]^T\, \underline{\underline{\mathcal{R}}}_{xx}^{-1}[k-1]}{\boldsymbol{I_k} + \lambda^{-1}\, \underline{x}[k]^T\, \underline{\underline{\mathcal{R}}}_{xx}^{-1}[k-1]\underline{x}[k]}}$$

Mise en œuvre récursive : 2nd algorithme

- Cette dernière peut s'écrire sous une forme plus compacte en posant :

$$\underline{\underline{\mathcal{P}}}[k] = \underline{\underline{\mathcal{R}}}_{xx}^{-1}[k] \qquad et \qquad \mathcal{K}[k] = \frac{\underline{\underline{\mathcal{P}}}[k-1]\,\underline{x}[k]}{\lambda\, \boldsymbol{I_k} + \underline{x}[k]^T \underline{\underline{\mathcal{P}}}[k-1]\underline{x}[k]} \quad \boxed{1}$$

Vecteur de dim $(L \times 1)$ appelé « Gain de Kalman »

Le dénominateur est un scalaire donc le calcul reste simple à implémenter

On obtient la relation suivante :

$$\underline{\underline{\mathcal{P}}}[k] = \lambda^{-1}\left(\boldsymbol{I_k} - \mathcal{K}[k]\,\underline{x}[k]^T\right)\underline{\underline{\mathcal{P}}}[k-1] \quad \boxed{2}$$

- On montre que le gain de Kalman vérifie:

$$\mathcal{K}[k]\left(\lambda\ \boldsymbol{I_k} + \underline{x}[k]^T \underline{\underline{\mathcal{P}}}[k-1]\underline{x}[k]\right) = \underline{\underline{\mathcal{P}}}[k-1]\,\underline{x}[k]$$

$$\Rightarrow \lambda\mathcal{K}[k] + \mathcal{K}[k]\underline{x}[k]^T \underline{\underline{\mathcal{P}}}[k-1]\underline{x}[k] = \underline{\underline{\mathcal{P}}}[k-1]\,\underline{x}[k]$$

$$\boxed{\Rightarrow \mathcal{K}[k] = \underline{\underline{\mathcal{P}}}[k]\,\underline{x}[k]}$$

Mise en œuvre récursive : 2nd algorithme

- Ce qui permet d'écrire la relation de mise à jour des coefficients du filtre:

$$\underline{\boldsymbol{h}}[k] = \underline{\underline{\boldsymbol{\mathcal{R}}}}_{xx}^{-1}[k]\,\underline{\boldsymbol{r}}_{dx}[k]$$

$$\Rightarrow \underline{\boldsymbol{h}}[k] = \underline{\underline{\boldsymbol{\mathcal{P}}}}[k]\left(\lambda\,\underline{\boldsymbol{r}}_{dx}[k-1] + \underline{\boldsymbol{x}}[k]d[k]\right)$$

$$\Rightarrow \underline{\boldsymbol{h}}[k] = \underbrace{\lambda\underline{\underline{\boldsymbol{\mathcal{P}}}}[k]}_{\left(\boldsymbol{I_k}-\boldsymbol{\mathcal{K}}[k]\,\underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\right)\underline{\underline{\boldsymbol{\mathcal{P}}}}[k-1]}\underline{\boldsymbol{r}}_{dx}[k-1] + \underbrace{\underline{\underline{\boldsymbol{\mathcal{P}}}}[k]\underline{\boldsymbol{x}}[k]}_{\boldsymbol{\mathcal{K}}[k]}\,d[k]$$

$$\Rightarrow \underline{\boldsymbol{h}}[k] = \left(\boldsymbol{I_k} - \boldsymbol{\mathcal{K}}[k]\,\underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\right)\underline{\boldsymbol{h}}[k-1] + \boldsymbol{\mathcal{K}}[k]\,d[k]$$

- Soit :

$$\underline{\boldsymbol{h}}[k] = \underline{\boldsymbol{h}}[k-1] + \boldsymbol{\mathcal{K}}[k]\,e[k] \quad \textbf{3}$$

avec l'erreur *a priori* donnée par : $e[k] = d[k] - \underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\underline{\boldsymbol{h}}[k-1]$

Mise en œuvre récursive : 2nd algorithme

- Nous obtenons alors une 2nd version de l'algorithme des moindres carrés. Il s'agit d'une technique récursive ne nécessitant pas l'inversion de matrice si bien que le nombre d'opérations arithmétiques est proportionnel à L^2.

Algorithme des moindres carrés récursifs (RLS)

1) A l'itération k, réception d'un nouvel échantillon $x[k]$ et formation du vecteur d'entrée
$$\underline{\boldsymbol{x}}[\boldsymbol{k}] = (x[k] \;\; x[k-1] \ldots x[k-L+1])^T$$

2) Calcul du signal en sortie de filtre : $\hat{d}[k] = \sum_{m=0}^{L-1} h^{(k-1)}[m]\, x[k-m] = \underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\, \underline{\boldsymbol{h}}[k-1]$

3) Calcul de l'erreur (dite *a priori*) : $e[k] = d[k] - \hat{d}[k]$

4) Mise à jour des coefficients :
$$\boldsymbol{\mathcal{K}}[k] = \frac{\underline{\underline{\boldsymbol{\mathcal{P}}}}[k-1]\,\underline{\boldsymbol{x}}[k]}{\lambda\; \boldsymbol{I_k} + \underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\underline{\underline{\boldsymbol{\mathcal{P}}}}[k-1]\underline{\boldsymbol{x}}[k]}$$
$$\underline{\underline{\boldsymbol{\mathcal{P}}}}[k] = \lambda^{-1}\left(\boldsymbol{I_k} - \boldsymbol{\mathcal{K}}[k]\,\underline{\boldsymbol{x}}[k]^{\boldsymbol{T}}\right)\underline{\underline{\boldsymbol{\mathcal{P}}}}[k-1]$$
$$\underline{\boldsymbol{h}}[k] = \underline{\boldsymbol{h}}[k-1] + \boldsymbol{\mathcal{K}}[k]\, e[k]$$

5) k=k+1 et retour à l'étape n°1

Mise en œuvre récursive : 2nd algorithme

- L'algorithme RLS possède de très bonnes propriétés à la fois en **convergence initiale** (vitesse de convergence) et en **convergence asymptotique** (précision de l'estimation). Ceci est lié au caractère exact du critère utilisé, qui ne fait pas appel à une approximation stochastique comme c'est le cas du NLMS.

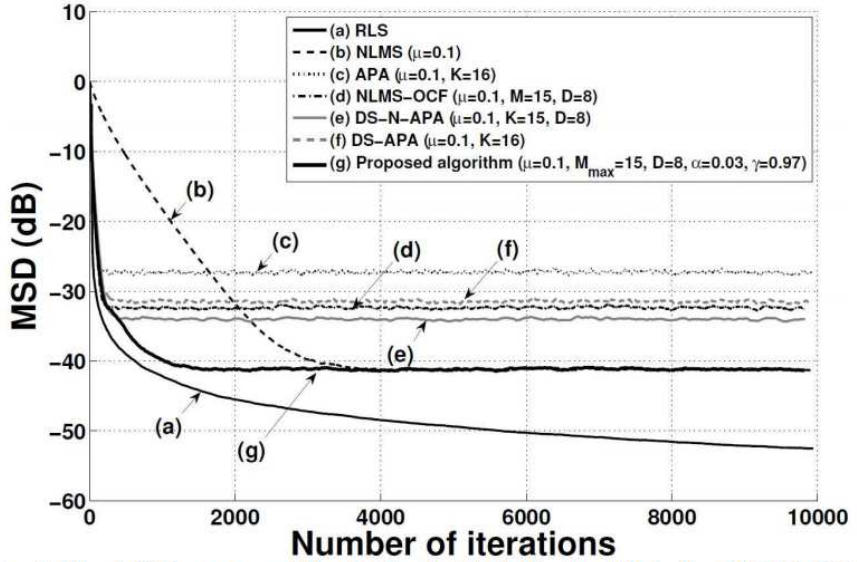


Fig. 5. The MSD curves of the RLS, the NLMS, the APA, the NLMS-OCF, the DS-APA, the DS-N-APA, and the proposed algorithm (The input signal is generated with $G_2(z)$, $n = 32$, SNR = 30dB).

Mean-Square Deviation (MSD)

$$\mathbb{E}\left[\left|\underline{\boldsymbol{h}}[k] - \underline{\boldsymbol{h}}^{opt}\right|^2\right]$$

en fonction du nombre d'itérations.



Conclusions

- Ce cours traite des principaux concepts à la base du filtrage adaptatif
  - Modélisation paramétrique
  - Filtrage optimal et théorie de Wiener
  - Filtrage adaptatif : critère statistique (LMS, NLMS de complexité $O(L)$) et critère algébrique (RLS de complexité $O(L^2)$)
- En utilisant les **propriétés de prédiction** au sein même de la mise à jour des coefficients du filtre adaptatif, il est possible de mettre au point des algorithmes RLS **dits rapides** (Fast) à faible complexité $O(L)$
  - Le FTF (Fast Transversal Filter), version rapide du RLS
  - Le FNTF (Fast Newton Transversal Filter)
- Nous nous sommes limités aux **approches temporelles** du filtrage adaptatif mais tout filtrage temporel possède un équivalent fréquentiel. On distingue:
  - Le FDAF (Frequency Domain Adaptive Filter)
  - Le MDF (Multidelay block frequency domain adaptive filter)

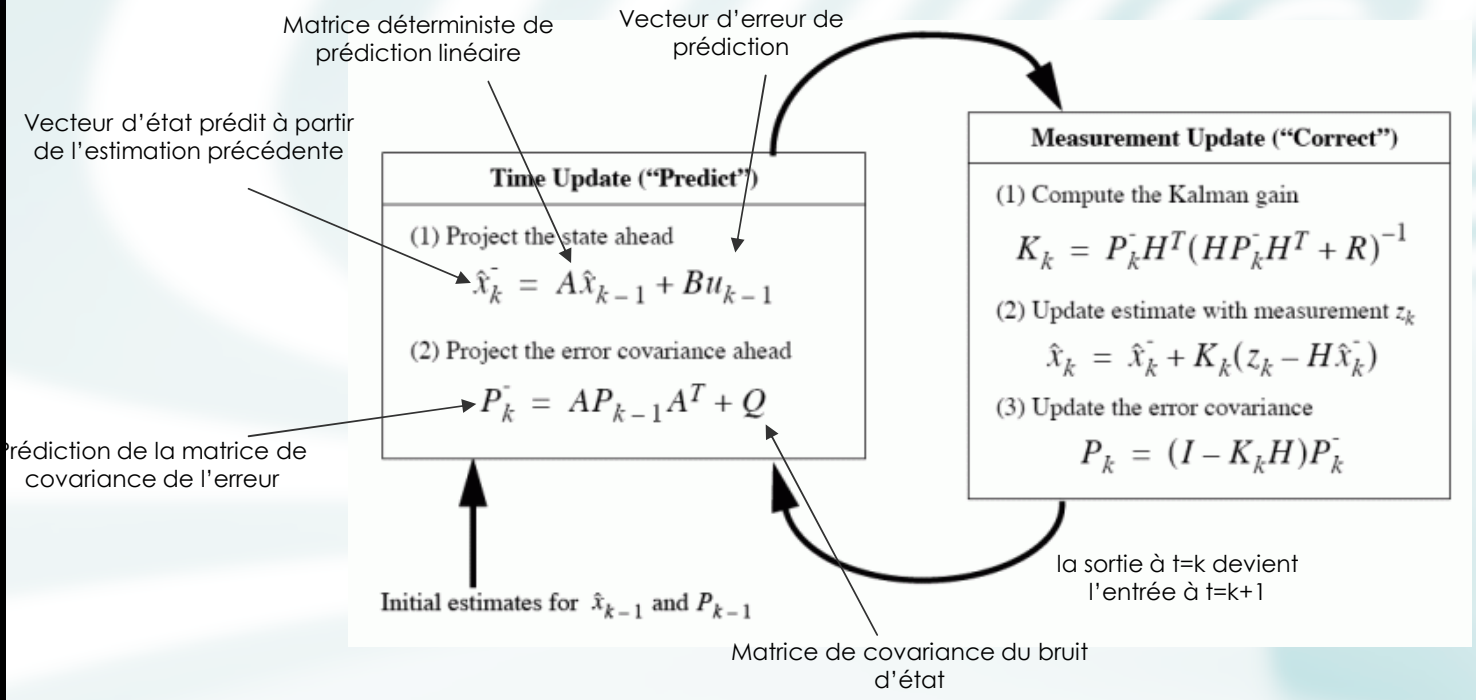


Un pas plus loin…

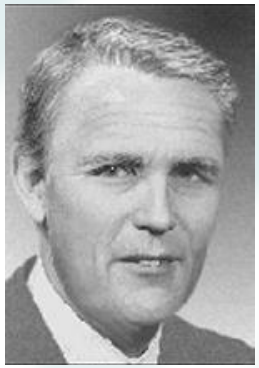
5- Le filtrage de Kalmàn

Un pas plus loin : le filtre de Kalman

- Le filtrage de Kalman (1960) est une méthode visant à estimer des paramètres d'un système évoluant dans le temps à partir de mesures bruitées. La force de ce filtre est sa **capacité de prédiction** des paramètres et de **rectification** des erreurs, non seulement des capteurs, mais aussi **du modèle** lui-même



Rudolf E. Kalman

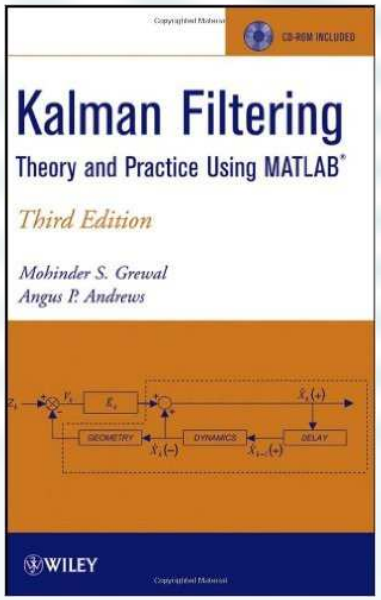




Attitude estimation with a 6DOF Inertial Mesurement Unit and a Kalman Filter

Rudolf Emil Kalman (1930-2016), USA – MIT Stanford – Califiornia State Univ. - EPFZ

- mathématicien américain, d'origine hongroise, diplômé du MIT
- Propose en 1960 une technique de filtrage en automatique mais scepticisme de la communauté
- Succès lors de l'intégration dans le programme de navigation de la mission Apollo (1961-1975)
- Professeur à l'Univ. Stanford de 1964 à 1971
- Applications : Système de navigation des missiles balistiques nucléaires de l'US Navy; guidage des que missiles longue portée Tomahawks; guidage de la navette américaine de la NASA ainsi que de la station spatiale internationale; guidage des avions commerciaux, traitement d'images,



Le 07 octobre 2009, à la maison blanche, le président américain Barak Obama remet la médaille nationale de la Science à R.E. Kalman , la plus haute distinction américaine pour des travaux scientifiques



Le filtre de Kalman : le modèle

- Positionnement du problème : système linéaire stochastique discret (invariant dans le temps) décrit par :

Vecteur d'état $\in \mathbb{R}^n$ (non observable !)

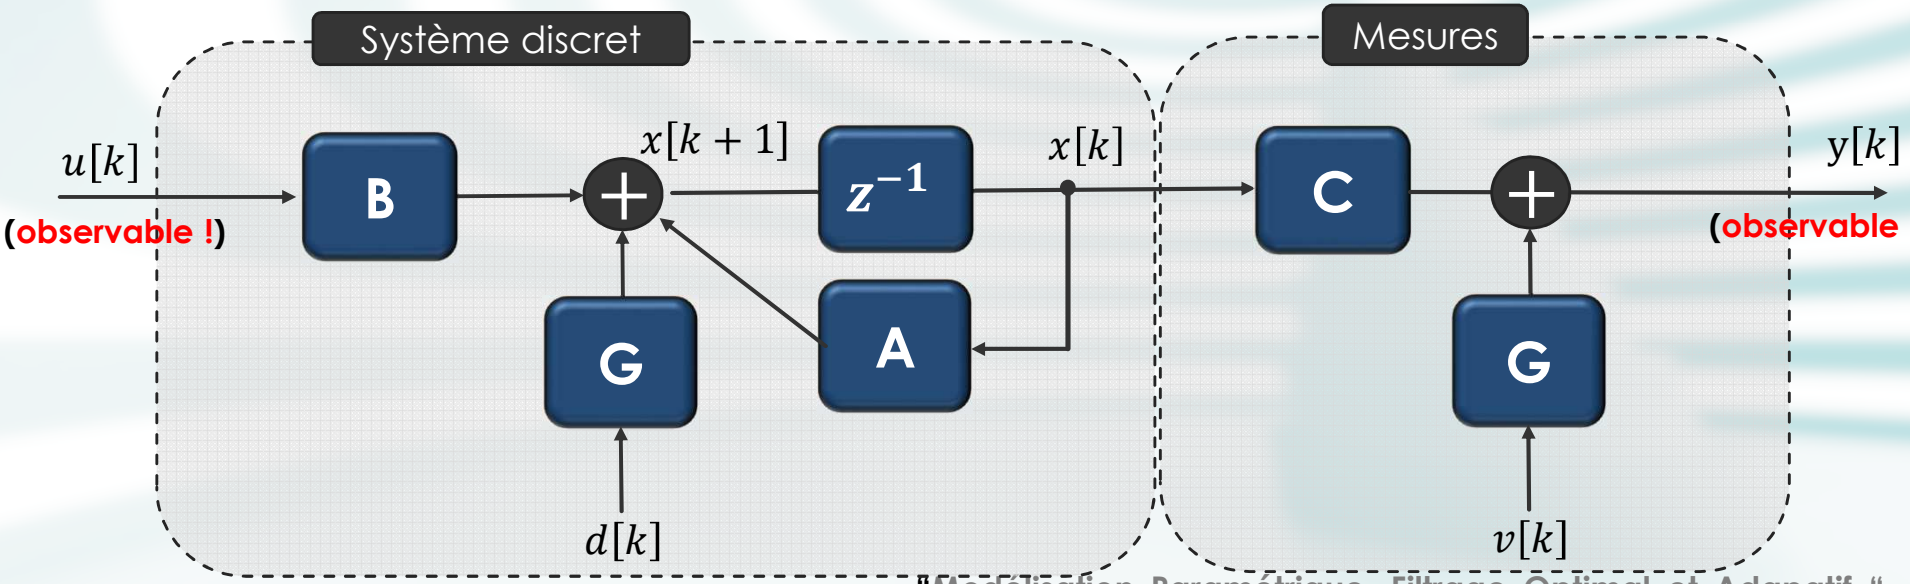
Vecteur des entrées $\in \mathbb{R}^m$

Bruit affectant le vecteur d'état $\in \mathbb{R}^q$

$$(1)\quad \underline{x}[k+1] = \boldsymbol{A}\,\underline{x}[k] + \boldsymbol{B}\,\underline{u}[k] + \boldsymbol{G}\,\underline{w}[k]$$
$$(2)\quad \underline{y}[k] = \boldsymbol{C}\,\underline{x}[k] + \underline{v}[k]$$

Vecteur des observations $\in \mathbb{R}^p$

Bruit affectant les observations $\in \mathbb{R}^p$



Le filtre de Kalman : le modèle

- Le processus aléatoire est parfaitement défini par la connaissance :
  - de son état initial $x(0)$ soit sa moyenne et sa variance

$$\bar{\underline{x}}[0] = \mathbb{E}\left(\underline{x}[0]\right)$$

$$P_0 = \mathrm{cov}\left(\underline{x}[0]\right) = \mathbb{E}\left(\left(\underline{x}[0] - \bar{\underline{x}}[0]\right)\left(\underline{x}[0] - \bar{\underline{x}}[0]\right)^T\right)$$

  - Les bruits $\{v[k]\}_{k\geq 0}$ et $\{w[k]\}_{k\geq 0}$ sont stationnaires et correspondent à des suites indépendantes de v.a. gaussiennes centrées et blanches

$$\mathbb{E}\left(\underline{\boldsymbol{v}}[k]\right) = \mathbf{0} \quad \text{et} \quad \mathbb{E}\left(\underline{\boldsymbol{w}}[k]\right) = 0$$

$$\mathbb{E}\left(\underline{\boldsymbol{v}}[k]\underline{\boldsymbol{v}}[m]^T\right) = \delta_{km}\,\boldsymbol{R} \quad \text{et} \quad \mathbb{E}\left(\underline{\boldsymbol{w}}[k]\underline{\boldsymbol{w}}[m]^T\right) = \delta_{km}\,\boldsymbol{Q}$$

avec les matrices de covariances $\boldsymbol{Q}$ et $\boldsymbol{R}$ sont définies positives.

  - Indépendance mutuelle entre l'état initial, le bruit de système et le bruit de mesures

$$\mathbb{E}\left(\underline{\boldsymbol{x}}[0]\,\underline{\boldsymbol{v}}[k]^T\right) = \mathbf{0} \qquad \mathbb{E}\left(\underline{\boldsymbol{x}}[0]\,\underline{\boldsymbol{w}}[k]^T\right) = \mathbf{0} \qquad \mathbb{E}\left(\underline{\boldsymbol{v}}[k]\underline{\boldsymbol{w}}[m]^T\right) = \mathbf{0}$$

Le filtre de Kalman : la problématique

- **Le problème** du filtrage linéaire : étant donné le modèle dynamique décrit précédemment et connaissant les entrées et les sorties jusqu'à l'instant actuel $k \geq 0$ c'est-à-dire $\{(x[i], y[i]), i = 0,1, \dots, k\}$, le problème consiste à estimer un vecteur d'état $\underline{\hat{x}}[k+l]$, également nommé $\underline{\hat{x}}[k+l|k]$, avec une **variance minimale** (MMSE).

☞ La notation $\underline{\hat{x}}[k+l|k]$ indique l'estimation du vecteur d'état à l'instant $k+l$ en prenant en compte les mesures depuis l'instant initial jusqu'à l'instant k

- Le vecteur d'erreur d'estimation est défini par

Problématique du filtrage de Kalman

$$\underline{\boldsymbol{e}}[k+l] = \underline{\boldsymbol{x}}[k+l] - \underline{\hat{\boldsymbol{x}}}[k+l|k]$$

$$\underline{\hat{\boldsymbol{x}}}[k+l|k] = \operatorname{argmin} \mathbb{E}\left(\underline{\boldsymbol{e}}[k+l]^T \underline{\boldsymbol{e}}[k+l]\right) = \operatorname{argmin} \operatorname{trace} \mathbb{E}\left(\underline{\boldsymbol{e}}[k+l]\underline{\boldsymbol{e}}[k+l]^T\right)$$

- Généralement, on considère 2 problématiques : le problème du **filtrage de Kalman** (lorsque $l = 0$) et le problème du **prédicteur de Kalman** à un pas (lorsque $l = 1$).

1ère problématique : le filtrage de Kalman

- Soit $\underline{\boldsymbol{e}}[k|k] = \underline{\boldsymbol{x}}[k] - \underline{\hat{\boldsymbol{x}}}[k|k]$ le vecteur d'erreur d'estimation, et soit $\boldsymbol{P}[k|k] = \mathbb{E}\left(\underline{\boldsymbol{e}}[k|k]\ \underline{\boldsymbol{e}}[k|k]^T\right)$ la matrice de covariance associée à cette erreur

- But étape n°1: Connaissant les mesures jusqu'à l'instant k , **la meilleure prédiction** du vecteur d'état $\underline{\boldsymbol{x}}[k+1]$ à partir de l'estimé $\underline{\hat{\boldsymbol{x}}}[k|k]$ est :

$$\textbf{(2bis)} \quad \boxed{\underline{\hat{\boldsymbol{x}}}[k+1|k] = \boldsymbol{A}\ \underline{\hat{\boldsymbol{x}}}[k|k] + \boldsymbol{B}\ \underline{\boldsymbol{u}}[k]}$$

alors on définit :

(3) $\underline{\boldsymbol{e}}[k+1|k] = \underline{\boldsymbol{x}}[k+1] - \underline{\hat{\boldsymbol{x}}}[k+1|k]$ Erreur d'estimation ***a priori***

(4) $\underline{\hat{\boldsymbol{y}}}[k+1|k] = \boldsymbol{C}\ \underline{\hat{\boldsymbol{x}}}[k+1|k]$ Estimation ***a priori*** de la sortie

(5) $\underline{\hat{\boldsymbol{y}}}[k+1|k+1] = \boldsymbol{C}\ \underline{\hat{\boldsymbol{x}}}[k+1|k+1]$ Estimation ***a posteriori*** de la sortie

Étape n°1 prédiction

- La covariance de l'erreur d'estimation *a priori* est donnée par :

$$\begin{aligned}
\boldsymbol{P}[k+1|k] &= \mathbb{E}\left(\underline{\boldsymbol{e}}[k+1|k]\ \underline{\boldsymbol{e}}[k+1|k]^T\right) \\
&= \mathbb{E}\left(\left(\underline{\boldsymbol{x}}[k+1] - \boldsymbol{A}\ \underline{\hat{\boldsymbol{x}}}[k|k] - \boldsymbol{B}\ \underline{\boldsymbol{u}}[k]\right)\underline{\boldsymbol{e}}[k+1|k]^T\right) \\
&= \mathbb{E}\left(\left(\boldsymbol{A}\ \underbrace{\left(\underline{\boldsymbol{x}}[k] - \underline{\hat{\boldsymbol{x}}}[k|k]\right)}_{\underline{\boldsymbol{e}}[k|k]} + \boldsymbol{G}\ \underline{\boldsymbol{w}}[k]\right)\underline{\boldsymbol{e}}[k+1|k]^T\right)
\end{aligned}$$

car $\underline{\boldsymbol{x}}[k+1] = \boldsymbol{A}\ \underline{\boldsymbol{x}}[k] + \boldsymbol{B}\ \underline{\boldsymbol{u}}[k] + \boldsymbol{G}\ \underline{\boldsymbol{w}}[k]$

$$\Rightarrow \boxed{\boldsymbol{P}[k+1|k] = \boldsymbol{A}\ \boldsymbol{P}[k+1|k]\boldsymbol{A}^T + \boldsymbol{G}\ \boldsymbol{Q}\boldsymbol{G}^T}$$

1ère problématique : le filtrage de Kalman

- But étape n°2: En utilisant la mesure obtenue à l'instant $k+1$, établir la relation liant **l'estimée *a posteriori*** et **l'estimée *a priori*** du vecteur d'état $\underline{\boldsymbol{x}}[k+1]$

on cherche un estimateur linéaire :

$$\boxed{\underline{\hat{\boldsymbol{x}}}[k+1|k+1] = \underline{\hat{\boldsymbol{x}}}[k+1|k] + K_e[k+1]\left(\boldsymbol{y}[k+1] - \hat{\boldsymbol{y}}[k+1|k]\right)}$$

- On cherche le paramètre K_e qui optimise le critère :

$$\begin{aligned} J(K_e) &= \mathbb{E}\left(\underline{\boldsymbol{e}}[k+1|k+1]^T \underline{\boldsymbol{e}}[k+1|k+1]\right) \\ &= \text{trace}\,\mathbb{E}\left(\underline{\boldsymbol{e}}[k+1|k+1]\,\underline{\boldsymbol{e}}[k+1|k+1]^T\right) \\ &= \text{trace}\,\boldsymbol{P}[k+1|k+1] \end{aligned}$$

Étape n°2
Estimation
(réactualisation)

- On cherche une relation de récurrence entre la matrice de covariance de l'erreur ***a posteriori*** $\boldsymbol{P}[k+1|k+1]$ et celle de l'erreur ***a priori*** $\boldsymbol{P}[k+1|k]$

$$\begin{aligned} \boldsymbol{P}[k+1|k+1] &= \mathbb{E}\left(\left(\underline{\boldsymbol{x}}[k+1] - \underline{\hat{\boldsymbol{x}}}[k+1|k+1]\right)\left(\underline{\boldsymbol{x}}[k+1] - \underline{\hat{\boldsymbol{x}}}[k+1|k+1]\right)^T\right) \\ &= \mathbb{E}\left(\left(\underline{\boldsymbol{e}}[k+1|k] - K_e[k+1]\,\underline{\boldsymbol{e}}_1[k+1|k]\right)\left(\underline{\boldsymbol{e}}[k+1|k] - K_e[k+1]\,\underline{\boldsymbol{e}}_1[k+1|k]\right)^T\right) \end{aligned}$$

où $\underline{\boldsymbol{e}}_1[k+1|k] = \boldsymbol{y}[k+1] - \hat{\boldsymbol{y}}[k+1|k]$

1ère problématique : le filtrage de Kalman

- on obtient 4 termes :

$$\boldsymbol{P}[k+1|k+1]=\mathbb{E}\left(\underline{\boldsymbol{e}}[k+1|k]\,\underline{\boldsymbol{e}}[k+1|k]^T+K_e[k+1]\underline{\boldsymbol{e_1}}[k+1|k]\underline{\boldsymbol{e_1}}[k+1|k]^T K_e[k+1]^T - K_e[k+1]\,\underline{\boldsymbol{e}}_1[k+1|k]\,\underline{\boldsymbol{e}}[k+1|k]^T-\underline{\boldsymbol{e}}[k+1|k]\,\underline{\boldsymbol{e}}_1[k+1|k]^T K_e[k+1]^T\right)$$

Soit encore :

$$\boxed{\begin{array}{c}\boldsymbol{P}[k+1|k+1]=\boldsymbol{P}[k+1|k]+K_e[k+1]\boldsymbol{P}_{e_1e_1}[k+1|k]\,K_e[k+1]^T\ \ldots\\ \ldots-\boldsymbol{P}_{e\,e_1}[k+1|k]\,K_e[k+1]^T-K_e[k+1]\,\boldsymbol{P}_{e_1e}[k+1|k]\end{array}}\quad(6)$$

- En insérant les relations (2) et (5) du modèle, on obtient :

$$\begin{aligned}\underline{\boldsymbol{e}}_1[k+1|k]&=\left(\boldsymbol{C}\,\underline{\boldsymbol{x}}[k+1]+\underline{\boldsymbol{v}}[k+1]\right)-\boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]\\&=\boldsymbol{C}\underline{\boldsymbol{e}}[k+1|k]+\underline{\boldsymbol{v}}[k+1]\end{aligned}$$

$$\Rightarrow \boldsymbol{P}_{e_1e_1}[k+1|k]=\boldsymbol{C}\,\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T+\boldsymbol{Q}$$

Étape n°2
Estimation
(réactualisation)

- De même, on obtient :

$$\boldsymbol{P}_{ee_1}[k+1|k]=\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T$$
$$\boldsymbol{P}_{e_1e}[k+1|k]=\boldsymbol{C}\,\boldsymbol{P}[k+1|k]$$

1ère problématique : le filtrage de Kalman

- Solution du problème : minimisation de $J = \text{argmin trace}\,\mathbb{E}\left(\underline{\boldsymbol{e}}[k]\underline{\boldsymbol{e}}[k]^T\right)$

$$\frac{dJ}{dK_e} = 0 \Rightarrow \mathbf{2}K_e[k+1]\,\boldsymbol{P}_{e_1e_1}[k+1|k] - 2\boldsymbol{P}_{e\,e_1}[k+1|k] = 0$$

Soit encore : $K_e[k+1] = \boldsymbol{P}_{e\,e_1}[k+1|k]\left(\boldsymbol{P}_{e_1e_1}[k+1|k]\right)^{-1}$

- Soit encore en insérant les relations précédentes :

$$\boxed{K_e[k+1] = \boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T(\boldsymbol{C}\,\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T + \boldsymbol{Q}\,)^{-1}}$$

Étape n°2
Estimation
(réactualisation)

- À partir de (6), on obtient la relation de récurrence suivante pour la matrice de covariance :

$$\boldsymbol{P}[k+1|k+1] = \boldsymbol{P}[k+1|k] - \boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T(\boldsymbol{C}\,\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T + \boldsymbol{Q}\,)^{-1}\boldsymbol{C}\,\boldsymbol{P}[k+1|k]$$

1ère problématique : le filtrage de Kalman

- L'algorithme de Kalmàn est alors obtenu par les relations suivantes

(2bis) $\underline{\hat{\boldsymbol{x}}}[k+1|k] = \boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k]$

$\boldsymbol{P}[k+1|k] = \boldsymbol{A}\,\boldsymbol{P}[k|k]\boldsymbol{A}^T + \boldsymbol{G}\,\boldsymbol{Q}\boldsymbol{G}^T$

Étape n°1 prédiction

$K_e[k+1] = \boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T(\boldsymbol{C}\,\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T + \boldsymbol{R})^{-1}$

(4) $\underline{\hat{\boldsymbol{y}}}[k+1|k] = \boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]$

Étape n°2 Estimation (réactualisation)

$\underline{\hat{\boldsymbol{x}}}[k+1|k+1] = \underline{\hat{\boldsymbol{x}}}[k+1|k] + K_e[k+1]\,(\,\boldsymbol{y}[k+1] - \hat{\boldsymbol{y}}[k+1|k]\,)$

$\boldsymbol{P}[k+1|k+1] = \boldsymbol{P}[k+1|k] - K_e[k+1]\,\boldsymbol{C}\,\boldsymbol{P}[k+1|k]$

$\underline{\hat{\boldsymbol{x}}}[k|k]$ → Étape n°1 prédiction → $\underline{\hat{\boldsymbol{x}}}[k+1|k]$ → Étape n°2 Estimation → $\underline{\hat{\boldsymbol{x}}}[k+1|k+1]$

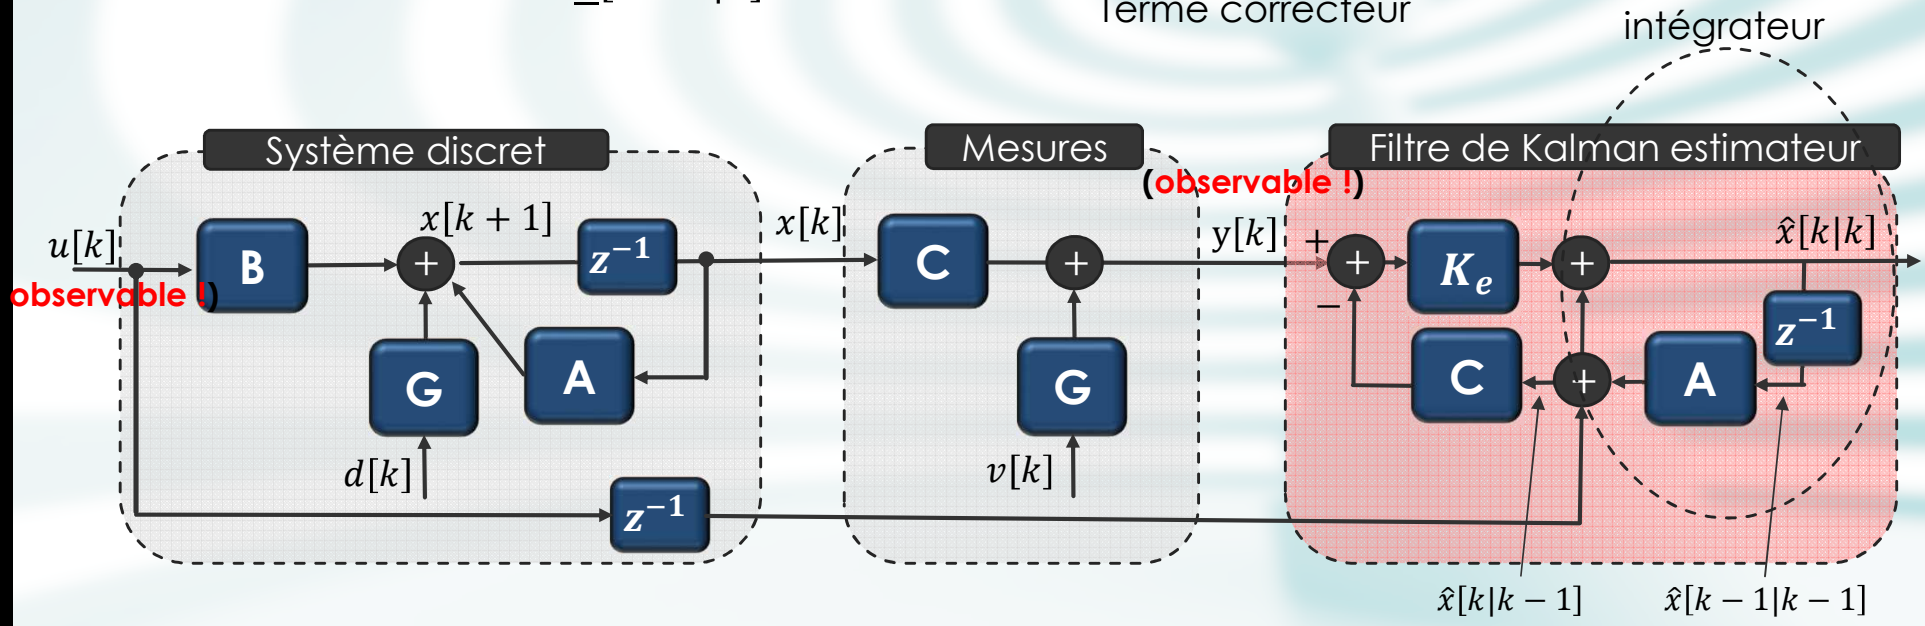
☞ L'équation d'évolution du gain de Kalman $K_e[k]$ et de la matrice de covariance $\boldsymbol{P}[k|k]$ sont indépendantes de la mesure $\boldsymbol{y}[k]$ donc on peut les calculer hors ligne

1ère problématique : le filtrage de Kalman

- L'estimée *a posteriori* de Kalmàn est alors obtenue par la relation suivante :

$$\underline{\hat{\boldsymbol{x}}}[k+1|k+1] = \underbrace{\boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k]}_{\text{Modèle du système } \underline{\hat{\boldsymbol{x}}}[k+1|k]} + \underbrace{K_e[k+1]\,\big(\,\boldsymbol{y}[k+1] - \boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]\,\big)}_{\text{innovation}}$$

Terme correcteur



2nde problématique : le filtrage de Kalman prédicteur

- But : on cherche une estimée linéaire $\hat{x}[k+1|k]$ de $x[k+1]$ qui minimise la trace de la matrice de covariance de l'erreur d'estimation :

$$\underline{\boldsymbol{e}}[k+1] = \underline{\boldsymbol{x}}[k+1] - \underline{\hat{\boldsymbol{x}}}[k+1|k]$$

- Etape n°1: Connaissant les mesures jusqu'à l'instant $k-1$, **la meilleure prédiction** du vecteur d'état $\underline{\boldsymbol{x}}[k+1]$ à partir de l'estimé $\underline{\hat{\boldsymbol{x}}}[k|k-1]$ est :

$$\underline{\hat{\boldsymbol{x}}}[k+1|k-1] = \boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k-1] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k]$$

- Etape n°2: En utilisant la mesure obtenue à l'instant k , établir la relation liant **l'estimée *a posteriori*** et **l'estimée *a priori*** du vecteur d'état $\underline{\boldsymbol{x}}[k+1]$

$$\underline{\hat{\boldsymbol{x}}}[k+1|k] = \underline{\hat{\boldsymbol{x}}}[k+1|k-1] + K_P[k+1]\left(\boldsymbol{y}[k+1] - \hat{\boldsymbol{y}}[k+1|k]\right)$$

avec **(4)** $\underline{\hat{\boldsymbol{y}}}[k+1|k] = \boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]$

2nde problématique : le filtrage de Kalman prédicteur

- En utilisant les relations déterminées antérieurement, e filtre prédicteur de Kalmàn est alors obtenu par les relations suivantes :

$$\underline{\hat{\boldsymbol{x}}}[k+1|k-1] = \boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k-1] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k]$$

$$\boldsymbol{P}[k+1|k-1] = \boldsymbol{A}\,\boldsymbol{P}[k|k-1]\boldsymbol{A}^T + \boldsymbol{G}\,\boldsymbol{Q}\boldsymbol{G}^T$$

Étape n°1 prédiction

$$K_P[k+1] = \boldsymbol{A}K_e[k] = \boldsymbol{A}\,\boldsymbol{P}[k|k-1]\,\boldsymbol{C}^T(\boldsymbol{C}\,\boldsymbol{P}[k|k-1]\,\boldsymbol{C}^T + \boldsymbol{R}\,)^{-1}$$

$$\underline{\hat{\boldsymbol{y}}}[k+1|k] = \boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]$$

$$\underline{\hat{\boldsymbol{x}}}[k+1|k] = \underline{\hat{\boldsymbol{x}}}[k+1|k-1] + K_P[k+1]\,(\,\boldsymbol{y}[k+1] - \hat{\boldsymbol{y}}[k+1|k]\,)$$

$$\boldsymbol{P}[k+1|k] = \boldsymbol{P}[k+1|k-1] - K_P[k+1]\,\boldsymbol{C}\,\boldsymbol{P}[k|k-1]\,\boldsymbol{A}^T$$

Étape n°2 Estimation (réactualisation)

$$\underline{\hat{\boldsymbol{x}}}[k|k-1] \xrightarrow{\text{Étape n°1 prédiction}} \underline{\hat{\boldsymbol{x}}}[k+1|k-1] \xrightarrow{\text{Étape n°2 Estimation}} \underline{\hat{\boldsymbol{x}}}[k+1|k]$$

2nde problématique : le filtrage de Kalman prédicteur

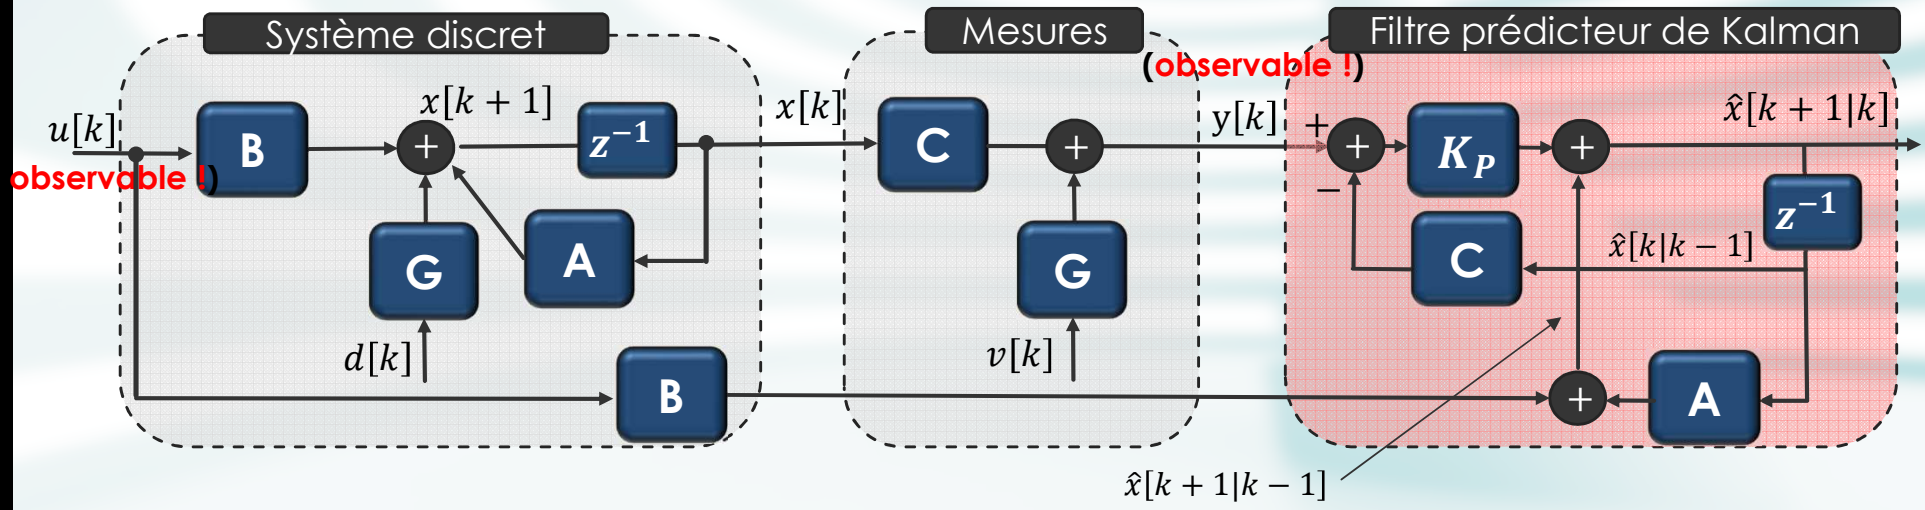
- La prédiction *a posteriori* de Kalmàn est alors obtenue par la relation suivante :

$$\underline{\hat{\boldsymbol{x}}}[k+1|k] = \boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k-1] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k] + K_P[k+1]\left(\boldsymbol{y}[k+1] - \boldsymbol{C}\,\underline{\hat{\boldsymbol{x}}}[k+1|k]\right)$$

Modèle du système $\underline{\hat{\boldsymbol{x}}}[k+1|k-1]$

innovation

Terme correcteur



Propriétés des filtres de Kalman

- L'estimateur de Kalman est une ***estimateur efficace*** (car à minimum de variance), de plus il s'agit ***d'estimateur non biaisé*** car les erreurs d'estimation $\underline{\boldsymbol{e}}[k|k]$ et de prédiction $\underline{\boldsymbol{e}}[k+1|k]$ sont des séquences aléatoires gaussiennes centrées

$$\mathbb{E}\big(\underline{\boldsymbol{e}}[k+1|k]\big) = 0 \quad et \quad \mathbb{E}\big(\underline{\boldsymbol{e}}[k|k]\big) = 0$$

- Si le régime permanent est atteint alors : $\boldsymbol{P}[k+1|k] \longrightarrow \boldsymbol{P}_\infty$ et $\begin{cases} \boldsymbol{K_e}[k] \longrightarrow \boldsymbol{K_{e_\infty}} \\ \boldsymbol{K_P}[k] \longrightarrow \boldsymbol{K_{P_\infty}} \end{cases}$
- On obtient alors : $\boldsymbol{K_{e_\infty}} = \boldsymbol{P_\infty}\,\boldsymbol{C}^T(\boldsymbol{C}\boldsymbol{P_\infty}\,\boldsymbol{C}^T + \boldsymbol{R})^{-1}$

$$\boldsymbol{K_{P_\infty}} = \boldsymbol{A}\boldsymbol{P_\infty}\,\boldsymbol{C}^T(\boldsymbol{C}\boldsymbol{P_\infty}\,\boldsymbol{C}^T + \boldsymbol{R})^{-1}$$

$$\Rightarrow \boldsymbol{P_\infty} = \boldsymbol{A}\boldsymbol{P_\infty}\,\boldsymbol{A}^T - \boldsymbol{A}\boldsymbol{P_\infty}\,\boldsymbol{C}^T(\boldsymbol{C}\boldsymbol{P_\infty}\,\boldsymbol{C}^T + \boldsymbol{R})^{-1}\boldsymbol{C}\boldsymbol{P_\infty}\boldsymbol{A}^T + \boldsymbol{G}\,\boldsymbol{Q}\boldsymbol{G}^T$$

- Cette dernière relation permet de calculer $\boldsymbol{P}_\infty$. Il s'agit de l'***équation algébrique de Ricatti discrète*** (ou DARE pour Discrete Agebraic Equation)
- Le filtre est (asymptotiquement) stable si la matrice $\boldsymbol{A} - \boldsymbol{K_{P_\infty}}\boldsymbol{C}$ est Schur stable (i.e. si ses valeurs propres sont à l'intérieur du cercle unité). L'équation de Ricatti admet alors une solution

Propriétés des filtres de Kalman

- A partir des relations établies précédemment, on montre que :

$$\boldsymbol{P}[k+1|k+1]=\boldsymbol{P}[k+1|k]-\underbrace{\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T(\boldsymbol{C}\,\boldsymbol{P}[k+1|k]\,\boldsymbol{C}^T+\boldsymbol{R})^{-1}\boldsymbol{C}\,\boldsymbol{P}[k+1|k]}_{définie\ positive}<\boldsymbol{P}[k+1|k]$$

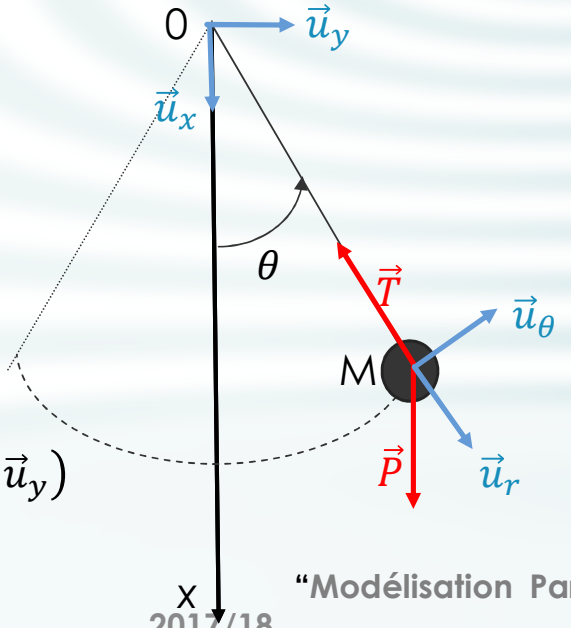
on en déduit :

$$\mathbb{E}(\mathrm{e}[k+1|k+1]\mathrm{e}[k+1|k+1]^T)<\mathbb{E}(\mathrm{e}[k+1|k]\mathrm{e}[k+1|k]^T)$$

- La prise en compte de la mesure $y[k]$ dans l'estimation $x[k|k]$ améliore la qualité de la prédiction $x[k|k-1]$

Un exemple : La fusion de capteurs (1/3)

- Estimer l'angle d'inclinaison ainsi que la vitesse angulaire d'un objet selon un axe uniquement à l'aide d'un filtre de Kalman. On dispose de 2 capteurs
  - Un accéléromètre détectant **l'accélération a_θ** d'un mobile selon un axe. Cet accéléromètre nous renvoie des valeurs d'accélérations bruitées
  - Un gyroscope détectant **la vitesse angulaire** v_θ selon l'axe Ox (donc la vitesse à laquelle le mobile s'incline). Ce gyroscope nous renvoie des valeurs de vitesses angulaires bruitées et biaisées. La difficulté est que le gyroscope possède un biais (inconnu) évoluant dans le temps ! On dit que les gyroscopes dérivent.



(A) $\sum \vec{f} = m\,\vec{a} \Leftrightarrow \vec{P} + \vec{T} = m\frac{d^2\overrightarrow{OM}}{dt^2}$

$$\vec{P} = mg\,\vec{u}_x$$
$$\vec{T} = -T\,\vec{u}_r$$
$$\overrightarrow{OM} = l\,\vec{u}_r = l\left(cos\theta\,\vec{u}_x + sin\theta\;\vec{u}_y\right)$$

$$\vec{v} = \frac{d\overrightarrow{OM}}{dt} = l\frac{d\vec{u}_r}{dt} = l\,\dot{\theta}\;\vec{u}_\theta$$

$$\vec{a} = l\left(-\dot{\theta}^2\,\vec{u}_r + \ddot{\theta}\;\vec{u}_\theta\right)$$

Soit après projection de (A)sur $(0,\vec{u}_\theta)$:

$$\ddot{\theta} + \frac{g}{l}sin\theta = 0 \xrightarrow{\theta\ faible} \ddot{\theta} \cong -\frac{g}{l}\theta$$

Un exemple : La fusion de capteurs (2/3)

- Avec nos 2 capteurs, on obtient les 2 équations suivantes

$$a_\theta = l\ddot{\theta} + b_a \cong -g\,\theta + b_1$$

Bruit accéléromètre.

$$v_\theta = l\dot{\theta} + (b + b_2)$$

biais gyroscope

Bruit gyroscope

$$\boldsymbol{R} = \mathbb{E}\left[\begin{pmatrix} b_1 \\ b_2 \end{pmatrix}(b_1 \quad b_2)\right] = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}$$

On utilise le jeu des 2 relations (celle en rouge + la 2nde en violet) plutôt que le jeu des 2 relations en violet, car ce dernier jeu de relations nécessite d'intégrer 1 fois $\dot{\theta}$ et 2 fois $\ddot{\theta}$ afin d'obtenir une estimation de θ (mais alors on va également intégrer les bruits b_a et b_2 ce qui va produire des erreurs d'estimation).

- Soit encore sous forme matricielle :

Vecteur de mesure.

Vecteur bruit de mesure.

Equation de mesure

$$\begin{pmatrix} v_\theta \\ a_\theta \end{pmatrix} = \begin{pmatrix} l & 0 & 1 \\ 0 & -g & 0 \end{pmatrix}\begin{pmatrix} \dot{\theta} \\ \theta \\ b \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} \Leftrightarrow \boxed{\underline{\boldsymbol{y}}[k] = \boldsymbol{C}\,\underline{\boldsymbol{x}}[k] + \underline{\boldsymbol{v}}[k]}$$

Matrice d'observation

Vecteur d'état

- Il nous reste à modéliser l'évolution temporelle du vecteur d'état. Pour cela on suppose que l'on a :

Equation d'évolution d'état : PREDICTION.

$$\begin{pmatrix} \dot{\theta} \\ \theta \\ b \end{pmatrix}_{k+1} = \begin{pmatrix} 1 & 0 & 0 \\ T_e & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}\begin{pmatrix} \dot{\theta} \\ \theta \\ b \end{pmatrix}_k \Rightarrow \boxed{\underline{\hat{\boldsymbol{x}}}[k+1|k] = \boldsymbol{A}\,\underline{\hat{\boldsymbol{x}}}[k|k] + \boldsymbol{B}\,\underline{\boldsymbol{u}}[k]}$$

Vitesse angulaire $\cong constante$

$\theta[k+1] \cong \theta[k] + \boldsymbol{T_e}\,\dot{\theta}$

biais du gyroscope $\cong constante$

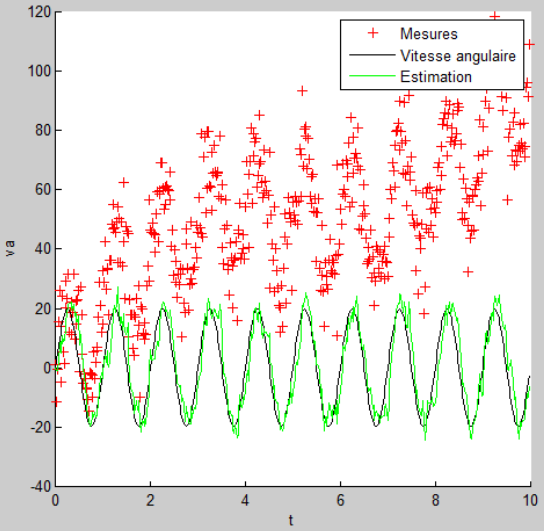
Un exemple: la fusion de capteurs (3/3)

- Les deux étapes (prédiction + filtrage de Kalman) permettent de suivre l'évolution temporelle du vecteur d'état

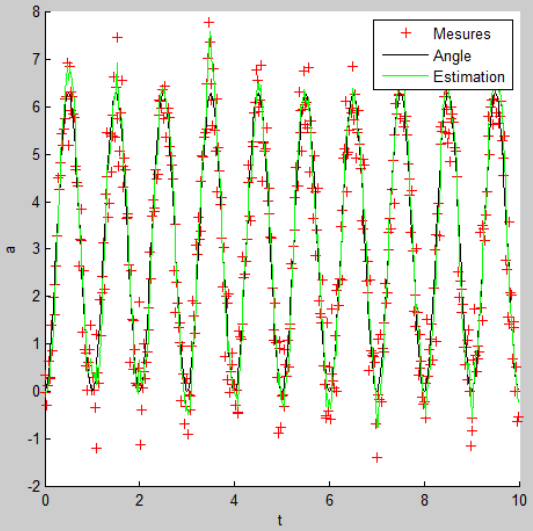
si vous êtes intéressés par cette technique, vous trouverez une bonne explication sur http://www.ferdinandpiette.com/blog/2011/04/le-filtre-de-kalman-interets-et-limites/

Note: les figures proviennent du site http://www.ferdinandpiette.com/blog/2011/04/exemple-dutilisation-du-filtre-de-kalman/

Estimation vitesse angulaire (gyroscope)



Estimation de l'angle (accéléromètre)



Estimation du biais GYROSCOPE

